

* Major Machine Learning Technique *

• REGRESSION / ESTIMATION: (PRE DICCION)

- PARA PREDICIR UN VALOR CONTINUO

↳ PARA PREDICIR EL PRECIO DE UNA CASA EN FUNCION DE SUS CARACTERISTICAS

→ ESTIMAR LAS EMISIONES DEL MOTOR DE UN AUTOMOVIL

• CLASSIFICATION:

- TÉCNICA DE CLASIFICACIÓN PARA PREDICIR LA CLASE O CATEGORÍA DE UN CASO

↳ SI UNA CÉLULA ES BENIGNA O MALIGNA

→ SI UN CLIENTE QUEDARÁ O NO SU TELECOMUNICADORA

• CLUSTERING: (AGUPACION / GRUPOS)

- AGRUPA LOS CASOS SIMILARES

↳ PACIENTES SIMILARES

→ SEGMENTACIÓN DE CLIENTES EN EL CAMPO BANCARIO

• ASSOCIATIONS:

- TÉCNICA DE ASOCIACIÓN PARA ENCONTRAR ARTICULOS O OBJETOS QUE A MENUDO COEXISTEN

↳ ARTICULOS QUE UN CLIENTE SUELE COMPRAR JUNTOS

● ANOMALY DETECTION

- DETECCIÓN DE ANOMALÍAS.

↳ FRAUDES EN TARJETAS DE CRÉDITO

● SEQUENCE MINING

- MINERÍA DE SECUENCIAS: SE USA PARA PREDICIR EL SIGUIENTE EVENTO

↳ UN FLUJO DE CLICS EN UN SITIO WEB

● DIMENSION REDUCTION

- REDUCCIÓN DE DIMENSION SE USA PARA REDUCIR EL TAMAÑO DE LOS DATOS (PCA)

● RECOMMENDATION SYSTEMS

- LOS SISTEMAS DE RECOMENDACIÓN SE USAN PARA ASOCIAR LAS PREFERENCIAS DE UNAS PERSONAS CON OTRAS, QUE TIENEN GUSTOS SIMILARES

↳ LES RECOMIENDAN NUEVOS ARTÍCULOS, LIBROS, PELÍCULAS, ETC.

DIFERENCIAS ENTRE:

- INTELIGENCIA ARTIFICIAL $\Rightarrow$ AI
- MACHINE LEARNING $\Rightarrow$ ML
- DEEP LEARNING $\Rightarrow$ DP

- AI COMPONENTS:

- COMPUTER VISION
- LANGUAGE PROCESSING
- CREATIVITY
- ETC

- MACHINE LEARNING

- CLASSIFICATION
- CLUSTERING
- NEURAL NETWORK

- REVOLUTION in ML:

- DEEP LEARNING.

AI COMPONENTS

#####

- LA "AI" INTENTA HACER QUE LAS COMPUTADORAS SEAN INTELGENTES PARA IMITAR FUNCIONES COGNITIVAS DE LOS HUMANOS

MACHINE LEARNING

* APRENDIZAJE AUTOMÁTICO

- ES LA RAMA DE LA "AI" QUE COBRE LA PARTE ESTADÍSTICA DE LA INTELIGENCIA ARTIFICIAL
- ENSEÑA A LA COMPUTADORA A RESOLVER PROBLEMAS OBSERVANDO MILES DE EJEMPLOS



● APRENDE DE ELLOS Y DESPUÉS USA
ESA EXPERIENCIA PARA RESOLVER
EL MISMO PROBLEMA EN SITUACIONES
NUEVAS.

#####

DEEP LEARNING

*APRENDIZAJE PROFUNDO

● ES UN CAMPO MUY ESPECIAL DEL
MACHINE LEARNING EN EL QUE
LAS COMPUTADORAS PUEDEN APRENDER
Y TOMAR DECISIONES INTELIGENTES POR
SI MISMAS.

● IMPLICA UN NIVEL DE AUTOMATIZACIÓN
MÁS PROFUNDO EN COMPARACIÓN CON LA
MAYORÍA DE ALGORITMOS DE ML

* MACHINE LEARNING *

• MACHINE LEARNING APP

• MACHINE LEARNING ALGORITHMS

→ APLICACIONES EN EL MUNDO REAL

→ - DESCRIPCION GENERAL DE LOS
TEMAS DE MACHINE LEARNING.

- COMO EL "APRENDIZAJE SUPERVISADO"
Y EL "NO SUPERVISADO"

- VARIOS ALGORITMOS DE APRENDIZAJE ..
AUTOMÁTICO

#####

PYTHON FOR MACHINE LEARNING

#####

• LIBRERIAS Python:

- se pueden escribir los algoritmos de MACHINE LEARNING y dirona muy bien

#####

PAQUETES DE LIBRERIAS

#####

* NUMPY: LIBRERIA MATEMATICA PARA TRABAJAR CON MATRICES N-DIMENSIONALES

CALCULOS EFICIENTES Y EFICACES

ES MEJOR QUE PYTHON NORMAL



INTERICA

- CALCULOS
- FUNCIONES
- TIPOS DE DATOS
- IMAGENES

*SCIPY: COLECCION DE ALGORITMOS NUMÉRICOS Y
CASAS DE HERRAMIENTAS ESPECÍFICAS DE
DOMINIO.

↓
CIENTÍFICA

- PROCESAMIENTO DE SEÑALES
- OPTIMIZACIÓN
- ESTADÍSTICAS
- ETC.

IDEN PARA COMPUTACIÓN CIENTÍFICA
Y ALTO RENDIMIENTO

*MATPLOTLIB: PAQUETE DE TRAZADO POPULAR QUE
PROPORCIONA GRÁFICOS 2D Y 3D

!!!**¡¡¡¡¡**IMPORTANTE!!!
..

PARA ENTENDER ESTAS CIBERBAS HAZER EL
CURSO "ANÁLISIS DE DATOS CON PYTHON"

*PANDAS: BIBLIOTECA PYTHON DE HUYALD NICEZ
ESTRUCTURAS DE DATOS FÁCILES DE USAR
Y ALTO RENDIMIENTO

IMPORTACIÓN, MANEJO Y ANÁLISIS DE
DATOS

OFRECE ESTRUCTURAS DE OPERACIONES
PARA MANIPULAR TABLAS NUMERICAS Y
SERIES TEMPORALES

* SKIT LEARN:

COLECCIÓN DE ALGORITMOS Y HERRAMIENTAS
PARA MACHINE LEARNING
IMPORTANTE DONDE

#####

SKIT LEARN

#####

- MUY IMPORTANTES EN DATA SCIENCE

- FREE SOFTWARES MACHINE LEARNING

- BUSCA HOYDIA DE ALGORITMOS DE:

- CLASIFICACIÓN
- REGRESIÓN
- ASOCIACIÓN


- PREPARADO PARA TRABAJAR CON:

- NUMPY → NUMERICA
- SCIPY → CIENTIFICA

- BUENA DOCUMENTACIÓN

- FÁCIL DE IMPLEMENTAR CON:

- SKIT LEARN → CON POCAS LINEAS DE CÓDIGO



#####

SUPERVISED vs UNSUPERVISED

#####

ALGORITMOS SUPERVISADOS Y NO SUPERVISADOS


● SUPERVISAR:

→ OBSERVAR

→ DIRIGIR LA EJECUCIÓN DE UNA TAREA

→ SUPERVISAR UN MODELO DE APRENDIZAJE

AUTOMÁTICO "ML". QUE PUEDE
PRODUCIR REGIONES DE CLASIFICACIÓN
COMO LAS QUE VEMOS AQUÍ:



• ¿CÓMO SE SUPERVISA?

→ ENSEÑANDO AL MODELO

→ SE CARGA EL MODELO CON CONOCIMIENTOS PARA QUE PUEDA PREDECIR INSTANCIAS FUTURAS.

• ¿CÓMO ENSEÑAMOS A UN MODELO?

→ ENSEÑAMOS AL MODELO CON DATOS DE UN CONJUNTO DE DATOS ETIQUETADOS:

DATOS ETIQUETADOS

ATRIBUTOS

ID	CLUMP	MIT	CLASS
100025	5	1	BENIGN
1007945	5	1	BENIGN
101343	3	1	MALIGNANT
101673	6	1	BENIGN
100013	4	5	BENIGN

CARACTERÍSTICAS

CONJUNTO DE DATOS ETIQUETADOS

* EL VALOR DE LOS DATOS :

→ NUMÉRICO : 8 (CUMB)



MÁS FRECUENTES

→ CATEGÓRICO : BENIGN




- SE USA CARACTERES
- SE USA PARA LA CLASIFICACIÓN


#####

* TYPES OF SUPERVISED LEARNING *

CLASSIFICATION



REGRESSION



CLASSIFICATION:

- PROCESO DE PREDECIR UNA CLASE,
ETIQUETA O CATEGORIA DISCRETA.

DATA ETIQUETADOS

ATRIBUTOS

ID	CYLIND	MIT	CLASS
100015	5	1	BENIGN
1007945	5	1	BENIGN
101343	3	1	MALIGNANT
101673	6	1	BENIGN
100013	4	5	BENIGN

CARACTERISTICAS

CATEGORICAL
VALUES


REGRESSION:

- ES EL PROCESO DE PREDECIR UN VALOR
CONTINUO EN LUGAR DE UN VALOR CATEGORICO

	MOTOR	CYLINDERS	CO2 EMISSIONS
0	2.0	4	196
1	7.4	4	221
2	1.5	4	136
3	3.5	6	255
4	3.5	6	244
5	3.3	6	230
6	2.4	4	255
7	3.5	6	?

CONTINUOUS
VALUES

REGRESSION



#####

* NO SUPERVISADO *

- ➔ NO SUPERVISAMOS EL MODELO
- ➔ DEJAMOS QUE EL MODELO FUNCIONE POR SI SOLO PARA DESCUBRIR INFORMACIÓN QUE PUEDE NO SER VISIBLE PARA EL OJO HUMANO
- ➔ EL ALGORITMO SE ENTRENA SOBRE EL CONJUNTO DE DATOS


CUSTOMER ID	AGE	EDU	INCOME	ADDRESS	DEBT IN RPD TO
1	41	2	19	USA001	6.3
2	47	1	100	USA007	12.8
3	33	2	57	USA022	20.9


NO ESTÁN ETIQUETADOS
TODOS ESTOS DATOS

- ➔ EXTRAER CONCLUSIONES SOBRE LOS DATOS ETIQUETADOS
- ➔ TIENE ALGORITMOS MÁS DIFÍCILES QUE EL APRENDIZAJE SUPERVISADO, PORQUE CONOCEREMOS POCO O NINGUNA INFO SOBRE LAS DATAS O LOS RESULTADOS ...



REDUCCIÓN DE DIMENSIONES, LA ESTIMACIÓN DE LA DENSIDAD, ANÁLISIS DE LA CESTA DE LA COMPRA Y LA AGRUPACIÓN EN CLUSTERS SON LAS TÉCNICAS DE ML SIN SUPERVISIÓN MÁS USADAS:






CLUSTERING

- TÉCNICA MAS POPULAR
- SE USA PARA GRUPAR PUNTOS DE DATOS U OBJETOS SIMILARES



APLICACIONES

- AYUDA ORGANIZAR EN GRUPOS TIPOS DE MÚSICA
- DESCUBRIR ESTRUCTURAS
- RESUMIR
- DETECTAR ANOMALIAS



RESUMEN



● SUPERVISADO:

- SE OCUPA DE DATOS ETIQUETADOS
- ALGORITMOS ML PARA LA CLASIFICACIÓN Y LA REGRESIÓN


● NO SUPERVISADO

- DATOS NO ETIQUETADOS
- MÉTODO AGRUPACIÓN CLUSTERING
- MENOS MODELOS
- MENOS MÉTODOS DE EVALUACIÓN QUE SE PUEDAN USAR PARA GARANTIZAR QUE EL RESULTADO SEA BUENO
- CREA UN ENTORNO MENOS CONTROLABLE Y DADO QUE LA MÁQUINA GENERA RESULTADOS PARA NOSOTROS.

INTRODUCTION TO REGRESSION

	MOTOR	CYLINDERS	CO ₂ CHANGES
0	2.0	4	196
1	2.4	4	224
2	1.5	4	136
3	3.5	6	255
4	3.5	6	244
5	3.2	6	230
6	2.4	4	255
7	3.5	6	?

CO₂ CHANGES VALUES



ESTE CONJUNTO DE DATOS ESTARELACIONADO
CON LAS EMISIONES DE CO₂ DE DIFERENTES
COCHES.

- ➔ MOTOR
- ➔ CILINDROS
- ➔ CONSUMO
- ➔ EMISSIONES CO₂

¡¡ IMPORTANTE !!


¿PODEMOS PREDECIR
LA EMISIÓN DE CO₂
DE UN COCHE UTILIZANDO
OTROS CAMPOS COMO EL
TAMAÑO DEL MOTOR?

* SUPONEMOS QUE TENEMOS DATOS
HISTÓRICOS DE DIFERENTES COCHES
Y SUPONEMOS QUE EL COCHE Nº 7
AÚN NO SE HA FABRICADO.

* NECESITAMOS ESTIMAR SU EMISIÓN
APROXIMADA DE CO_2 DESPUÉS DE LA
PRODUCCIÓN

¿¿ ES POSIBLE?? ¿¿

— PODEMOS USAR MÉTODOS DE REGRESIÓN
PARA PREDECIR UN VALOR CONTINUO
UTILIZANDO OTRAS VARIABLES



X: VARIABLES INDEPENDIENTES

Y: DEPENDIENTES

	MOTOR	CYLINDERS	CO ₂ EMISSIONS
0	2.0	4	196
1	7.4	4	224
2	1.5	4	136
3	3.5	6	255
4	3.5	6	244
5	3.2	6	230
6	2.4	4	255
7	3.5	6	261

CONTINUOS
VALORES

Y → ESTADO, METO O METO FINAL QUE ESTUDIAMOS
E INTENTAMOS PREDECIR

X → VARIABLES CONOCIDAS O EXPLICATIVAS SON
LAS CAUSAS DE LOS ESTADOS

UN MODELO DE REGRESIÓN RELACIONA Y O
LA VARIABLE DEPENDIENTE CON UNA FUNCIÓN
DE X.

LA CLAVE DE LA REGRESIÓN ES QUE NUESTRO
VALOR DEPENDIENTE DEBE SER CONTINUO Y

LO PUEDE SER UN VALOR DISCRETO.

SIN EMBARGO LAS VARIABLES X O
INDEPENDIENTES SE PUEDEN MEDIR EN
UNA ESCALA DE MEDICIÓN CATEGÓRICA O CONTINUA

TIPOS DE MODELOS DE REGRESIÓN

● REGRESIÓN SIMPLE:

- SE USA UNA VARIABLE INDEPENDIENTE PARA ESTIMAR UNA VARIABLE DEPENDIENTE
- PUEDE SER LINEAL O NO
- EJ: PREDECIR CO_2 UTILIZANDO LA VARIABLE MOTOS
- LA LINEALIDAD DE REGRESIÓN SE BASA EN LA NATURALEZA DE LA RELACIÓN

● REGRESIÓN MÚLTIPLE:

- MÁS DE UNA VARIABLE INDEPENDIENTE
- PUEDE SER LINEAL O NO

APLICACIONES DE REGRESIÓN

- PREVISIÓN DE VENTAS
- ANÁLISIS DE SATISFACCIÓN
- PREDECIR PRECIOS
- INGRESOS DE LOS VENDEDORES
- FINANZAS
- ATENCIÓN MÉDICA
- ETC.

REGRESION LINEAL SIMPLE

	MOTOR	CILINDROS	CONSUMO	CO ₂
0	2.0	4	8.5	196
1	2.4	4	9.6	221
2	1.5	4	5.9	136
3	3.5	6	11.1	255
4	3.5	6	10.6	244
5	3.7	6	10.1	230
6	2.4	4	9.2	? 

• PODEMOS USAR LA REGRESION LINEAL PARA PREDICAR UN VALOR CONTINUO

• VARIABLE DEPENDIENTE

• VARIABLES INDEPENDIENTES

ESCA APROXIMACION DE UN MODELO LINEAL QUE SE USA PARA DESCRIBIR LA RELACION ENTRE DOS O MAS VARIABLES.

#####

¡¡ IMPORTANTE !!


¿PODEMOS PREDICAR LA EMISION DE CO₂ DE UN COCHE UTILIZANDO OTRAS CAMPOS COMO EL TAMAÑO DEL MOTOR?


POR SUPUESTO
QUE SI


#####

¿CÓMO FUNCIONA?

	MOTOR	CILINDROS	CONSUMO	CO ₂
0	2.0	4	8.5	196
1	2.4	4	9.6	221
2	1.5	4	5.9	136
3	3.5	6	11.1	255
4	3.5	6	10.6	244
5	3.7	6	10.1	230
6	2.4	4	9.2	?



① EL DIAGRAMA DE DISPERSIÓN MUESTRA QUE SE TRATA DE UNA REGRESIÓN LINEAL



* PUEDE BUSCAR UNA LÍNEA A TRAVÉS DE LOS DATOS

X EJEMPLO: A MEDIDA QUE AUMENTA EL TAMAÑO DEL MOTOR, AUMENTA CO₂

② USANDO LA LÍNEA DE ANTES PODRÍAMOS VER QUE UN MOTOR 2.4 → EMITE 221 CO₂.


Y PODRÍAMOS PREDECIR CUANTO EMITE NUESTRO VEHÍCULO N° 6

MODELO DE REPRESENTACION

• HAY QUE PREDECIR EL VALOR Y

• USAMOS LA VARIABLE INDEPENDIENTE DE LOS CILINDROS X_1

DIAGRAMA DE DISPERSION



• LA LINEA DE AJUSTE SE MUESTRA TRADICIONALMENTE COMO UN POLINOMIO

$$\hat{Y} = \theta_0 + \theta_1 X_1$$

$\hat{Y}$ → VARIABLE DEPENDIENTE

X_1 → VARIABLE INDEPENDIENTE / SINGLE PREDICTOR

$\theta_0 + \theta_1$ → PARAMETROS DE LA LINEA QUE DEBEMOS DARLE

PROBLEMA DE REGRESION SIMPLE CON UNA SOLA X

→ PENDIENTE DE LA RECTA

→ INTERSECCION

} COEFICIENTE DE LA LINEA DE AJUSTE

$$\hat{y} = \theta_0 + \theta_1 x_1$$

* ESTA ECUACION:

- $\hat{y}$ ES UNA FUNCION DE x_1
- $\hat{y}$ ES DEPENDIENTE DE x_1

RESOLVER

#####


¿CÓMO DIBUJAR UNA LINEA QUE
ADIVINSE LOS PUNTOS?

¿CÓMO SE DETERMINA QUE LINEA SE
AJUSTA MEJOR?

#####

- CALCULAR θ_0 y θ_1 PARA ENCONTRAR
LA LINEA QUE MEJOR SE AJUSTE A
NUESTROS DATOS.

CONTINUE



HOW to find the best fit?

● SUPONEMOS QUE HEMOS ENCONTRADO LA LINEA QUE MEJOR SE AJUSTA A NUESTROS DATOS


$$\hat{y} = \theta_0 + \theta_1 x_1$$

$$x_1 = 5.4$$

$$y = 250$$

y

DIAGRAMA DE DISPERSION



x

$x_1 = 5.4 \rightarrow$ VARIABLE INDEPENDIENTE

$y = 250 \rightarrow$ EMISIONES CO₂ DE x_1

● SI TENEMOS UN MOTOR x_1 Y UN CO₂ = 250
SU CO₂ DEBERIA PREDECIRSE MUY CERCA
DEL VALOR BELC* SEGUN LOS DATOS HISTORICOS

* VEHICULO NUEVO

DIAGRAMA DE DISPERSION


$$X_1 = 5.4$$

$$Y = 250$$

Y

$$\hat{Y} = \theta_0 + \theta_1 X_1$$

$$\hat{Y} = 340 \rightarrow \text{PREDICCIÓN EMISIONES } X_1$$



X

$$\begin{aligned} \text{ERROR} &= Y - \hat{Y} \\ &= 250 - 340 \\ &= -90 \end{aligned}$$

ERROR RESIDUAL


ERROR

• SI USAMOS LA LINEA DE AJUSTE (POLINOMIO) CON PARAMETROS CONOCIDOS PODR PREDICIR LAS EMISIONES DE CO₂. EL RESULTADO SERIA:
 $\hat{Y} = 340$

• SI COMPARAMOS EL VALOR REAL CON LA PREDICCIÓN VEMOS QUE HAY UN ERROR DE 90 UNIDADES


• NUESTRA LINEA DE PREDICCIÓN NO ES PRECISA

DIAGRAMA DE DISPERSION




IMPORTANTE:

- ERROR RESIDUAL: ES LA DISTANCIA DESDE EL PUNTO DE DATOS HASTA LA LINEA DE REGRESION AJUSTADA ($\hat{y} = 340$)



LA MEDIDA DE TODOS LOS ERRORES RESIDUALES MUESTRA QUÉ TAN MAL ENCAJA LA LÍNEA CON TODO EL CONJUNTO DE DATOS

DIAGRAMA DE DISPERSION



$$x_1 = 5.4$$

$$y = 250$$

y

$$\hat{y} = \theta_0 + \theta_1 x_1$$

$$\hat{y} = 340 \rightarrow \text{PREDICCIÓN EMISIONES } x_1$$

$$\begin{aligned} \text{ERROR} &= y - \hat{y} \\ &= 250 - 340 \\ &= -90 \end{aligned}$$

$$MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

EQUACIÓN:
ERROR CUADRÁTICO
MEDIO

- MATEMÁTICAMENTE CON LA ECUACIÓN ERROR CUADRÁTICO MEDIO (MSE).

* NUESTRO OBJETIVO ES ENCONTRAR UNA REGIÓN EN LA QUE SE MINIMICE LA MEDIA DE TODOS LOS ERRORES.

* DEBEMOS MINIMIZAR EL ERROR MEDIO DE LA PREDICCIÓN UTILIZANDO LA LUGAR DE DATOS.

REAJUSTE:

* EL OBJETIVO DE LA REGRESIÓN LINEAL ES MINIMIZAR ESTA ECUACIÓN MSE, PARA ESO DEBEMOS ENCONTRAR LOS MEJORES PARÁMETROS θ_0 Y θ_1

¿CÓMO ENCONTRAMOS θ_0 Y θ_1 ?

¿CÓMO ENCONTRAR LA PERFECT LINE?

*NO PODEMOS MOVER LA LINEA
DEAR.

- 2 ENFOQUES:

• ENFOQUE MATEMÁTICO

• ENFOQUE DE OPTIMIZACIÓN

ESTIMANDO PARÁMETROS

	MOTOR	CILINDROS	COLUMA	CO ₂
0	2.0	4	8.5	196
1	2.4	4	9.6	221
2	1.5	4	5.9	136
3	3.5	6	11.1	255
4	3.5	6	10.6	244
5	3.7	6	10.1	230
6	2.4	4	9.2	221

$$\hat{y} = \theta_0 + \theta_1 x_1$$

* CALCULAR LA MEDIA DE LAS
COLUMNAS INDEPENDIENTES Y
DEPENDIENTES. O OBJETIVO DEL
CONJUNTO DE DATOS

* SE PUEDE DEMOSTRAR QUE LA INTERSECCION
Y LA PENDIENTE SE PUEDEN CALCULAR
CON ESTAS ECUACIONES

$$\hat{y} = \theta_0 + \theta_1 x_1$$

$$\theta_1 = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2}$$

VALOR MEDIO
TAMAJOS MOTOR

$$\bar{x} = (2.0 + 2.4 + 1.5 + \dots) / 9 = 3.03$$

VALOR MEDIO
EMISSIONES

$$\bar{y} = (196 + 221 + 136 + \dots) / 9 = 226.22$$

$$\theta_1 = \frac{(2.0 - 3.03)(196 - 226.22) + (2.4 - 3.03)(221 - 226.22) + \dots}{(2.0 - 3.03)^2 + (2.4 - 3.03)^2 + \dots}$$

$$\theta_1 = 39$$

$$\theta_0 = \bar{y} - \theta_1 \bar{x}$$

$$\theta_0 = 226.22 - 39 * 3.03$$

$$\theta_0 = 125.74$$

• AHORA PODAMOS ESCRIBIR EL POLINOMIO DE LA UNIDA:

#####

$$\hat{Y} = 125.74 + 39 \times x_1$$

#####

• UNDA US7 QUE HAYAS ENCONTRADO LOS DATOS DE LA ECUACION UNIDA

• PODAMOS RESOLVER LA ECUACION PARA PREDICAR LAS EMISIONES DEL DUTO NUEVO

	MOTOR	Unidades	Consumo	CO ₂
0	2.0	4	8.5	196
1	2.4	4	9.6	221
2	1.5	4	5.9	136
3	3.5	6	11.1	255
4	3.5	6	10.6	244
5	3.7	6	10.1	230
6	2.4	4	9.2	?

$$\hat{Y} = \theta_0 + \theta_1 x_1$$

$$CO_2 = \theta_0 + \theta_1 \text{ Motor} \leftarrow$$

$$CO_2 = 125 + 39 \text{ Motor} \leftarrow$$

$$CO_2 = 125 + 39 \times 2.4$$

$$CO_2 = 218.6$$


?

PROS REGRESIÓN LINEAL

(LINEAS DE REGRESION)

- MUY RÁPIDA
- NO HAY QUE JUSTIFICAR
PUNTOS
- FÁCIL DE ENTENDER
- MUY INTERPRETABLES

DIAGRAMA DE DISPERSIÓN



#####

EVALUACIÓN DEL MODELO

EN MODELOS DE REGRESIÓN

#####

* EL OBJETIVO DE LA REGRESIÓN

ES CONSTRUIR UN MODELO PARA
PREDECIR CON PRECISIÓN UN
CASO DESCONOCIDO.

* DEBEMOS REALIZAR UNA EVALUACIÓN
DE REGRESIÓN DESPUÉS DE
CONSTRUIR EL MODELO

* HAY DOS ENFOQUES DE
EVALUACIÓN. *

≡ ENTRENAR Y PROBAR (TEST) ≡

≡ DIVISIÓN ENTRE TRAIN Y TEST ≡

* HAY ALGUNAS MÉTRICAS
PARA DETERMINAR LA PRECISIÓN
DE LOS MODELOS DE REGRESIÓN


¿EL MEJOR ENFOQUE PARA
OBTENER RESULTADOS MAS
PRECISOS?

¿Podemos calcular la precisión de nuestro
modelo?

1^{er} ENFOQUE:

- SELECCIONAR UNA PARTE DE NUESTRO
CONJUNTO DE DATOS PARA PROBLEMA
- CONSTRUIR UN MODELO CON ESTE
CONJUNTO DE DATOS (TRAIN)
- SELECCIONAMOS UNA PEQUEÑA PARTE DEL
CONJUNTO DE DATOS (TEST)

* CONJUNTO DE PRUEBA *



	MOTOR	CILINDROS	CONSUMO	CO ₂
--	-------	-----------	---------	-----------------

0	2.0	4	8.5	196
1	2.4	4	9.6	221
2	1.5	4	5.9	136

3	3.5	6	11.1
4	3.5	6	10.6
5	3.7	6	10.1
6	2.4	4	9.2

TEST

255
244
230
221

TRAIN

ACTUAL
VALUES

- COMPARAMOS LOS VALORES REALES
DEL CONJUNTO DE PRUEBA CON
NUESTRO MODELO

ACTUAL
VALUES VS
PREDICTED
VALUES

PREDICTION
3 239
4 244
5 230
6 218.6

PREDICTED
VALUES

$$ERROR = \frac{1}{n} \sum_{j=1}^n |y_j - \hat{y}_j|$$

	MOTOR	CIANIDROS	CONSUMO	CO ₂		PREDICION
0	2.0	4	8.5	196		
1	2.4	4	9.6	221		3 234
2	1.5	4	5.9	136		4 244
3	3.5	6	11.1	255		5 230
4	3.5	6	10.6	244		6 218.6
5	3.7	6	10.1	230		
6	2.4	4	9.2	221		

TEST

$\hat{y}$
 y

$$ERROR = \frac{1}{n} \sum_{j=1}^n |y_j - \hat{y}_j|$$

$$ERROR = \frac{(234 - 255) + (244 - 244) + \dots}{4}$$

1er ENFOQUE:

- ENTRENAR Y PROBAR EN EL MISMO CONJUNTO DE DATOS
- ENTRENAR EL MODELO EN TODO EL CONJUNTO DE DATOS Y LO PRUEBA CON UNA PARTE DEL MISMO CONJUNTO DE DATOS.
- SE PUEDE OBTENER UN REPRESENTANTE DE PREDICCIONES PRECISAS DADO EL MODELO
- ALTA PRECISION DE ENTRENAMIENTO
- BAJA PRECISION FUERA DE LA MUESTRA

— PRECISIÓN DEL ENTRENAMIENTO

- PORCENTAJE DE PREDICCIONES CORRECTAS AL USAR EL CONJUNTO DE DATOS DE PRUEBA
- UNA ALTA PRECISIÓN NO ES NECESARIAMENTE ALGO BUENO.

ESTO PUEDE PROVOCAR UN SOBREENCAJTE DE LOS DATOS:

- ↳ ESTA DEMASIADO ADAPTADO A LOS DATOS
- ↳ PUEDES CAPTURAR EL RUIDO Y PRODUCIR UN MODELO GENERALIZADO

— PRECISIÓN FUERA DE LA MUESTRA

- PORCENTAJE DE PREDICCIONES CORRECTAS QUE EL MODELO HACE SOBRE DATOS CON LOS QUE NO SE HA ENTRENADO.
- AL REDUCIR UN TRAIN Y UN TEST EN EL MISMO CONJUNTO DE DATOS, ES POSIBLE QUE LA PRECISIÓN SE REDUZCA DEBIDO A LA BAJA PROBABILIDAD DE UN SOBREENCAJTE

¡¡ IMPORTANTE !!

DATA PRECISIÓN FUERA DE
LA MUESTRA.
EL PROPOSITO DEL MODELO ES
HACER PREDECIONES CORRECTAS
A PARTIR DE DATOS
DESCONOCIDOS.

¿CÓMO PODEMOS

MEJORAR LA PRECISIÓN

FUERA DE LA MUESTRA???



USANDO EL 2º ENFOQUE:


≡ DIVISIÓN ENTRE TRAIN Y TEST ≡
* TRAIN / TEST SPLIT *

	MOTOR	CILINDROS	CONSUMO	CO ₂
0	2.0	4	9.5	196
1	2.4	4	9.6	221
2	1.5	4	5.9	136
3	3.5	6	11.1	255
4	3.5	6	10.6	244
5	3.7	6	10.1	230
6	2.4	4	9.2	221

TRAIN



1. SELECCIONAMOS UNA PARTE DE NUESTRO CONJUNTO DE DATOS
2. Y EL RESTO SE USA PARA LAS PRUEBAS
3. SE PASA AL MODELO PARA SU PREDICCIÓN
4. LOS VALORES PRONOSTICADOS SE COMPARAN CON LOS VALORES REALES.



● TRAIN / TEST SPLIT:

- IMPLICA DIVIDIR EL CONJUNTO DE DATOS PARA QUE EXCLUYAN MUTUAMENTE
 - DESPUÉS ENTRENAS CON EL CONJUNTO DE ENTRENAMIENTO Y HACES PRUEBAS CON EL CONJUNTO DE PRUEBAS.
 - EVALUACIÓN MÁS PRECISA DE LA PRECISIÓN FUERA DE LA MUESTRA. EL CONJUNTO DE DATOS NO FORMA PARTE DEL QUE SE USÓ PARA ENTRENAR DATOS
 - ES MÁS REALISTA PARA LOS PROBLEMAS DEL MUNDO REAL.
 - EL MODELO NO CONOCE EL RESULTADO DE ESTOS PUNTOS DE DATOS
 - DESPUÉS DE ENTRENAR EL MODELO CON EL CONJUNTO DE TEST POSTERIORMENTE.
- 

EL PROBLEMA DEL TRAIN/TEST SPLIT:
DEPENDIENDO EN GRAN MEDIDA DE LOS
CONJUNTOS DE DATOS EN LOS QUE
SE ENTRENAN Y PROBAMOS.

#####

* HAY OTRO MODELO DE EVALUACIÓN
CUANDO:

VALIDACIÓN CRUZADA DE
PLIEGUES K

#####

➡ RESUELVE LA MAYORÍA DE ESTOS
PROBLEMAS.


¿CÓMO SE USA?



HOW TO USE K-FOLD CROSS-VALIDATION

¿CÓMO SE CORRIÓ UNA DEPENDENCIA
NO QUE RESULTA DE UNA DEPENDENCIA?

- SE PROMEDIO



1. SI TENEMOS K IGUAL A CUATRO VECES
2. DIVIDIMOS EL CONJUNTO DE DATOS COMO SE MUESTRA ARRIBA.
3. USAMOS EL PRIMER 25% PARA TEST Y EL RESTO PARA TRAIN.
4. EL MODELO SE CREA CON TRAIN Y SE EVALUA CON TEST
5. EN LA SIGUIENTE RONDA O DESPLIEGUE USAMOS EL SEGUNDO 25% ... ETC

6. POR ÚLTIMO:

-SE PROMEDIA EL RESULTADO DE LAS
CUATRO EVALUACIONES

*
* PRECISION = AVG (80% + 84% + 82% + 86%) = 83%
* (ACCURACY)
*

LA VALIDACIÓN CRUZADA DE PLIEGUE K:

- => FORMA MÁS SIMPLE
- => MÚLTIPLES DIVISIONES ENTRE TEST Y TRAIN
- => UTILIZA EL MISMO CONJUNTO DE DATOS
- => CADA DIVISION ES DIFERENTE
- => EL RESULTADO SE PROMEDIA PARA OBTENER
UNA PRECISION MÁS UNIFORME FUERA DE
LA MUESTRA

* CURSO VALIDACIÓN
CRUZADA DE K PLIEGUES *

#####

MÉTRICAS DE EVALUACIÓN EN MODELOS DE REGRESIÓN

#####

LAS MÉTRICAS DE EVALUACIÓN SE
USAN PARA EXPLICAR EL RENDIMIENTO
DE UN MODELO:

	HOTOR	CUBIENOS	CONSERVO	CO ₂	
0	2.0	4	8.5	196	
1	2.4	4	9.6	221	
2	1.5	4	5.9	136	
3	3.5	6	11.1	255	
4	3.5	6	10.6	244	
5	3.7	6	10.1	230	
6	2.4	4	9.2	221	

$\hat{y}$

PREDICTION
3 234
4 244
5 230
6 219.6

$$\text{ERROR} = \frac{1}{n} \sum_{j=1}^n |y_j - \hat{y}_j|$$

$$\text{ERROR} = \frac{(234 - 255) + (244 - 244) + \dots}{4}$$

-PODEMOS COMPARAR LOS VALORES REALES Y LOS VALORES PREDICTADOS PARA CALCULAR LA PRECISIÓN DE NUESTRO MODELO DE REGRESIÓN.

● LAS MÉTRICAS PROPORCIONAN INFORMACIÓN SOBRE LAS ÁREAS QUE REQUIEREN MENOR

$$\text{ERROR} = \frac{(234 - 255) + (244 - 244) + \dots}{4}$$

$$\text{ERROR} = \frac{1}{n} \sum_{j=1}^n |y_j - \hat{y}_j|$$

	MOTOR	CILINDROS	CORSO	CO ₂
0	2.0	4	8.5	196
1	2.4	4	9.6	221
2	1.5	4	5.9	136
3	3.5	6	11.1	255
4	3.5	6	10.6	244
5	3.7	6	10.1	230
6	7.4	4	9.2	221

test

Y



- MAE
- MSE
- RMSE
- ...

$\hat{y}$

	Prediction
3	254
4	244
5	230
6	218.6




- MAE : ERROR ABSOLUTO MEDIO
- MSE : ERROR CUADRÁTICO MEDIO
- RMSE : RÍZ ERROR CUADRÁTICO MEDIO


¿QUÉ ES UN ERROR DE MODELO?

- EN UNA REGRESIÓN EL ERROR DEL MODELO ES LA DIFERENCIA ENTRE LOS PUNTOS DE DATOS Y LA LÍNEA DE TENDENCIA GENERADA POR EL ALGORITMO.

FULL DATA



COMO HAY VARIOS PUNTOS DE DATOS
UN ERROR SE PUEDE DETERMINAR DE
VARIAS MANERAS:



$$MAE = \frac{1}{n} \sum_{j=1}^n |y_i - \hat{y}_j|$$

$$MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$$

$$RAE = \frac{\sum_{j=1}^n |y_i - \hat{y}_j|}{\sum_{j=1}^n |y_i - \bar{y}|}$$

$$R^2 = 1 - RSE \quad \leftarrow \quad RSE = \frac{\sum_{j=1}^n (y_i - \hat{y}_j)^2}{\sum_{j=1}^n (y_i - \bar{y})^2}$$

✱ MAE: ERROR ABSOLUTO MEDIO:

- ES LA MEDIDA DEL VALOR ABSOLUTO DE LOS ERRORES
- LA MAS FACIL DE ENTENDER
- ES SOLO EL ERROR PROMEDIO.

✱ MSE: ERROR CUADRÁTICO MEDIO:

- ES MÁS PORICAR QUE EL MAE PORQUE SE CENTRA MAS EN LOS ERRORES GRANDES
- QUE DIFERENTIAR EXPOENCIALMENTE LOS ERRORES MAS GRANDES EN COMPARACIÓN CON LOS + PEQUEÑOS

* RMSE: RAÍZ DEL ERROR CUADRÁTICO MEDIO

- LA RAÍZ CUADRADA DE MSE
- DE LAS MÁS POPULARES PORQUE EL MSE SE PUEDE INTERPRETAR EN LAS MISMAS UNIDADES QUE EL VECTOR DE RESPUESTA O LAS UNIDADES Y .

• FACILITA LA RELACIÓN DE SU INFORMACIÓN

* RDE: ERROR ABSOLUTO RELATIVO.

- MIDE LA MAE ENTRE LOS VALORES REALES Y LOS PREDICHOS EN RELACIÓN CON LA DIFERENCIA MAE ENTRE VALORES REALES Y MEDIA

* RSS: SUMA CUADRADOS RESIDUALES

$$RSS = \sum (Real - predicho)^2$$

* RSE: ERROR CUADRÁTICO RELATIVO

- ES MUY PARECIDO A RAE PERO LA COMUNIDAD DE CIENCIA DE DATOS LO HA ADOPTADO AMPLIAMENTE.
- SE UTILIZA PARA CALCULAR EL R^2 CUADRADO.

* R^2 : NO ES UN ERROR POR SI SOLO.

- ES UNA MÉTRICA POPULAR PARA MEDIR LA PRECISIÓN DE UN MODELO.

- REPRESENTA QUE TAN CERCA ESTÁN LOS VALORES DE LOS DATOS DE LA LÍNEA DE REGRESIÓN AJUSTADA.

- CUANTO MÁS ALTO SEA EL CUADRADO R^2 , MÁS CERCA SE AJUSTARÁ EL MODELO A LOS DATOS.

CADA UNA DE ESTAS MÉTRICAS SE PUEDE UTILIZAR PARA CANTIFICAR LA PRECISIÓN.

LA ELECCIÓN DE LA MÉTRICA DEPENDE COMPLEMENTAMENTE:

- TIPO DE MODELO
- TIPO DE DATOS
- DOMINIO DEL CONOCIMIENTO

* CURSO MÉTRICAS
EVALUACIÓN MODELOS DE
REGRESIÓN *

#####

LABORATORIO

#####

* REGRESIÓN LINEAL SIMPLE *

ESTUDAR EN VIDEO => LABORATORIO 1

#####

REGRESIÓN LINEAL MÚLTIPLE

#####

EN LA REGRESIÓN LINEAL SIMPLE
HEMOS VISTO QUE SE USA UNA VARIABLE
INDEPENDIENTE PARA PREDECIR UNA
VARIABLE DEPENDIENTE:

EJEMPLO:

- PREDECIR LAS EMISIONES DE CO₂
CON LA VARIABLE DEL TAMAÑO DEL
MOTOR

=> PERO EN REALIDAD HAY MÚLTIPLES
VARIABLES QUE PREDECEN LAS EMISIONES
DE CO₂.

=> CUANDO HAY VARIAS VARIABLES INDEPENDIENTES
SE DENOMINA REGRESIÓN LINEAL MÚLTIPLE

=> POR EJEMPLO:

-USANDO EL TAMAÑO DEL MOTOR
Y EN NÚMERO DE CILINDROS

● LA REGRESIÓN LINEAL MÚLTIPLE ES
LA EXTENSIÓN DE LA REGRESIÓN LINEAL
SIMPLE ●

IMPORTANTE

APLICACIONES DE LA REGRESIÓN LINEAL MÚLTIPLE

①

● IDENTIFICAR LA FUERZA DEL EFECTO QUE
TIENEN LAS VARIABLES INDEPENDIENTES
SOBRE LAS VARIABLES DEPENDIENTE

=> POR EJEMPLO: EFECTO RENDIMIENTO EXÁMENES

- TIEMPO DE REVISIÓN
- DIVERSIDAD SOBRE LOS EXÁMENES
- LA DISTANCIA A CLASE
- GÉNERO

②

• PREDICIR EL IMPACTO DE LOS CAMBIOS:

- POR ENTENDER COMO CAMBIA LA VARIABLE DEPENDIENTE AL CAMBIAR LAS VARIABLES INDEPENDIENTES

=> POR EJEMPLO: REVISAR LOS DATOS DE SALUD DE UNA PERSONA .

- CUANDO SE OBTIENE LA PÉRDIDA DE PESO DE UNA PERSONA POR CADA UNIDAD DE DIFERENTE OPTIMIZACIÓN DEL ÍNDICE DE MASA CORPORAL DEL PACIENTE MANTENIENDO CONSTANTES OTROS FACTORES

¿CÓMO FUNCIONA?

- AL IGUAL QUE EN CASO SIMPLE LA REGRESIÓN LINEAL MÚLTIPLE ES UN MÉTODO DE PREDICCIÓN DE UNA VARIABLE CONTINUA
- UTILIZA MÚLTIPLES VARIABLES
(VARIABLES INDEPENDIENTES O PREDICTORES)
- PREDICEN HASTA LA VARIABLE DEPENDIENTE
(VARIABLE OBJETIVO)

¿CO₂?

X: VARIABLES INDEPENDIENTES

Y: DEPENDIENTE

	X: VARIABLES INDEPENDIENTES			Y: DEPENDIENTE
	MOTOR	CILINDROS	CONSUMO	CO ₂
0	2.0	4	8.5	196
1	2.4	4	9.6	221
2	1.5	4	5.9	136
3	3.5	6	11.1	255
4	3.5	6	10.6	244
5	3.7	6	10.1	230
6	2.4	4	9.2	221
7	2.7	6	11.1	255
8	3.7	6	11.6	267
9	2.4	4	9.2	212

$$CO_2 Em = \theta_0 + \theta_1 Motor + \theta_2 Cylindros + \dots$$

* PERMITE SABER QUE VARIABLES SON PREDICANTES SIGNIFICATIVAS DE LA VARIABLE DE RESULTADO.

* PUEDE INVESTIGAR COMO AFECTA CADA CARACTERÍSTICA A LA VARIABLE DE RESULTADO

ECUACIÓN DE REGRESIÓN

$$\hat{y} = \theta_0 + \theta_1 x_1 + \theta_2 x_2 + \dots + \theta_n x_n$$

VECTORIALEMENTE:

$$\hat{y} = \theta^T X$$

$$\theta^T = [\theta_0, \theta_1, \theta_2, \dots] \text{ (VECTOR DE COEFICIENTES)}$$

PARÁMETRO / VECTOR DE PESO

$$X = \begin{bmatrix} 1 \\ x_1 \\ x_2 \\ x_3 \\ \dots \end{bmatrix}$$

→ CALCULO DE CARACTERÍSTICAS
QUE REPRESENTA EL AUTOMÓVIL

→ x_1 - MOTOR

x_2 - CILINDROS

x_3 - ETC.

$X = \begin{bmatrix} 1 \\ x_1 \\ x_2 \\ x_3 \\ \dots \end{bmatrix}$ • EL PRIMER ELEMENTO DEL VECTOR DE CARACTERÍSTICAS SE ESTABLECE EN 1.

IMPORTANTE:

- COEFICIENTE Θ_0 EN EL PARÁMETRO DE INTERSECCIÓN O SESGO
- CUANDO EL VECTOR SE MULTIPLICA POR EL VECTOR DEL PARÁMETRO

• LA TRANSPOSICIÓN $\Theta^T X$ EN UN ESPACIO UNIDIMENSIONAL ES LA ECUACIÓN DE UNA LÍNEA:

REGRESIÓN LINEAL SIMPLE

• CUANDO TENEMOS MÁS DE UNA ENTRADA LA LÍNEA SE LLAMA: PLANO / HIPERPLANO

REGRESIÓN LINEAL MÚLTIPLE

• DEBEMOS ENCONTRAR EL HIPERPLANO QUE MEJOR SE ADAPTA A NUESTROS DATOS.

USANDO MSE PARA ENCONTRAR LOS ERRORES EN EL MODELO

$$\hat{y} = \Theta^T X$$

• CUANDO CONOCAMOS Θ^T YA
PODEMOS USAR EL MODELO Y EL CONJUNTO
DE CARACTERÍSTICAS DE CADA 1ª FILA

$$\hat{y} = 140 \rightarrow \text{PREDICCIÓN } CO_2 \text{ } X_i$$

$$y_i = 196 \rightarrow \text{VALOR REAL}$$

$$y_i - \hat{y} = 56 \rightarrow \text{ERROR RESIDUAL}$$

EL ERROR PARA UNA SGA LINEAL
COMO EN LA REGRESIÓN LINEAL SIMPLE

$$MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

→ ESTA MEDIDA
REPRESENTA

QUE TAN MAL REPRESENTA EL MODELO EL CONJUNTO
DE DATOS =

• EL OBJETIVO ES MINIMIZAR MSE •

¿CÓMO ESTIMAMOS θ ?

①

→ MÍNIMOS CUADRADOS ORDINARIOS →

⇒ INTENTAN ESTIMAR LOS VALORES DE LOS COEFICIENTES MINIMIZANDO EL ERROR CUADRÁTICO MEDIO: MSE

→ UTILIZAN LOS DATOS COMO UNA MATRIZ

→ - OPERACIONES DE ALGEBRA LINEAL

- EL PROBLEMA: COMPLEJIDAD TEMPORAL DE CÁLCULO DE LAS OPERACIONES MATRICIALES, PUEDE LLEVAR MUCHO TIEMPO.

→ CUANDO EL CONJUNTO DE DATOS ES SUPERIOR A 10.000 ESTA TÉCNICA ES UNA BUENA OPCIÓN.

②

→ ALGORITMO DE OPTIMIZACIÓN →

⇒ GRADIENTES DESCENDIENTES

→ ES ADECUADO CONJUNTO DE DATOS DE 10.000 +.

③ FASE DE PREDICCIÓN.

- ES TAN SENCILLO COMO RESOLVER LA ECUACION PARA UN CANTIDAD ESPECÍFICA DE ENTRADAS.

* PREDICCIÓNES CON LÍNEAS MÚLTIPLES.

	MOTOR	Ciudades	Consumo	CO ₂
0	2.0	4	8.5	196
1	2.4	4	9.6	221
2	1.5	4	5.9	136
3	3.5	6	11.1	255
4	3.5	6	10.6	244
5	3.7	6	10.1	230
6	2.4	4	9.2	211
7	3.7	6	11.1	255
8	3.7	6	11.6	267
9	2.4	4	9.2	?

$$\hat{y} = \theta^T X$$

$$\theta^T = [125, 6.2, 14, \dots]$$

$$\hat{y} = 125 + 6.2x_1 + 14x_2 + \dots$$

$$CO_2Em = 125 + 6.2 \text{ motor} + 14 \text{ ciudades} \dots$$

$$CO_2Em = 125 + 6.2 \times 2.4 + 14 \times 4 + \dots$$

- PREDICCIÓN
- CÁLCULO
- RESULTADO

$$CO_2Em = 125 + 6.2 \times 2.4 + 14 \times 4 \dots \text{etc}$$

$$CO_2Em = 214.1$$

PREGUNTAS SOBRE:

REGRESIÓN LINEAL MÚLTIPLE

• PODEMOS USAR MÚLTIPLES VARIABLES INDEPENDIENTES PARA PREDECIR LA VARIABLE DEPENDIENTE:

- UNO DE LOS RESULTADOS DE ESTOS MODELOS ES MEJOR QUE LA REGRESIÓN SIMPLE

• ¿CUANTAS VARIABLES DEBEMOS DE USAR PARA LA PREDICCIÓN?

- USAR VARIABLES SIN JUSTIFICACIÓN PUEDE RESULTAR UN MODELO SOBREADJUSTADO

• UN MODELO SOBREADJUSTADO ES UN VERDADERO PROBLEMA PORQUE ES DEMASIADO COMPLICADO PARA EL CONJUNTO DE DATOS Y NO ES LO SUFICIENTEMENTE GENERAL PARA UNA BUENA PREDICCIÓN.

• ES RECOMENDABLES EVITAR USAR MUCHAS VARIABLES

• SE PUEDEN UTILIZAR GRÁFICOS DE DISPERSIÓN PARA COMPROBAR VISUALMENTE LA LINEALIDAD.

• SI NO ES LINEAL, HAY QUE USAR REGRESIÓN NO LINEAL.

#####

LABORATORIO

#####

* REGRESIÓN LINEAL MÚLTIPLE *

ESTUDAR EN VÍDEO => LABORATORIO 2

#####

MÓDULO 3

INTRODUCCIÓN

CLASIFICACIÓN

#####

- ES UN ENFOQUE DE APRENDIZAJE SUPERVISADO
- MEDIO PARA CATEGORIZAR O CLASIFICAR ALGUNOS ELEMENTOS DE CONOCIMIENTO EN UN CONJUNTO DISCRETO DE CLASES
- INTENTA CONOCER LA RELACIÓN ENTRE LAS VARIABLES CARACTERÍSTICAS Y LAS VARIABLES OBJETIVO DE INTERÉS.

DEL DISTRIBUTO OBJETIVO DE LA CLASIFICACIÓN ES:

VARIABLES CATEGÓRICAS CON VALORES DISCRETOS

¿CÓMO FUNCIONA LA CLASIFICACIÓN Y LOS CLASIFICADORES?

AGE	ED	EMPL	ADDRESS	INCOME	DEBT	CREDIT	OTHER	DEFAULT
41	3	17	12	176	9.3	14.359	5.009	1
27	1	10	6	31	17.3	1362	4.001	0
40	1	15	14	55	5.5	0.836	2.169	0
42	1	15	14	120	2.9	7.659	0.821	0
24	2	2	0	28	17.3	1.787	3.057	1
41	2	5	5	25	10.2	0.398	2.557	0
39	1	20	9	67	30.6	3.834	16.668	0
43	1	12	11	38	3.6	0.779	1.239	0
24	1	3	4	19	24.4	1.358	3.277	1
36	1	0	13	25	19.7	2.778	2.147	0
37	2	16	10	130	9.3	10.23	3.21	

* PREDICCIÓN IMPAGO CREDITO *

(DATOS DE MOROSIDAD)

VARIABLE CATEGORICA

AGE	ED	EMLOY	ADDRESS	HOME	DEBIT	CREDIT	OTHER	DEFER
41	3	17	12	176	9.3	11.359	5.009	1
27	1	10	6	31	17.3	1.362	4.001	0
40	1	15	14	55	5.5	0.836	2.169	0
41	1	15	14	120	2.9	2.659	0.821	0
24	2	2	0	28	17.3	1.387	3.057	1
41	2	5	5	25	10.2	0.538	2.47	0
39	1	20	9	67	30.6	3.834	1.668	0
43	1	12	11	38	3.6	0.479	1.239	0
24	1	3	4	19	24.4	1.358	3.279	1
36	1	0	13	25	19.7	2.778	2.147	0

37	2	16	10	130	9.3	10.33	3.21	
----	---	----	----	-----	-----	-------	------	--



DADO UN CONJUNTO DE DATOS DE ENTRENAMIENTO EN EL CUAL LAS ETIQUETAS DE DESTINO, LA CLASIFICACIÓN DETERMINA LA ETIQUETA DE CLASE PARA UN CASO DE PRUEBA EN EL QUE SE QUIERE ESTIMAR.


* EJEMPLO *

- UN BUEN EJEMPLO ES LA PREDICCIÓN DE UN IMPAGO CREDITICIO:
- NOS PREOCUPA LA POSIBILIDAD DE QUE UN PRÉSTAMO NO SE REEMBOLE.
- SI LOS DATOS DE MOROSIDAD CREDITICIA SE PUEDEN UTILIZAR PARA PREDECIR QUE CLIENTES TIENEN PROBABILIDADES DE TENER PROBLEMAS PARA DEVOLVER LOS PRÉSTAMOS, ES POSIBLE SE RECHAZA SU SOLICITUD DE PRÉSTAMO O SE LES OFRECEN PRODUCTOS ALTERNATIVOS.
- EL OBJETIVO DE UN MODELO DE PREDICCIÓN DE MOROSIDAD ES USAR LOS DATOS PARA CREAR UN CLASIFICADOR.

AGE	ED	CREDIT	ADDRESS	INCOME	DEBT	CREDIT	OTHER	STATUS
41	3	17	12	176	9.3	11.359	5.001	1
27	1	10	6	31	17.3	1.362	4.001	0
40	1	15	14	55	5.5	2.186	2.169	0
41	1	15	14	120	2.9	2.691	0.871	0
24	2	2	0	28	17.3	1.353	3.052	1
41	2	5	5	25	10.2	0.198	2.471	0
39	1	20	9	67	30.6	3.839	16.09	0
43	1	12	11	38	3.6	0.071	1.259	0
24	1	3	4	19	29.4	1.359	3.277	1
36	1	0	13	25	19.2	2.778	2.471	0
37	2	16	10	110	9.3	10.25	3.21	

CATEGORICAL VARIABLE

MODELING



PREDICCIÓN

ETIQUETA PREDICIDA

◦ EL EJEMPLO ANTERIOR SE
REFIERE AL CLASIFICADOR BINARIO

0 1
CON DOS VALORES.

◦ PERO PODEMOS CREAR MODELOS
PARA LA CLASIFICACIÓN MULTICLAS.

CLASIFICACIÓN MULTICLAS

EJEMPLO



* CONJUNTOS DE DADOS DE PACIENTES QUE PADecem
 TODAS A MESMA SINTOMATOLOGIA *

DGE	SEX	BP	CHOLESTEROL	UA	K	DRUG
23	F	HIGH	HIGH	0.773	0.039	Y
42	M	LOW	HIGH	0.735	0.056	C
47	M	LOW	HIGH	0.697	0.067	C
28	F	NORMAL	HIGH	0.564	0.072	X
61	F	LOW	HIGH	0.557	0.039	Y
22	F	NORMAL	HIGH	0.671	0.039	X
49	F	NORMAL	HIGH	0.77	0.049	Y
44	M	LOW	HIGH	0.767	0.065	C
60	M	NORMAL	HIGH	0.777	0.051	Y
43	M	LOW	NORMAL	0.526	0.077	Y

CATEGORICAL
 VARIABLE

DGE	SEX	BP	CHOLESTEROL	UA	K	DRUG
36	F	LOW	HIGH	0.697	0.069	

* DRUG: E: MEDICAMENTO DE CAC RESPOSTA BOM.

DGE	SEX	BP	CHOLEST.	NU	K	DRUG
23	F	HIGH	HIGH	0.793	0.037	Y
42	M	LOW	HIGH	0.725	0.056	C
47	M	LOW	HIGH	0.694	0.069	C
28	F	NORMAL	HIGH	0.564	0.042	X
61	F	LOW	HIGH	0.559	0.077	Y
22	F	NORMAL	HIGH	0.673	0.039	X
49	F	NORMAL	HIGH	0.77	0.049	Y
44	M	LOW	HIGH	0.767	0.069	C
60	M	NORMAL	HIGH	0.773	0.051	Y
43	M	LOW	NORMAL	0.526	0.072	Y

CATEGORICAL
VARIABLE

AGE	SEX	BP	CHOLEST.	NU	K	DRUG
36	F	LOW	HIGH	0.697	0.069	


* MUESTRA DE
CLASIFICACIÓN
MULTICLASE



PREDICTED
CLASSES

MODELING

PREDICTION



CLASSIFIER

USOS EMPRESARIALES DE CLASIFICACIÓN

* PARA PREDECIR LA CATEGORÍA A LA QUE PERTENECE UN CLIENTE


* PARA DETECTAR LA PÉRDIDA DE CLIENTES.
SE PUEDE PREDECIR SI UN CLIENTE CAMBIA A OTRO
PROVEEDOR O MARCA.

* PARA PREDECIR SI UN CLIENTE RESPONDE O NO
A UNA CAMPAÑA PUBLICITARIA CONGRUENTE.

LA CLASIFICACIÓN DE DATOS:

• VARIAS APLICACIONES EN UNA AMPLIA VARIEDAD DE SECTORES.

• MUCHOS PROBLEMAS PUEDEN SOLUCIONARSE CON ASOCIACIONES ENTRE LAS VARIABLES CARACTERÍSTICAS Y LAS VARIABLES OBJETIVO.



• ESPECIALMENTE CUANDO SE DISPONE DE DATOS ETIQUETADOS:

- FILTRAR SPAM
- RECONOCER LA VOZ
- RECONOCER LA ESCRITURA A MANO
- IDENTIFICACIÓN BIOMÉTRICA
- CLASIFICACIÓN DE DOCUMENTOS, ETC.

*CLASIFICACIÓN DE ALGORITMOS EN MACHINE LEARNING *

- DECISION TREES (ID3, C4.5, C5.0)
- NAÏVE BAYES
- LINEAR DISCRIMINANT ANALYSIS
- K-NEAREST NEIGHBOR
- LOGISTIC REGRESSION
- NEURAL NETWORKS
- SUPPORT VECTOR MACHINES (SVM)

#####

K-NEAREST NEIGHBOURS

ALGORITMO MACHINE LEARNING

MÓDULO 3

#####

INTRO TO KNN

- IMAGINA QUE UN PROVEEDOR DE TELÉFONO HA SEGMETADO SU BASE DE CLIENTES SEGUN PATRONES DEL USO DE SERVICIOS.
- CLASIFICA A LOS CLIENTES EN 4 GRUPOS

VALUE	LABEL
1	BASIC SERVICE
2	E-SERVICE
3	PLUS SERVICE
4	TOTAL SERVICE

CON TODOS LOS DATOS DEMOGRÁFICOS LA EMPRESA PUEDE PERSONALIZAR LAS OFERTAS PARA CLIENTES POTENCIALES INDIVIDUALES.

* ESTAMOS ANTE :

PROBLEMA DE CLASIFICACIÓN

* CONJUNTO DE DATOS CON ETIQUETAS PREDEFINIDAS

* NECESITAMOS CONSTRUIR UN MODELO QUE PUEDA PREDICIR LA CLASE DE UN CASO NUEVO O DESCONOCIDO

* TENEMOS QUE CREAR UN CLASIFICADOR POR EJEMPLO :

- USAR LAS FICAS DEL ϕ AL 7 PARA PREDICIR LA FRA 8.

DEMOSTRACIÓN





REGION AGE MARITAL ADDRESS INCOME ED EMPLOY RETIRE GENDES DESIDE CLETCAT

0	2	44	1	9	64	4	5	0	0	2	1
1	3	33	1	7	136	5	5	0	0	6	4
2	3	52	1	24	146	1	29	0	1	2	3
3	2	33	0	12	33	2	0	0	1	1	1
4	2	30	1	9	30	1	2	0	0	4	3
5	2	39	0	12	39	2	16	0	1	1	3
6	3	22	1	2	19	2	4	0	1	5	2
7	2	35	0	5	26	2	10	0	0	3	4
8	3	50	1	7	166	4	31	0	0	5	?

*USAMOS SOLO DOS CAMPOS
COMO PREDICTORES:

- EDDAD
- INGRESOS

*DESPUES GRAFICAREMOS
LOS CLIENTES EN FUNCION DE
SU MEMBRERIA.

* ¿CÓMO ENCONTRAMOS LA CLASE
DE NUESTRO NUEVO CLIENTE?

Nº 8

1° → Podemos ASIGNAR LA CLASE
DE SU VECINO MAS CERCAÑO EN
LA GRÁFICA.


IMPORTANT

⇒ 1-NN → 4: TOTAL SERVICE
(ES EL VECINO MAS CERCAÑO)
"KNN"

1-NN = 4

TOTAL SERVICE

GRÁFICA DE
DISPERSIÓN




* ¿PODEMOS CONFIAR EN QUE NUESTRO JUICIO SE BASA EN EL VECINO MAS CERCANO?

— PUEDE SER UN MAU JUICIO SI EL VECINO MAS CERCANO ES UN CASO MUY EXCEPCIONAL O UN CASO ATÍPICO.

PARA EVITAR ESTO
ESCOGEMOS LOS 5
VECINOS MAS CERCANOS.

OBTENEMOS LA
MAYORIA DE CLASES
PARA DEFINIR
LA CLASE



ESTO TIENE
MAS SENTIDO.

5-NN → 3
PLUS SERVICE

ESTO DEMUESTRA LA
INTUICIÓN QUE SUBYACE EN KNN

DEFINICIÓN DE KNN


ES UN ALGORITMO DE CLASIFICACIÓN QUE TOMA UN CONJUNTO DE PUNTOS ETIQUETADOS Y LOS USA PARA APRENDER A ETIQUETAR OTROS PUNTOS.



*CLASIFICA LOS CASOS EN FUNCIÓN DE SU SIMILITUD CON OTROS CASOS.

*LOS PUNTOS QUE ESTÁN CERCA SE LLAMAN VECINOS:

NEIGHBORS



*KNN SE BASA EN ESTE PARADIGMA:

-CASOS SIMILARES CON LAS MISMAS ETIQUETAS DE CASOS ESTÁN CERCA UNO DE OTROS.

-LA DISTANCIA ENTRE DOS CASOS ES UNA MEDIDA DE SU SIMILITUD

*CÓMO LA SIMILITUD O «LA INVERSA», LA DISTANCIA O DISIMILITUD DE DOS PUNTOS DE DATOS.

→ USANDO:

LA DISTANCIA EUCLIDIANA

* ALGORITMO KNN *

(K-NEAREST NEIGHBOURS)

1° DAR UN VALOR A K .

2° CALCULAR LA DISTANCIA DESDE EL NUEVO CASO HASTA CADA UNO DE LOS CASOS DEL CONJUNTO DE DATOS.

3° BUSCAR LAS OBSERVACIONES K EN LOS DATOS DE ENTRENAMIENTO QUE ESTEN MÁS CERCA DE LAS MEDICIONES DEL PUNTO DE DATOS DESCONOCIDO.

4° PREDECIR LA RESPUESTA DEL PUNTO DEL DATO DESCONOCIDO. UTILIZANDO EL VALOR DE RESPUESTA MÁS POPULAR DE LOS K -NEAREST NEIGHBOURS MÁS CERCANOS.

* PARTES CONFUSAS *

- 
- 1° ¿CÓMO SELECCIONAR LA K CORRECTA?
 - 2° ¿CÓMO CALCULAR LA SIMILITUD DE LOS CASOS?

* PARTES CONFUSAS *

2º - CALCULAR SIMILITUD ENTRE DOS PUNTOS DE DATOS:

* EJEMPLO ① 1 DIMENSION

- SUPONEMOS QUE TENEMOS 2 CLIENTES Y QUE SOLO TIENEN UNA CARACTERÍSTICA:
- EDAD

CLIENTE 1: 34 AÑOS

CLIENTE 2: 30 AÑOS

PODEMOS USAR FACILMENTE UN TIPO ESPECÍFICO DE DISTANCIA:

* DISTANCIA MINIKOWSKI *

$$DIS(X_1, X_2) = \sqrt{\sum_{i=1}^n (x_{1i} - x_{2i})^2}$$

(DISTANCIA EUCLIDIANA)

LA DISTANCIA ENTRE X_1 Y X_2


$$= \sqrt{(34 - 30)^2} = 4$$

* EJEMPLO (2):

2 DIMENSIONES

CLIENTE 1: 34 AÑOS - 190 INGRESOS

CLIENTE 2: 30 AÑOS - 200 INGRESOS



$$DIS (x_1, x_2) = \sqrt{\sum_{i=1}^n (x_{1i} - x_{2i})^2}$$

$$= \sqrt{(34-30)^2 + (190-200)^2} = 10.77$$

* EJEMPLO (3):

MULTIDIMENSIONES



CLIENTE 1: 34 AÑOS - 190 INGRESOS - 3 EDUCACIÓN

CLIENTE 2: 30 AÑOS - 200 INGRESOS - 8 EDUCACIÓN

$$DIS (x_1, x_2) = \sqrt{\sum_{i=1}^n (x_{1i} - x_{2i})^2}$$

$$= \sqrt{(34-30)^2 + (190-200)^2 + (3-8)^2} = 11.87$$

¿CUAL ES EL MEJOR VALOR DE K?



• UN K BAJO PROVOCA UN SOBREFITTING DEL MODELO.


• SIGNIFICA QUE EL MODELO NO ESTA LO SUFICIENTEMENTE GENERALIZADO PARA PODER SER USADO EN CASOS FUERA DE LA MUESTRA.

* FUERA DE LA MUESTRA: *
* SON DATOS QUE ESTAN FUERA DEL *
* CONJUNTO DE DATOS UTILIZADO PARA *
* ENTRENAR EL MODELO. *

• EL SOBREFITTING ES MUY MALO. PUESTO QUE QUEREMOS QUE NUESTRO MODELO GENERALMENTE FUNCIONE CON CUALQUIER DATO. NO SOLO CON LOS DATOS UTILIZADOS EN EL ENTRENAMIENTO

• $K = 20 \rightarrow ?$

↓



• SI ELEGIMOS UN VALOR MUY ALTO DE K .
EL MODELO SE GENERALIZA DEMASIADO.

* LA SOLUCIÓN GENERAL: *

- RESERVAR UNA PARTE DE LOS DATOS PARA
PROBAR LA PRECISIÓN DEL MODELO.

- UNA VEZ HECHO ESTO:

a) $K = 1$

b) UTILIZAR LOS DATOS DEL TRAIN PARA
MODELAR

c) CALCULAR LA PRECISIÓN DE LA PREDICCIÓN
CON TODAS LAS MUESTRAS DEL CONJUNTO DE
TEST.

d) REPETIR EL PROCESO DETERMINANDO LA K

e) COMPROBAR QUE K ES LA MEJOR PARA
TU MODELO.

- EN NUESTRO EJEMPLO ES EL 4.
 $K=4 \rightarrow$ NOS DADA LA MEJOR PRECISIÓN.

*TAMBIÉN SE PUEDE USAR PARA CALCULAR
LOS VALORES DE UN OBJETIVO CONTINUO*

- KNN: SE PUEDE USAR PARA REGRESIÓN

- EN ESTA SITUACIÓN EL VALOR OBJETIVO
MEDIO O KNN MEDIO.

→ SE USA PARA OBTENER LA PREDICCIÓN
PARA EL NUEVO CASO.

• EJEMPLO:

- HAY QUE HACER LA PREDICCIÓN DEL PRECIO DE
UNA VIVIENDA EN FUNCIÓN DE SU CONJUNTO DE
CARACTERÍSTICAS.

→ - Nº HABITACIONES
- AÑO CONSTRUCCIÓN
- ETC.

- PUEDE ENCONTRAR FÁCILMENTE LOS 3
CASOS VECINOS MÁS CERCANOS, NO SOLO
EN FUNCIÓN DE DISTANCIA, SINO TAMBIÉN EN
FUNCIÓN DE TODAS LAS VARIABLES Y LUEGO
PREDICIR EL PRECIO SEGÚN TAMAÑO MEDIO DE LOS
VECINOS.

#####

MÉTRICAS DE EVALUACIÓN DE LOS CLASIFICADORES

MÓDULO 3

#####

— ESTAS MÉTRICAS EXPLICAN EL RENDIMIENTO
DE UN MODELO.

• TENEMOS UN CONJUNTO DE DATOS CON EL
HISTÓRICO QUE MUESTRA EL GIRO DE UN
CLIENTE PARA UNA EMPRESA DE SEGURO.

— HEMOS ENTRENADO EL MODELO Y AHORA
QUEREMOS CALCULAR SU PRECISIÓN USANDO
EL CONJUNTO DE TEST.

— PASAMOS EL CONJUNTO DE TEST (PRUEBA)
A NUESTRO MODELO Y OBTENDEMOS LAS
ETIQUETAS PREDICADAS.

— ¿CÓMO SABEMOS CUÁL ES EL PROCESO?



- COMPARAR LOS VALORES REALES EN EL TEST CON LOS VALORES PREDICADOS POR EL MODELO.
- LAS MÉTRICAS DESEMPLEAN UN PAPEL CLAVE EN EL DESARROLLO DE UN MODELO
 - ↳ LAS PROPORCIONA INFO SOBRE LAS ÁREAS QUE PODRÍAN REQUIRIR MEJORA

* METRICS *

- 1º - ÍNDICE DE JACCARD
- 2º - PUNTUACIÓN F1
- 3º - LOG LOSS


* INDICE DE JACCARD *

(JACCARD INDEX)

≡ COEFICIENTE DE SIMILITUD DE JACCARD ≡

Y : ACTUAL LABELS

$\hat{Y}$: PREDICTED LABELS



$$J(Y, \hat{Y}) = \frac{|Y \cap \hat{Y}|}{|Y \cup \hat{Y}|} = \frac{|Y \cap \hat{Y}|}{|Y| + |\hat{Y}| - |Y \cap \hat{Y}|}$$

JACCARD ES EL TAMAÑO DE LA INTERSECCIÓN
DIVIDIDO POR EL TAMAÑO DE LA UNIÓN DEL
CONJUNTO DE ETIQUETAS

EJEMPLO:

- CONJUNTO DE PRUEBAS DE TAMAÑO 10
- CON 8 PREDICCIONES CORRECTAS U 8 INTERSECCIONES

$Y: [0, 0, 0, 0, 0, 1, 1, 1, 1, 1]$

$\hat{Y}: [1, 1, 0, 0, 0, 1, 1, 1, 1, 1]$



$$J(Y, \hat{Y}) = \frac{8}{10 + 10 - 8} = 0.66$$

* LA PRECISION DE JACCARD ES: 0.66

* SI TODO EL CONJUNTO DE PREDICTED LABELS PARA UNA MUESTRA COINCIDE Estrictamente con el conjunto REAL (Actual Labels):

* DE LO CONTRARIO:

→ 0.0

↓
 $J(Y, \hat{Y}) = 1.0$


=====

* MATRIZ DE CONFUSIÓN *

(F1-SCORE)

≡ CONFUSION MATRIX ≡

- SUPONGAMOS QUE NUESTRO CONJUNTO DE TEST TIENE SOLO 40 FILAS



* ESTA MATRIZ MUESTRA PREDECIONES CORRECTAS E INCORRECTAS EN COMPARACION CON LAS TRUE LABELS

- LA PRIMERA FILA ES PARA CLIENTES CUYO VALOR REAL DE CHURNO EN EL CONJUNTO DE PRUEBA ES 1.
- COMO PODEMOS CALCULAR 40 CLIENTES EL VALOR DE CHURN DE 15 DE ELLOS ES 1.
- DE ESOS 15: PREDITO BIEN 6 COMO 1 Y 9 COMO 0.

• ESTO SIGNIFICA QUE PARA 6 CLIENTES, EL VALOR DE CHURN REAL ERA 1, EN EL CONJUNTO DE PRUEBA, Y EL CLASIFICADOR TAMBIÉN PREDIJO BIEN LOS 6 COMO 1.

• SIN EMBARGO: MIENTRAS QUE LA ETIQUETA REAL DE 9 CLIENTES ERA 1 EL CLASIFICADOR PREDIJO 0.

↳ PODEMOS CONSIDERAR ESTO COMO UN ERROR DEL MODELO PARA LA 1ª FICHA.

* LOS CLIENTES CON VALOR REAL 0 DE LA SEGUNDA FICHA SON 25.
EL CLASIFICADOR PREDIJO BIEN 24 Y UNO DE ELLOS COMO 1.

↳ ESTA PREDICCIÓN ES OK.

IMPORTANTE:

LA MATRIZ DE CONFUSIÓN NOS MUESTRA LA CAPACIDAD DEL MODELO PARA PREDICAR O SEPARAR CORRECTAMENTE LAS CLASES.

• EN EL CASO ESPECÍFICO DE UN CLASIFICADOR BINARIO COMO ESTE EJEMPLO:

- PODEMOS INTERPRETAR ESTOS NÚMEROS COMO EL RECuento DE:

- VERDADEROS POSITIVOS $\rightarrow$ TP
- FALSOS NEGATIVOS $\rightarrow$ FN
- VERDADEROS NEGATIVOS $\rightarrow$ TN
- FALSOS POSITIVOS $\rightarrow$ FP

• BASÁNDONOS EN EL RECuento DE CADA SECCIÓN, PODEMOS CALCULAR LA PRECISIÓN Y LA RECUPERACIÓN DE CADA ETIQUETA.

* LA PRECISIÓN ES UNA MEDIDA DE LA PREDICCIÓN *

$$\bullet \text{PRECISION} = TP / (TP + FP)$$

$$\bullet \text{RECALL} = TP / (TP + FN)$$

$\rightarrow$ ES LA VERDADERA TASA POSITIVA

CONFUSION MATRIX

TRUE LABEL γ	CHURN = 1	6	9
	CHURN = 0	1	24
		CHURN = 1	CHURN = 0
		PREDICTED LABEL γ	

20
15
10
5

- $\text{PRECISION} = \text{TP} / (\text{TP} + \text{FP})$
- $\text{RECALL} = \text{TP} / (\text{TP} + \text{FN})$
- $\text{F1-SCORE} = 2 \times (\text{PRC} \times \text{REC}) / (\text{PRC} + \text{REC})$ ✗

	PRECISION	RECALL	F1-SCORE
CHURN = 0	0.73	0.96	0.83
CHURN = 1	0.86	0.40	0.55

PRECISION MEDIA = 0.69

* F1-SCORE *

ES EL PROMEDIO ARMÓNICO DE LA
PRECISION Y EL RECALL.
DONDE F1 SU MEJOR VALOR ES 1 Y PEOR 0.

* PÉRDIDA LOGARÍTMICA *

(LOG LOSS)

≡ MIDE EL RENDIMIENTO DE CLASIFICADOR ≡
DE PROBABILIDADES ENTRE 0 y 1.


A VECES LA SALIDA DE CLASIFICADOR
ES LA PROBABILIDAD DE UNA ETIQUETA
DE CLASE EN LUGAR DE LA ETIQUETA

* EJEMPLO:

↳ EN REGRESIÓN LOGÍSTICA, LA SALIDA
PUEDE SER LA PROBABILIDAD DE
PÉRDIDA DEL CLIENTE

AGE	SEX	BP	CHLORSTE.	LDL	K	CHURN
23	F	HIGH	HIGH	0.753	0.031	1
41	M	LOW	HIGH	0.737	0.056	1
47	M	LOW	HIGH	0.695	0.067	0
28	F	NORMAL	HIGH	0.564	0.021	0
61	F	LOW	HIGH	0.559	0.078	0
22	F	NORMAL	HIGH	0.571	0.039	1
49	F	NORMAL	HIGH	0.77	0.049	0
44	M	LOW	HIGH	0.762	0.057	1
60	M	NORMAL	HIGH	0.772	0.051	0
43	M	LOW	NORMAL	0.526	0.072	1

TEST



↓
ACTUAL LABELS
Y

PREDICTED CHURN
0.91
0.13
0.04
0.23
0.43
...

↑
PREDICTED PROBABILITY

* ECUACIÓN LOG LOSS *

$$-(y \times \log(\hat{y}) + (1-y) \times \log(1-\hat{y})) \quad (1)$$

• POR AHORA CALCULAREMOS LA PÉRDIDA DE LOG PARA CADA FILA QUE MIDE CUÁN LEJOS ESTÁ NUESTRA PREDICCIÓN DE LA REALIDAD:

PREDICTED CHURN	log loss
0.91	0.094 <=
0.13	0.89 ✗
0.04	0.04 <=
0.23	0.26
0.43	0.56
...	

(2)

$$\log \text{loss} = 0.60$$

$\hat{y}$ PREDICTED PROBABILITY

$$\log \text{loss} = -\frac{1}{n} \sum (y \times \log(\hat{y}) + (1-y) \times \log(1-\hat{y}))$$

• CALCULAMOS LA PÉRDIDA PROMEDIO EN TODAS LAS FILAS DEL CONJUNTO DE PRUEBAS.

#####

LABORATORIO

#####

* LABORATORIO KNN *

ESTUDAR EN VISUAL => LABORATORIO 3

#####

INTRODUCCIÓN

MÓDULO 3

DECISION TREES

#####

TRAZAR TODOS LOS CAMINOS DE DECISION POSIBLES EN FORMA DE ARBOL

≡ ¿CÓMO CONSTRUIR UN DECISION TREE? ≡

* CONSULTAS DE DATOS DE PACIENTES QUE PADECEN TODAS LA MISMA ENFERMEDAD *

AGE	SEX	BP	CHOLEST.	LDL	K	DRUG
23	F	HIGH	HIGH	0.793	0.039	A
42	M	LOW	HIGH	0.739	0.056	A
47	M	LOW	HIGH	0.694	0.069	B
28	F	NORMAL	HIGH	0.564	0.042	B
61	F	LOW	HIGH	0.559	0.079	B
22	F	NORMAL	HIGH	0.691	0.079	A
49	F	NORMAL	HIGH	0.77	0.049	B
44	M	LOW	HIGH	0.762	0.069	A
60	M	NORMAL	HIGH	0.772	0.051	B
43	M	LOW	NORMAL	0.516	0.072	A

CATEGORICAL
VARIABLE

AGE	SEX	BP	CHOLEST.	LDL	K	DRUG
36	F	LOW	HIGH	0.697	0.069	

* DRUG: EL MEDICAMENTO AL CUAL RESPONDIÓ BIEN.

* CREAR UN MODELO PARA DETERMINAR
QUE FÁRMACO SERÍA EL ADECUADO
PARA UN FUTURO PACIENTE CON
LA MISMA ENFERMEDAD

• CARACTERÍSTICAS:

- EDAD.
- SEXO.
- PRESIÓN ARTERIAL (BP).
- COLESTEROL.

• OBJETIVO:


- EL FÁRMACO AL QUE RESPONDIO CADA PACIENTE.

• ES UN EJEMPLO DE CLASIFICADORES
BINARIOS Y PUEDE UTILIZAR LA PARTE
DE ENTRENAMIENTO DEL CONJUNTO DE
DATOS PARA CREAR UN DECISION TREE.

CONSTRUIR DECISION TREE CON CONJUNTO DE ENTRENAMIENTO (TRAINING TEST) ←


SE CREA DIVIDIENDO EL TRAINING TEST EN
MUCHOS DIFERENTES.

△ DRUG B
○ DRUG A




CLASIFICADOR DE PACIENTES.

- DONDE UN NUDO CONTIENE LA TOTALIDAD O MAYOR PARTE DE UNA CATEGORIA DE DATOS.



* Podemos construir el árbol considerando los atributos uno por uno.

1. ELEGIR UN ATRIBUTO PARA TU DATASET.
2. CALCULAR LA IMPORTANCIA EN LA DIVISION DE DATOS : (SPITTING OF DATA).
3. SPLIT DATA BASED. DIVIDIR LOS DATOS SEGUN EL VALOR DEL MEJOR ATRIBUTO.
4. GO TO STEP 1. (REPETIR EN CADA RAMA).



CLASIFICADOR DE PACIENTES.

#####

CONSTRUIR

MÓDULO 3


DECISION TREES

#####


* SE CREAN UTILIZANDO PARTICIONES RECURSIVAS PARA CLASIFICAR LOS DATOS.

⇒ ¿CUÁL ES EL MEJOR ATRIBUTO?

- SUJITOS QUE TENEMOS 14 PACIENTES EN NUESTRA BASE DE DATOS.
- EL ALGORITMO ELIGE LA CARACTERÍSTICA MÁS PREDICTIVA PARA DIVIDIR LOS DATOS.
- ELEGIMOS COLESTEROL COMO PRIMER ATRIBUTO PARA DIVIDIR LOS DATOS.




• DIVIDIR LOS DATOS EN DOS PARTES: ALTO Y NORMAL




- SOLO CON HIGH NO PODAMOS PREDECIR CON ALTA CONFIANZA QUE EL MEDICAMENTO B PODRÍA SER EL ADECUADO PARA EL.

- SOLO CON NORMAL NO TENEMOS SUFICIENTE EVIDENCIA O INFORMACIÓN PARA DETERMINAR SI EL MEDICAMENTO B O A ES DE HECHO EL ADECUADO.



• USAMOS EL DIFERENTE SEXO:



- F: DRUG B CON ALTA CERTeza
- M: DRUG A CON BAJA CERTeza.

* MEJOR OPCIÓN QUE COLESTEROL.

• POR LO TANTO EL NUDO SEX ES MAS SIGNIFICATIVO QUE COLESTEROL, ES MAS PREDICTIVO QUE LOS OTROS ATRIBUTOS.


- MAS PREDICTIVO
- DISTINCIÓN DE LA IMPUREZA DE LOS NODOS
- LOWER ENTROPY

• AÑADIMOS A SEX EL ATRIBUTO DE COLESTEROL

IMPORTANTE:



* UN NUDO ES PURO SI EN EL

100% DE LOS CASOS
LOS NODOS CAEN A
UNA CATEGORÍA
ESPECÍFICA DEL CAMPO
DE DESTINO *



→
- AHORA SI PODEMOS
TOMAR FACILMENTE
UNA DECISIÓN

* AHORA NUDO
COLESTEROL ES
MAS PURO:



ENTROPY = ? ENTROPY = ?

- EL MÉTODO USA PARTICIONES RECURSIVAS PARA DIVIDIR LOS REGISTROS DE ENTRENAMIENTO EN SECCIONES MINIMIZANDO LA IMPUREZA EN CADA CASO.
- LA IMPUREZA DE LOS NODOS SE CALCULA MEDIANTE LA ENTROPÍA DE LOS DATOS DEL NODO.

¿QUÉ ES LA ENTROPÍA?

- LA CANTIDAD DE TRASTORNO DE LA INFORMACIÓN O CANTIDAD DE INCERTIDUMBRE EN LOS DATOS.
- LA ENTROPÍA EN EL NUDO DEPENDE DE CUANTOS DATOS HAY EN ESE NUDO Y SE CALCULA PARA CADA NUDO.


△ DRUG B 7
○ DRUG A 1



ENTROPY LOW



△ DRUG B 3
○ DRUG A 5



ENTROPY HIGH



△ DRUG B ?
○ DRUG A 0

ENTROPY = 0



△ DRUG B 4
○ DRUG A 4

ENTROPY = 1



- EN LAS DECISION TREE BUSCAMOS ÁRBOLES QUE TENGAN LA ENTROPÍA MÁS BAJA EN SUS NUDOS.
- LA ENTROPÍA SE USA PARA CALCULAR LA HOMOGENEIDAD DE LAS MUESTRAS CON CADA NUDO.

● CALCULO ENTROPY DE UN NODO ●

≡ TABLA DE FRECUENCIAS ≡

$$\text{ENTROPY} = -p(A) \log_2(p(A)) - p(B) \log_2(p(B))$$


P → LA PROPORCIÓN DE UNA CATEGORÍA (MEDICAMENTO)
A B

EJEMPLO:

• VAMOS A CALCULAR LA ENTROPÍA DEL CONJUNTO DE DATOS ANTES DE DIVIDIRLO:

DGE	SEX	BP	CHOLESTR.	LDL	K	DRUG
23	F	HIGH	HIGH	0.793	0.031	A
42	M	LOW	HIGH	0.735	0.056	A
47	M	LOW	HIGH	0.694	0.067	B
28	F	NORMAL	HIGH	0.564	0.021	B
61	F	LOW	HIGH	0.559	0.079	B
22	F	NORMAL	HIGH	0.671	0.039	A
49	F	NORMAL	HIGH	0.77	0.049	B
44	M	LOW	HIGH	0.767	0.055	A
60	M	NORMAL	HIGH	0.777	0.051	B
43	M	LOW	NORMAL	0.526	0.072	A

$$E = 0.940$$



S: [9B, 5A]



$$E = -p(A) \log_2(p(A)) - p(B) \log_2(p(B))$$

$$E = -(9/14) \log_2(9/14) - (5/14) \log_2(5/14)$$

$$E = 0.940$$

• AHORA PODEMOS PROBAR DIFERENTES ATRIBUTOS PARA VER EL MAS PRECISIVO

AGE	SEX	BP	CHOLESTR.	LDL	K	DRUG
23	F	HIGH	HIGH	0.793	0.034	A
42	M	LOW	HIGH	0.735	0.056	A
47	M	LOW	HIGH	0.694	0.067	B
28	F	NORMAL	HIGH	0.564	0.022	B
61	F	LOW	HIGH	0.559	0.079	B
22	F	NORMAL	HIGH	0.573	0.039	A
49	F	NORMAL	HIGH	0.77	0.049	B
44	M	LOW	HIGH	0.762	0.055	A
60	M	NORMAL	HIGH	0.772	0.051	B
43	M	LOW	NORMAL	0.526	0.072	A



¿CUAL ES EL NUDO CON MAYOR GANCHO DE INFORMACIÓN?

→ (LA INFORMACIÓN QUE SE OBTIENE AL AUMENTAR EN NIVEL DE CERTIDUMBRE DESPUES DE LA DIVISION).

INFORMATION GAIN = (ENTROPY BEFORE SPLIT) - ENTROPY AFTER SPLIT

* CONSTRUIR UN DECISION TREE ES:

- ENCONTRAR ATRIBUTOS QUE DISMINUYAN LA MAYOR GANANCIA DE INFORMACIÓN.

AGE	SEX	BP	CHOLESTR.	LDL	K	DRUG
23	F	HIGH	HIGH	0.773	0.037	A
42	M	LOW	HIGH	0.735	0.056	A
47	M	LOW	HIGH	0.697	0.067	B
28	F	NORMAL	HIGH	0.564	0.022	B
61	F	LOW	HIGH	0.559	0.077	B
22	F	NORMAL	HIGH	0.577	0.039	A
49	F	NORMAL	HIGH	0.77	0.049	B
44	M	LOW	HIGH	0.767	0.059	A
60	M	NORMAL	HIGH	0.777	0.051	B
43	M	LOW	NORMAL	0.526	0.072	A

$S: [9B, 5A]$

$E = 0.940$



CHOLESTEROL

NORMAL

HIGH

$S: [6B, 2A]$

$S: [3B, 3A]$

$E = 0.811$

$E = 1.00$

$GAIN(S, cholesterol)$

$= 0.048$

$S: [9B, 5A]$

$E = 0.940$



SEX

M

F

$S: [3B, 4A]$

$S: [6B, 1A]$

$E = 0.985$

$E = 0.592$


$GAIN(S, sex)$

⇐

$= 0.940 - [(7/14)0.985 + (7/14)0.592]$
 $= 0.151$



*YA TENEMOS NUESTRO COMIENZO
CORRECTO DEL DECISION TREE.



• PODEMOS REPETIR EL PROCESO PARA
CADA RAMA Y PROBAR CADA UNO DE
LOS OTROS ATRIBUTOS PARA SEGUIR ALCANZANDO
LAS HOJAS MAS PURAS.

• ESTA ES LA FORMA EN LA QUE
SE CONSTRUYE UN ARBOL DE DECISIONES.

#####

LABORATORIO

#####

* LABORATORIO ARBOL DE DECISIONES *

ESTUDAR EN VISUALC => LABORATORIO 4

#####

LABORATORIO II

#####

* LABORATORIO CREDIT CARD FRAUD DETEC *

ESTUDAR EN VIDEO => LABORATORIO 5
OPTIONAL

* IMPORTANTE:


— Librerías:

- SCIKIT-LEARN
- SNAP ML

* SNAP ML: LIBRERÍA DE IBM DE ALTO
(IBM) RENDIMIENTO PARA EL
MODELADO DE ML.

- PROPORCIONA IMPLEMENTACIONES DE CPU/GPU ALTAMENTE EFICIENTES DE MODELOS LINEALES Y BODAS EN DEBODAS.
- NO SOLO DEBODA LOS ALGORITMOS ML, TIENE SUS PROPIOS ALGORITMOS.

$$RAE = \frac{\sum_{j=1}^n |y_i - \hat{y}_j|}{\sum_{j=1}^n |y_i - \bar{y}|}$$



$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$$



$$MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

$$\hat{y} = \theta_0 + \theta_1 x_1$$

$$\theta_1 = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2}$$

$$\theta_0 = \bar{y} - \theta_1 \bar{x}$$