

* Major Machine Learning Technique *

• REGRESSION / ESTIMATION: (PRE DICCION)

- PARA PREDECIR UN VALOR CONTINUO

↳ PARA PREDECIR EL PRECIO DE UNA CASA EN FUNCION DE SUS CARACTERISTICAS

→ ESTIMAR LAS EMISIONES DEL MOTOR DE UN AUTOMOVIL

• CLASSIFICATION:

- TÉCNICA DE CLASIFICACIÓN PARA PREDECIR LA CLASE O CATEGORÍA DE UN CASO

↳ SI UNA CÉLULA ES BENIGNA O MALIGNA

→ SI UN CLIENTE QUEDARÁ O NO SU TELECOMUNICADORA

• CLUSTERING: (AGUPACION / GRUPOS)

- AGRUPA LOS CASOS SIMILARES

↳ PACIENTES SIMILARES

→ SEGMENTACIÓN DE CLIENTES EN EL CAMPO BANCARIO

• ASSOCIATIONS:

- TÉCNICA DE ASOCIACIÓN PARA ENCONTRAR ARTICULOS O OBJETOS QUE A MENUDO COEXISTEN

↳ ARTICULOS QUE UN CLIENTE SUELE COMPRAR JUNTOS

● ANOMALY DETECTION

- DETECCIÓN DE ANOMALÍAS.

↳ FRAUDES EN TARJETAS DE CRÉDITO

● SEQUENCE MINING

- MINERÍA DE SECUENCIAS: SE USA PARA PREDICIR EL SIGUIENTE EVENTO

↳ UN FLUJO DE CLICS EN UN SITIO WEB

● DIMENSION REDUCTION

- REDUCCIÓN DE DIMENSIÓN SE USA PARA REDUCIR EL TAMAÑO DE LOS DATOS (PCA)

● RECOMMENDATION SYSTEMS

- LOS SISTEMAS DE RECOMENDACIÓN SE USAN PARA ASOCIAR LAS PREFERENCIAS DE UNAS PERSONAS CON OTRAS, QUE TIENEN GUSTOS SIMILARES

↳ LES RECOMIENDAN NUEVOS ARTÍCULOS, LIBROS, PELÍCULAS, ETC.

DIFERENCIAS ENTRE:

- INTELIGENCIA ARTIFICIAL $\Rightarrow$ AI
- MACHINE LEARNING $\Rightarrow$ ML
- DEEP LEARNING $\Rightarrow$ DP

- AI COMPONENTS:

- COMPUTER VISION
- LANGUAGE PROCESSING
- CREATIVITY
- ETC

- MACHINE LEARNING

- CLASSIFICATION
- CLUSTERING
- NEURAL NETWORK

- REVOLUTION in ML:

- DEEP LEARNING.

AI COMPONENTS

#####

- LA "AI" INTENTA HACER QUE LAS COMPUTADORAS SEAN INTELIGENTES PARA IMITAR FUNCIONES COGNITIVAS DE LOS HUMANOS

MACHINE LEARNING

* APRENDIZAJE AUTOMÁTICO

- ES LA RAMA DE LA "AI" QUE COBRE LA PARTE ESTADÍSTICA DE LA INTELIGENCIA ARTIFICIAL
- ENSEÑA A LA COMPUTADORA A RESOLVER PROBLEMAS OBSERVANDO MILES DE EJEMPLOS



● APRENDE DE ELLOS Y DESPUÉS USA
ESA EXPERIENCIA PARA RESOLVER
EL MISMO PROBLEMA EN SITUACIONES
NUEVAS.

#####

DEEP LEARNING

*APRENDIZAJE PROFUNDO

● ES UN CAMPO MUY ESPECIAL DEL
MACHINE LEARNING EN EL QUE
LAS COMPUTADORAS PUEDEN APRENDER
Y TOMAR DECISIONES INTELIGENTES POR
SI MISMAS.

● IMPLICA UN NIVEL DE AUTOMATIZACIÓN
MÁS PROFUNDO EN COMPARACIÓN CON LA
MAYORÍA DE ALGORITMOS DE ML

* MACHINE LEARNING *

• MACHINE LEARNING APP

• MACHINE LEARNING ALGORITHMS

→ APLICACIONES EN EL MUNDO REAL

→ - DESCRIPCION GENERAL DE LOS
TEMAS DE MACHINE LEARNING.

- COMO EL "APRENDIZAJE SUPERVISADO"
Y EL "NO SUPERVISADO"

- VARIOS ALGORITMOS DE APRENDIZAJE ..
AUTOMÁTICO

#####

PYTHON FOR MACHINE LEARNING

#####

• LIBRERIAS Python:

- se pueden escribir los algoritmos de MACHINE LEARNING y dirona muy bien

#####

PAQUETES DE LIBRERIAS

#####

* NUMPY: LIBRERIA MATEMATICA PARA TRABAJAR CON MATRICES N-DIMENSIONALES

CALCULOS EFICIENTES Y EFICACES

ES MEJOR QUE PYTHON NORMAL



INTERICA

- CALCULOS
- FUNCIONES
- TIPOS DE DATOS
- IMAGENES

*SCIPY: COLECCION DE ALGORITMOS NUMÉRICOS Y
CASAS DE HERRAMIENTAS ESPECÍFICAS DE
DOMINIO.

↓
CIENTÍFICA

- PROCESAMIENTO DE SEÑALES
- OPTIMIZACIÓN
- ESTADÍSTICAS
- ETC.

IDEN PARA COMPUTACIÓN CIENTÍFICA
Y ALTO RENDIMIENTO

*MATPLOTLIB: PAQUETE DE TRAZADO POPULAR QUE
PROPORCIONA GRÁFICOS 2D Y 3D

!!!**¡¡¡IMPORTANTE!!!**!!!

PARA ENTENDER ESTAS CIBEREMAS HAZER EL
CURSO "ANÁLISIS DE DATOS CON PYTHON"

*PANDAS: BIBLIOTECA PYTHON DE HUYALD NICEZ
ESTRUCTURAS DE DATOS FÁCILES DE USAR
Y ALTO RENDIMIENTO

IMPORTACIÓN, MANEJO Y ANÁLISIS DE
DATOS

OFRECE ESTRUCTURAS DE OPERACIONES
PARA MANIPULAR TABLAS NUMERICAS Y
SERIES TEMPORALES

* SKIT LEARN:

COLECCIÓN DE ALGORITMOS Y HERRAMIENTAS
PARA MACHINE LEARNING

* IMPORTANTE DONDE *

#####

SKIT LEARN

#####

- MUY IMPORTANTES EN DATA SCIENCE

- FREE SOFTWARES MACHINE LEARNING

- BUSCA HOYDIA DE ALGORITMOS DE:

- CLASIFICACIÓN
- REGRESIÓN
- ASOCIACIÓN


- PREPARADO PARA TRABAJAR CON:

- NUMPY → NUMERICA
- SCIPY → CIENTIFICA

- BUENA DOCUMENTACIÓN

- FÁCIL DE IMPLEMENTAR CON:

- SKIT LEARN → CON POCAS LINEAS DE CÓDIGO



#####

SUPERVISED vs UNSUPERVISED

#####

ALGORITMOS SUPERVISADOS Y NO SUPERVISADOS


● SUPERVISAR:

→ OBSERVAR

→ DIRIGIR LA EJECUCIÓN DE UNA TAREA

→ SUPERVISAR UN MODELO DE APRENDIZAJE

AUTOMÁTICO "ML". QUE PUEDE
PRODUCIR REGIONES DE CLASIFICACIÓN
COMO LAS QUE VEMOS AQUÍ:



• ¿CÓMO SE SUPERVISA?

→ ENSEÑANDO AL MODELO

→ SE CARGA EL MODELO CON CONOCIMIENTOS PARA QUE PUEDA PREDECIR INSTANCIAS FUTURAS.

• ¿CÓMO ENSEÑAMOS A UN MODELO?

→ ENSEÑAMOS AL MODELO CON DATOS DE UN CONJUNTO DE DATOS ETIQUETADOS:

DATOS ETIQUETADOS

ATRIBUTOS

ID	CLUMP	MIT	CLASS
100025	5	1	BENIGN
1002945	5	1	BENIGN
101343	3	1	MALIGNANT
101673	6	1	BENIGN
100013	4	5	BENIGN

CARACTERÍSTICAS

CONJUNTO DE DATOS ETIQUETADOS

* EL VALOR DE LOS DATOS :

→ NUMÉRICO : 8 (CUMB)



MÁS FRECUENTES

→ CATEGÓRICO : BENIGN




- SE USA CARACTERES
- SE USA PARA LA CLASIFICACIÓN


#####

* TYPES OF SUPERVISED LEARNING *

CLASSIFICATION



REGRESSION



CLASSIFICATION:

- PROCESO DE PREDECIR UNA CLASE,
ETIQUETA O CATEGORIA DISCRETA.

DATOS ETIQUETADOS

ATRIBUTOS

ID	CYLIND	MIT	CLASS
100025	5	1	BENIGN
1007945	5	1	BENIGN
101343	3	1	MALIGNANT
101673	6	1	BENIGN
100013	4	5	BENIGN

CARACTERÍSTICAS

CATEGORICAL
VALUES


REGRESSION:

- ES EL PROCESO DE PREDECIR UN VALOR
CONTINUO EN LUGAR DE UN VALOR CATEGÓRICO

	MOTOR	CYLINDERS	CO2 EMISSIONS
0	2.0	4	196
1	2.4	4	221
2	1.5	4	136
3	3.5	6	255
4	3.5	6	244
5	3.3	6	230
6	2.4	4	255
7	3.5	6	?

CONTINUOUS
VALUES

REGRESSION



#####

* NO SUPERVISADO *

➔ NO SUPERVISAMOS EL MODELO

➔ DEJAMOS QUE EL MODELO
FUNCIÓN POR SÍ SOLO
PARA DESCUBRIR INFORMACIÓN
QUE PUEDE NO SER VISIBLE PARA
EL OJO HUMANO


➔ EL ALGORITMO SE ENTRENA
SOBRE EL CONJUNTO DE DATOS

CUSTOMER ID	AGE	EDU	INCOME	ADDRESS	DEBT IN RPD TO
1	41	2	19	USA001	6.3
2	47	1	100	USA007	12.8
3	33	2	57	USA022	20.9


NO ESTÁN ETIQUETADOS
TODOS ESTOS DATOS


➔ EXTRAER CONCLUSIONES
SOBRE LOS DATOS ETIQUETADOS

➔ TIENE ALGORITMOS MÁS DIFÍCILES
QUE EL APRENDIZAJE SUPERVISADO,
PORQUE CONOCER Poca O NINGUNA INFO
SOBRE LAS DATAS O LOS RESULTADOS ...



REDUCCIÓN DE DIMENSIONES, LA ESTIMACIÓN DE LA DENSIDAD, ANÁLISIS DE LA CESTA DE LA COMPRA Y LA AGRUPACIÓN EN CLUSTERS SON LAS TÉCNICAS DE ML SIN SUPERVISIÓN MÁS USADAS:






CLUSTERING

- TÉCNICA MAS POPULAR
- SE USA PARA GRUPAR PUNTOS DE DATOS U OBJETOS SIMILARES



APLICACIONES

- AYUDA ORGANIZAR EN GRUPOS TIPOS DE MÚSICA
- DESCUBRIR ESTRUCTURAS
- RESUMIR
- DETECTAR ANOMALIAS



RESUMEN



● SUPERVISADO:

- SE OCUPA DE DATOS ETIQUETADOS
- ALGORITMOS ML PARA LA CLASIFICACIÓN Y LA REGRESIÓN


● NO SUPERVISADO

- DATOS NO ETIQUETADOS
- MÉTODO AGRUPACIÓN CLUSTERING
- MENOS MODELOS
- MENOS MÉTODOS DE EVALUACIÓN QUE SE PUEDAN USAR PARA GARANTIZAR QUE EL RESULTADO SEA BUENO
- CREA UN ENTORNO MENOS CONTROLABLE Y DADO QUE LA MÁQUINA GENERA RESULTADOS PARA NOSOTROS.

INTRODUCTION TO REGRESSION

MOTOR	CYLINDERS	CO ₂ EFFLUENTS
0	2.0	196
1	7.4	221
2	1.5	136
3	3.5	255
4	3.5	244
5	3.2	230
6	2.4	255
7	3.5	?

CO₂ EFFLUENTS VALUES



ESTE CONJUNTO DE DATOS ESTARENDICUADO
CON LAS EMISIONES DE CO₂ DE DIFERENTES
COCHES.

- ➔ MOTOR
- ➔ CILINDROS
- ➔ CONSUMO
- ➔ EMISSIONES CO₂

¡¡ IMPORTANTE !!


¿PODEMOS PREDECIR
LA EMISIÓN DE CO₂
DE UN COCHE UTILIZANDO
OTROS CAMPOS COMO EL
TAMAÑO DEL MOTOR?

* SUPONEMOS QUE TENEMOS DATOS
HISTÓRICOS DE DIFERENTES COCHES
Y SUPONEMOS QUE EL COCHE Nº 7
AÚN NO SE HA FABRICADO.

* NECESITAMOS ESTIMAR SU EMISIÓN
APROXIMADA DE CO_2 DESPUÉS DE LA
PRODUCCIÓN

¿¿ ES POSIBLE?? ¿¿

— PODEMOS USAR MÉTODOS DE REGRESIÓN
PARA PREDECIR UN VALOR CONTINUO
UTILIZANDO OTRAS VARIABLES



X: VARIABLES INDEPENDIENTES

Y: DEPENDIENTES

	MOTOR	CYLINDERS	CO ₂ EMISSIONS
0	2.0	4	196
1	7.4	4	224
2	1.5	4	136
3	3.5	6	255
4	3.5	6	244
5	3.2	6	230
6	2.4	4	255
7	3.5	6	261

CONTINUOS
VALORES

Y → ESTADO, METO O METO FINAL QUE ESTUDIAMOS
E INTENTAMOS PREDECIR

X → VARIABLES CONOCIDAS O EXPLICATIVAS SON
LAS CAUSAS DE LOS ESTADOS

UN MODELO DE REGRESIÓN RELACIONA Y O
LA VARIABLE DEPENDIENTE CON UNA FUNCIÓN
DE X.

LA CLAVE DE LA REGRESIÓN ES QUE NUESTRO
VALOR DEPENDIENTE DEBE SER CONTINUO Y

LO PUEDE SER UN VALOR DISCRETO.

SIN EMBARGO LAS VARIABLES X O
INDEPENDIENTES SE PUEDEN MEDIR EN
UNA ESCALA DE MEDICIÓN CATEGÓRICA O CONTINUA

TIPOS DE MODELOS DE REGRESIÓN

● REGRESIÓN SIMPLE:

- SE USA UNA VARIABLE INDEPENDIENTE PARA ESTIMAR UNA VARIABLE DEPENDIENTE
- PUEDE SER LINEAL O NO
- EJ: PREDECIR CO_2 UTILIZANDO LA VARIABLE MUJER
- LA LINEALIDAD DE REGRESIÓN SE BASA EN LA NATURALEZA DE LA RELACIÓN

● REGRESIÓN MÚLTIPLE:

- MÁS DE UNA VARIABLE INDEPENDIENTE
- PUEDE SER LINEAL O NO

APLICACIONES DE REGRESIÓN

- PREVISIÓN DE VENTAS
- ANÁLISIS DE SATISFACCIÓN
- PREDECIR PRECIOS
- INGRESOS DE LOS VENDEDORES
- FINANZAS
- ATENCIÓN MÉDICA
- ETC.

REGRESION LINEAL SIMPLE

	MOTOR	CILINDROS	CONSUMO	CO ₂
0	2.0	4	8.5	196
1	2.4	4	9.6	221
2	1.5	4	5.9	136
3	3.5	6	11.1	255
4	3.5	6	10.6	244
5	3.7	6	10.1	230
6	2.4	4	9.2	? 

• PODEMOS USAR LA REGRESION LINEAL PARA PREDECIR UN VALOR CONTINUO

• VARIABLE DEPENDIENTE

• VARIABLES INDEPENDIENTES

ESCA APROXIMACION DE UN MODELO LINEAL QUE SE USA PARA DESCRIBIR LA RELACION ENTRE DOS O MAS VARIABLES.


!! IMPORTANTE !!

¿PODEMOS PREDECIR
LA EMISION DE CO₂
DE UN COCHE UTILIZANDO
OTROS CAMPOS COMO EL
TAMANO DEL MOTOR?



POR SUPUESTO
QUE SI

¿CÓMO FUNCIONA?

	MOTOR	CILINDROS	CONSUMO	CO ₂
0	2.0	4	8.5	196
1	2.4	4	9.6	221
2	1.5	4	5.9	136
3	3.5	6	11.1	255
4	3.5	6	10.6	244
5	3.7	6	10.1	230
6	2.4	4	9.2	?



① EL DIAGRAMA DE DISPERSIÓN MUESTRA QUE SE TRATA DE UNA REGRESIÓN LINEAL



* PUEDE BUSCAR UNA LÍNEA A TRAVÉS DE LOS DATOS

* EJEMPLO: A MEDIDA QUE AUMENTA EL TAMAÑO DEL MOTOR, AUMENTA CO₂

② USANDO LA LÍNEA DE ANTES PODRÍAMOS VER QUE UN MOTOR 2.4 → EMITE 221 CO₂.


Y PODRÍAMOS PREDECIR CUANTO EMITE NUESTRO VEHÍCULO N° 6

MODELO DE REPRESENTACION

• HAY QUE PREDECIR EL VALOR Y

USAMOS LA VARIABLE INDEPENDIENTE DE LOS CILINDROS X_1

DIAGRAMA DE DISPERSION



• LA LINEA DE AJUSTE SE MUESTRA TRADICIONALMENTE COMO UN POLINOMIO

$$\hat{Y} = \theta_0 + \theta_1 X_1$$

$\hat{Y}$ → VARIABLE DEPENDIENTE

X_1 → VARIABLE INDEPENDIENTE / SINGLE PREDICTOR

$\theta_0 + \theta_1$ → PARAMETROS DE LA LINEA QUE DEBEMOS DAR

PROBLEMA DE REGRESION SIMPLE CON UNA SOLA X

→ PENDIENTE DE LA RECTA

→ INTERSECCION

} COEFICIENTE DE LA LINEA DE AJUSTE

$$\hat{y} = \theta_0 + \theta_1 x_1$$

* ESTA ECUACION:

- $\hat{y}$ ES UNA FUNCION DE x_1
- $\hat{y}$ ES DEPENDIENTE DE x_1

RESOLVER

#####


¿CÓMO DIBUJAR UNA LINEA QUE
ADAPTES LOS PUNTOS?

¿CÓMO SE DETERMINA QUE LINEA SE
AJUSTA MEJOR?

#####

- CALCULAR θ_0 y θ_1 PARA ENCONTRAR
LA LINEA QUE MEJOR SE AJUSTA A
NUESTROS DATOS.

CONTINUE



HOW to find the best fit?

● SUPONEMOS QUE HEMOS ENCONTRADO LA LINEA QUE MEJOR SE AJUSTA A NUESTROS DATOS


$$\hat{y} = \theta_0 + \theta_1 x_1$$

$$x_1 = 5.4$$

$$y = 250$$

y

DIAGRAMA DE DISPERSION



x

$x_1 = 5.4 \rightarrow$ VARIABLE INDEPENDIENTE

$y = 250 \rightarrow$ EMISIONES CO₂ DE x_1

● SI TENEMOS UN MOTOR x_1 Y UN CO₂ = 250
SU CO₂ DEBERIA PREDECIRSE MUY CERCA
DEL VALOR BELC* SEGUN LOS DATOS HISTORICOS

* VEHICULO NUEVO

DIAGRAMA DE DISPERSION


$$X_1 = 5.4$$

$$Y = 250$$

Y

$$\hat{Y} = \theta_0 + \theta_1 X_1$$

$$\hat{Y} = 340 \rightarrow \text{PREDICCIÓN EMISIONES } X_1$$



X

$$\begin{aligned} \text{ERROR} &= Y - \hat{Y} \\ &= 250 - 340 \\ &= -90 \end{aligned}$$

ERROR RESIDUAL


ERROR

• SI USAMOS LA LINEA DE AJUSTE (POLINOMIO) CON PARAMETROS CONOCIDOS PODRÍAMOS PREDECIR LAS EMISIONES DE CO₂. EL RESULTADO SERÍA:
 $\hat{Y} = 340$

• SI COMPARAMOS EL VALOR REAL CON LA PREDICCIÓN VEMOS QUE HAY UN ERROR DE 90 UNIDADES


• NUESTRA LINEA DE PREDICCIÓN NO ES PRECISA

DIAGRAMA DE DISPERSION




IMPORTANTE:

- ERROR RESIDUAL: ES LA DISTANCIA DESDE EL PUNTO DE DATOS HASTA LA LINEA DE REGRESION AJUSTADA ($\hat{y} = 340$)



LA MEDIDA DE TODOS LOS ERRORES RESIDUALES MUESTRA QUÉ TAN MAL ENCAJA LA LÍNEA CON TODO EL CONJUNTO DE DATOS

DIAGRAMA DE DISPERSIÓN



$$x_1 = 5.4$$

$$y = 250$$

y

$$\hat{y} = \theta_0 + \theta_1 x_1$$

$$\hat{y} = 340 \rightarrow \text{PREDICCIÓN EMISIONES } x_1$$

$$\begin{aligned} \text{ERROR} &= y - \hat{y} \\ &= 250 - 340 \\ &= -90 \end{aligned}$$

$$MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2 \rightarrow \text{EQUACIÓN: ERROR CUADRÁTICO MEDIO}$$

- MATEMÁTICAMENTE CON LA ECUACIÓN ERROR CUADRÁTICO MEDIO (MSE).

* NUESTRO OBJETIVO ES ENCONTRAR UNA REGIÓN EN LA QUE SE MINIMICE LA MEDIA DE TODOS LOS ERRORES.

* DEBEMOS MINIMIZAR EL ERROR MEDIO DE LA PREDICCIÓN UTILIZANDO LA LUGAR DE DATOS.

REAJUSTE:

* EL OBJETIVO DE LA REGRESIÓN LINEAL ES MINIMIZAR ESTA ECUACIÓN MSE, PARA ESO DEBEMOS ENCONTRAR LOS MEJORES PARÁMETROS θ_0 Y θ_1

¿CÓMO ENCONTRAMOS θ_0 Y θ_1 ?

¿CÓMO ENCONTRAR LA PERFECT LINE?

*NO PODEMOS MOVER LA LINEA
DEAR.

- 2 ENFOQUES:

• ENFOQUE MATEMÁTICO

• ENFOQUE DE OPTIMIZACIÓN

ESTIMANDO PARÁMETROS

	MOTOR	CILINDROS	COLUMA	CO ₂
0	2.0	4	8.5	196
1	2.4	4	9.6	221
2	1.5	4	5.9	136
3	3.5	6	11.1	255
4	3.5	6	10.6	244
5	3.7	6	10.1	230
6	2.4	4	9.2	221

$$\hat{y} = \theta_0 + \theta_1 x_1$$

* CALCULAR LA MEDIA DE LAS
COLUMAS INDEPENDIENTES Y
DEPENDIENTES. O OBJETIVO DEL
CONJUNTO DE DATOS

* SE PUEDE DEMOSTRAR QUE LA INTERSECCION
Y LA PENDIENTE SE PUEDEN CALCULAR
CON ESTAS ECUACIONES

$$\hat{y} = \theta_0 + \theta_1 x_1$$

$$\theta_1 = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2}$$

VALOR MEDIO
TAMAJOS MOTOR

$$\bar{x} = (2.0 + 2.4 + 1.5 + \dots) / 9 = 3.03$$

VALOR MEDIO
EMISSIONES

$$\bar{y} = (196 + 221 + 136 + \dots) / 9 = 226.22$$

$$\theta_1 = \frac{(2.0 - 3.03)(196 - 226.22) + (2.4 - 3.03)(221 - 226.22) + \dots}{(2.0 - 3.03)^2 + (2.4 - 3.03)^2 + \dots}$$

$$\theta_1 = 39$$

$$\theta_0 = \bar{y} - \theta_1 \bar{x}$$

$$\theta_0 = 226.22 - 39 * 3.03$$

$$\theta_0 = 125.74$$

• AHORA PODAMOS ESCRIBIR EL POLINOMIO DE LA UNED:

#####

$$\hat{Y} = 125.74 + 39 \times x_1$$

#####

• ULD US7 QUE HAYAS ENCONTRADO LOS DATOS DE LA ECUACION UNED

• PODAMOS RESOLVER LA ECUACION PARA PREDICAR LAS EMISIONES DEL AUTO NUEVO

	MOTOR	Unidads	Consumo	CO ₂
0	2.0	4	8.5	196
1	2.4	4	9.6	221
2	1.5	4	5.9	136
3	3.5	6	11.1	255
4	3.5	6	10.6	244
5	3.7	6	10.1	230
6	2.4	4	9.2	?

$$\hat{Y} = \theta_0 + \theta_1 x_1$$

$$CO_2 = \theta_0 + \theta_1 \text{ Motor} \leftarrow$$

$$CO_2 = 125 + 39 \text{ Motor} \leftarrow$$

$$CO_2 = 125 + 39 \times 2.4$$


$$CO_2 = 218.6$$

PROS REGRESIÓN LINEAL

(LINEAS DE REGRESION)

- MUY RÁPIDA
- NO HAY QUE JUSTIFICAR
PUNTOS
- FÁCIL DE ENTENDER
- MUY INTERPRETABLES

DIAGRAMA DE DISPERSIÓN



#####

EVALUACIÓN DEL MODELO

EN MODELOS DE REGRESIÓN

#####

* EL OBJETIVO DE LA REGRESIÓN

ES CONSTRUIR UN MODELO PARA
PREDECIR CON PRECISIÓN UN
CASO DESCONOCIDO.

* DEBEMOS REALIZAR UNA EVALUACIÓN
DE REGRESIÓN DESPUÉS DE
CONSTRUIR EL MODELO

* HAY DOS ENFOQUES DE
EVALUACIÓN. *

≡ ENTRENAR Y PROBAR (TEST) ≡

≡ DIVISIÓN ENTRE TRAIN Y TEST ≡

* HAY ALGUNAS MÉTRICAS
PARA DETERMINAR LA PRECISIÓN
DE LOS MODELOS DE REGRESIÓN


¿EL MEJOR ENFOQUE PARA
OBTENER RESULTADOS MAS
PRECISOS?

¿Podemos calcular la precisión de nuestro
modelo?

1^{er} ENFOQUE:

- SELECCIONAR UNA PARTE DE NUESTRO
CONJUNTO DE DATOS PARA PROBLEMA
- CONSTRUIR UN MODELO CON ESTE
CONJUNTO DE DATOS (TRAIN)
- SELECCIONAMOS UNA PEQUEÑA PARTE DEL
CONJUNTO DE DATOS (TEST)

* CONJUNTO DE PRUEBA *



	MOTOR	CILINDROS	CONSUMO	CO2
0	2.0	4	8.5	196
1	2.4	4	9.6	221
2	1.5	4	5.9	136
3	3.5	6	11.1	255
4	3.5	6	10.6	244
5	3.7	6	10.1	230
6	2.4	4	9.2	221

TEST

TRAIN

ACTUAL
VALUES

- COMPARAMOS LOS VALORES REALES
DEL CONJUNTO DE PRUEBA CON
NUESTRO MODELO

ACTUAL
VALUES VS PREDICTED
VALUES

PREDICTION
3 239
4 244
5 230
6 218.6

PREDICTED
VALUES

$$ERROR = \frac{1}{n} \sum_{j=1}^n |y_j - \hat{y}_j|$$

	MOTOR	CIANIDROS	CONSUMO	CO ₂		PREDICION
0	2.0	4	8.5	196		
1	2.4	4	9.6	221		3 234
2	1.5	4	5.9	136		4 244
3	3.5	6	11.1	255		5 230
4	3.5	6	10.6	244		6 218.6
5	3.7	6	10.1	230		
6	2.4	4	9.2	221		

TEST

$\hat{y}$
 y

$$\text{ERROR} = \frac{1}{n} \sum_{j=1}^n |y_j - \hat{y}_j|$$

$$\text{ERROR} = \frac{(234 - 255) + (244 - 244) + \dots}{4}$$

1er ENFOQUE:

- ENTRENAR Y PROBAR EN EL MISMO CONJUNTO DE DATOS
- ENTRENAR EL MODELO EN TODO EL CONJUNTO DE DATOS Y LO PRUEBA CON UNA PARTE DEL MISMO CONJUNTO DE DATOS.
- SE PUEDE OBTENER UN REPRESENTANTE DE PREDICCIONES PRECISAS PARA EL MODELO
- ALTA PRECISION DE ENTRENAMIENTO
- BAJA PRECISION FUERA DE LA MUESTRA

— PRECISIÓN DEL ENTRENAMIENTO

- PORCENTAJE DE PREDICCIONES CORRECTAS AL USAR EL CONJUNTO DE DATOS DE PRUEBA
- UN ALTA PRECISIÓN NO ES NECESARIAMENTE ALGO BUENO.

ESTO PUEDE PROVOCAR UN SOBREENCAJTE DE LOS DATOS:

- ↳ ESTA DEMASIADO ADAPTADO A LOS DATOS
- ↳ PUEDES CAPTURAR EL RUIDO Y PRODUCIR UN MODELO GENERALIZADO

— PRECISIÓN FUERA DE LA MUESTRA

- PORCENTAJE DE PREDICCIONES CORRECTAS QUE EL MODELO HACE SOBRE DATOS CON LOS QUE NO SE HA ENTRENADO.
- AL REDUCIR UN TRAIN Y UN TEST EN EL MISMO CONJUNTO DE DATOS, ES POSIBLE QUE LA PRECISIÓN SEAN BAJAS DEBIDO A LA BAJA PROBABILIDAD DE UN SOBREENCAJTE

¡¡ IMPORTANTE !!

DATA PRECISIÓN FUERA DE
LA MUESTRA.
EL PROPOSITO DEL MODELO ES
HACER PREDECIONES CORRECTAS
A PARTIR DE DATOS
DESCONOCIDOS.

¿CÓMO PODEMOS

MEJORAR LA PRECISIÓN

FUERA DE LA MUESTRA???



USANDO EL 2º ENFOQUE:


≡ DIVISIÓN ENTRE TRAIN Y TEST ≡
* TRAIN / TEST SPLIT *

	MOTOR	CILINDROS	CONSUMO	CO ₂
0	2.0	4	9.5	196
1	2.4	4	9.6	221
2	1.5	4	5.9	136
3	3.5	6	11.1	255
4	3.5	6	10.6	244
5	3.7	6	10.1	230
6	2.4	4	9.2	221

TRAIN



1. SELECCIONAMOS UNA PARTE DE NUESTRO CONJUNTO DE DATOS
2. Y EL RESTO SE USA PARA LAS PRUEBAS
3. SE PASA AL MODELO PARA SU PREDICCIÓN
4. LOS VALORES PRONOSTICADOS SE COMPARAN CON LOS VALORES REALES.



● TRAIN / TEST SPLIT:

- IMPLICA DIVIDIR EL CONJUNTO DE DATOS PARA QUE EXCLUYAN MUTUAMENTE
 - DESPUÉS ENTRENAS CON EL CONJUNTO DE ENTRENAMIENTO Y HACES PRUEBAS CON EL CONJUNTO DE PRUEBAS.
 - EVALUACIÓN MÁS PRECISA DE LA PRECISIÓN FUERA DE LA MUESTRA. EL CONJUNTO DE DATOS NO FORMA PARTE DEL QUE SE USÓ PARA ENTRENAR DATOS
 - ES MÁS REALISTA PARA LOS PROBLEMAS DEL MUNDO REAL.
 - EL MODELO NO CONOCE EL RESULTADO DE ESTOS PUNTOS DE DATOS
 - DESPUÉS DE ENTRENAR EL MODELO CON EL CONJUNTO DE TEST POSTERIORMENTE.
- 

- EL PROBLEMA DEL TRAIN/TEST SPLIT:
DEPENDI EN GRAN MEDIDA DE LOS
CONJUNTOS DE DATOS EN LOS QUE
SE ENTRENAN Y PROBAMOS.

#####

* HAY OTRO MODELO DE EVALUACIÓN
(CANDO:

VALIDACIÓN CRUZADA DE
PLIEGUES K

#####

➡ RESUELVE LA MAYORÍA DE ESTOS
PROBLEMAS.

¿CÓMO SE USA?





HOW TO USE K-FOLD CROSS-VALIDATION

¿CÓMO SE CORRIÓ UNA DEPENDENCIA
NO QUE RESULTA DE UNA DEPENDENCIA?


- SE PROMEDIO

DATASET




1° FOLD

80%




2° FOLD

84%




3° FOLD

82%



4° FOLD

86%



TODA EL CONJUNTO DE
DATOS REPRESENTADO
POR PUNTOS.

1. SI TENEMOS K IGUAL A CUATRO VECES
2. DIVIDIMOS EL CONJUNTO DE DATOS COMO SE
NUESTRA ARRIBA.
3. USAMOS EL PRIMER 25% PARA TEST Y
EL RESTO PARA TRAIN.
4. EL MODELO SE CREA CON TRAIN Y SE EVALUA CON TEST
5. EN LA SIGUIENTE RONDA O DESPLIEGUE
USAMOS EL SEGUNDO 25% ... ETC

6. POR ÚLTIMO:

-SE PROMEDIA EL RESULTADO DE LAS
CUATRO EVALUACIONES

*
* PRECISION = AVG (80% + 84% + 82% + 86%) = 83%
* (ACCURACY)
*

LA VALIDACIÓN CRUZADA DE PLIEGUE K:

- => FORMA MÁS SIMPLE
- => MÚLTIPLES DIVISIONES ENTRE TEST Y TRAIN
- => UTILIZA EL MISMO CONJUNTO DE DATOS
- => CADA DIVISIÓN ES DIFERENTE
- => EL RESULTADO SE PROMEDIA PARA OBTENER
UNA PRECISIÓN MÁS UNIFORME FUERA DE
LA MUESTRA

* CURSO VALIDACIÓN
CRUZADA DE K PLIEGUES *

#####

MÉTRICAS DE EVALUACIÓN EN MODELOS DE REGRESIÓN

#####

LAS MÉTRICAS DE EVALUACIÓN SE
USAN PARA EXPLICAR EL RENDIMIENTO
DE UN MODELO:

	HOTEL	CUBEDS	COUNTRY	CO ₂	
0	2.0	4	8.5	196	
1	2.4	4	9.6	221	
2	1.5	4	5.9	136	
3	3.5	6	11.1	255	
4	3.5	6	10.6	244	
5	3.7	6	10.1	230	
6	2.4	4	9.2	221	

$\hat{y}$

PREDICTION
3 234
4 244
5 230
6 219.6

$$\text{ERROR} = \frac{1}{n} \sum_{j=1}^n |y_j - \hat{y}_j|$$

$$\text{ERROR} = \frac{(234 - 255) + (244 - 244) + \dots}{4}$$

-PODEMOS COMPARAR LOS VALORES REALES Y LOS VALORES PREDICTADOS PARA CALCULAR LA PRECISIÓN DE NUESTRO MODELO DE REGRESIÓN.

• LAS MÉTRICAS PROPORCIONAN INFORMACIÓN SOBRE LAS ÁREAS QUE REQUIEREN MENOR

$$\text{ERROR} = \frac{(234 - 255) + (244 - 244) + \dots}{4}$$

$$\text{ERROR} = \frac{1}{n} \sum_{j=1}^n |y_j - \hat{y}_j|$$

	MOTOR	CILINDROS	CORSERTE	CO ₂
0	2.0	4	8.5	196
1	2.4	4	9.6	221
2	1.5	4	5.9	136
3	3.5	6	11.1	255
4	3.5	6	10.6	244
5	3.7	6	10.1	230
6	2.4	4	9.2	221

test

Y



- MAE
- MSE
- RMSE
- ...

$\hat{y}$

	PREDICCIÓN
3	254
4	244
5	230
6	218.6




- MAE : ERROR ABSOLUTO MEDIO
- MSE : ERROR CUADRÁTICO MEDIO
- RMSE : RÍZ ERROR CUADRÁTICO MEDIO


¿QUÉ ES UN ERROR DE MODELO?

- EN UNA REGRESIÓN EL ERROR DEL MODELO ES LA DIFERENCIA ENTRE LOS PUNTOS DE DATOS Y LA LÍNEA DE TENDENCIA GENERADA POR EL ALGORITMO.

FULL DATA



COMO HAY VARIOS PUNTOS DE DATOS
UN ERROR SE PUEDE DETERMINAR DE
VARIAS MANERAS:



$$MAE = \frac{1}{n} \sum_{j=1}^n |y_i - \hat{y}_j|$$

$$MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$$

$$RAE = \frac{\sum_{j=1}^n |y_i - \hat{y}_j|}{\sum_{j=1}^n |y_i - \bar{y}|}$$

$$R^2 = 1 - RSE \quad \leftarrow \quad RSE = \frac{\sum_{j=1}^n (y_i - \hat{y}_j)^2}{\sum_{j=1}^n (y_i - \bar{y})^2}$$

✱ MAE: ERROR ABSOLUTO MEDIO:

- ES LA MEDIDA DEL VALOR ABSOLUTO DE LOS ERRORES
- LA MAS FACIL DE ENTENDER
- ES SOLO EL ERROR PROMEDIO.

✱ MSE: ERROR CUADRÁTICO MEDIO:

- ES MÁS PORICAR QUE EL MAE PORQUE SE CENTRA MAS EN LOS ERRORES GRANDES
- QUE DIFERENTIAR EXPOENCIALMENTE LOS ERRORES MAS GRANDES EN COMPARACIÓN CON LOS + PEQUEÑOS

* RMSE: RAÍZ DEL ERROR CUADRÁTICO MEDIO

- LA RAÍZ CUADRADA DE MSE
- DE LAS MÁS POPULARES PORQUE EL MSE SE PUEDE INTERPRETAR EN LAS MISMAS UNIDADES QUE EL VECTOR DE RESPUESTA O LAS UNIDADES Y .

• FACILITA LA RELACIÓN DE SU INFORMACIÓN

* RDE: ERROR ABSOLUTO RELATIVO.

- MIDE LA MAE ENTRE LOS VALORES REALES Y LOS PREDICHOS EN RELACIÓN CON LA DIFERENCIA MAE ENTRE VALORES REALES Y MEDIA

* RSS: SUMA CUADRADOS RESIDUALES

$$RSS = \sum (Real - predicho)^2$$

* RSE: ERROR CUADRÁTICO RELATIVO

- ES MUY PARECIDO A RAE PERO LA COMUNIDAD DE CIENCIA DE DATOS LO HA ADOPTADO AMPLIAMENTE.
- SE UTILIZA PARA CALCULAR EL R^2 CUADRADO.

* R^2 : NO ES UN ERROR POR SI SOLO.

- ES UNA MÉTRICA POPULAR PARA MEDIR LA PRECISIÓN DE UN MODELO.

- REPRESENTA QUE TAN CERCA ESTÁN LOS VALORES DE LOS DATOS DE LA LÍNEA DE REGRESIÓN AJUSTADA.

- CUANTO MÁS ALTO SEA EL CUADRADO R^2 , MÁS CERCA SE AJUSTARÁ EL MODELO A LOS DATOS.

CADA UNA DE ESTAS MÉTRICAS SE PUEDE UTILIZAR PARA CANTIFICAR LA PRECISIÓN.

LA ELECCIÓN DE LA MÉTRICA DEPENDE COMPLEMENTAMENTE:

- TIPO DE MODELO
- TIPO DE DATOS
- DOMINIO DEL CONOCIMIENTO

* CURSO MÉTRICAS
EVALUACIÓN MODELOS DE
REGRESIÓN *

#####

LABORATORIO

#####

* REGRESIÓN LINEAL SIMPLE *

ESTUDAR EN VÍDEO $\Rightarrow$ LABORATORIO 1

#####

REGRESIÓN LINEAL MÚLTIPLE

#####

EN LA REGRESIÓN LINEAL SIMPLE
HEMOS VISTO QUE SE USA UNA VARIABLE
INDEPENDIENTE PARA PREDECIR UNA
VARIABLE DEPENDIENTE:

EJEMPLO:

- PREDECIR LAS EMISIONES DE CO₂
CON LA VARIABLE DEL TAMAÑO DEL
MOTOR

⇒ PERO EN REALIDAD HAY MÚLTIPLES
VARIABLES QUE PREDECEN LAS EMISIONES
DE CO₂.

⇒ CUANDO HAY VARIAS VARIABLES INDEPENDIENTES
SE DENOMINA REGRESIÓN LINEAL MÚLTIPLE

=> POR EJEMPLO:

-USANDO EL TAMAÑO DEL MOTOR
Y EN NÚMERO DE CILINDROS

● LA REGRESIÓN LINEAL MÚLTIPLE ES
LA EXTENSIÓN DE LA REGRESIÓN LINEAL
SIMPLE ●

IMPORTANTE

APLICACIONES DE LA REGRESIÓN LINEAL MÚLTIPLE

①

● IDENTIFICAR LA FUERZA DEL EFECTO QUE
TIENEN LAS VARIABLES INDEPENDIENTES
SOBRE LAS VARIABLES DEPENDIENTE

=> POR EJEMPLO: EFECTO RENDIMIENTO EXÁMENES

- TIEMPO DE REVISIÓN
- DIVERSIDAD SOBRE LOS EXÁMENES
- LA DISTANCIA A CLASE
- GÉNERO

②

• PREDICIR EL IMPACTO DE LOS CAMBIOS:

- POR ENTENDER COMO CAMBIA LA VARIABLE DEPENDIENTE AL CAMBIAR LAS VARIABLES INDEPENDIENTES

=> POR EJEMPLO: REVISAR LOS DATOS DE SALUD DE UNA PERSONA .

- CUANDO SE OBTIENE LA PÉRDIDA DE PESO DE UNA PERSONA POR CADA UNIDAD DE DIFERENTE OPTIMIZACIÓN DEL ÍNDICE DE MASA CORPORAL DEL PACIENTE MANTENIENDO CONSTANTES OTROS FACTORES

¿CÓMO FUNCIONA?

- AL IGUAL QUE EN CASIMPLE LA REGRESIÓN UNAL MÚLTIPLE ES UN MÉTODO DE PREDICCIÓN DE UNA VARIABLE CONTINUA
- UTILIZA MÚLTIPLES VARIABLES
(VARIABLES INDEPENDIENTES O PREDICTORES)
- PREDICEN EL VALOR DE UNA VARIABLE DEPENDIENTE
(VARIABLE OBJETIVO)

¿CO₂?

X: VARIABLES INDEPENDIENTES

Y: DEPENDIENTE

	MOTOR	CILINDROS	CONSUMO	CO ₂
0	2.0	4	8.5	196
1	2.4	4	9.6	221
2	1.5	4	5.9	136
3	3.5	6	11.1	255
4	3.5	6	10.6	244
5	3.7	6	10.1	230
6	2.4	4	9.2	221
7	2.7	6	11.1	255
8	3.7	6	11.6	267
9	2.4	4	9.2	212

$$CO_2 Em = \theta_0 + \theta_1 Motor + \theta_2 Cylindros + \dots$$

* PERMITE SABER QUE VARIABLES SON PREDICANTES SIGNIFICATIVAS DE LA VARIABLE DE RESULTADO.

* PUEDE INVESTIGAR COMO AFECTA CADA CARACTERÍSTICA A LA VARIABLE DE RESULTADO

ECUACIÓN DE REGRESIÓN

$$\hat{y} = \theta_0 + \theta_1 x_1 + \theta_2 x_2 + \dots + \theta_n x_n$$

VECTORIALEMENTE:

$$\hat{y} = \theta^T X$$

$$\theta^T = [\theta_0, \theta_1, \theta_2, \dots] \text{ (VECTOR DE COEFICIENTES)}$$

PARÁMETRO / VECTOR DE PESO

$$X = \begin{bmatrix} 1 \\ x_1 \\ x_2 \\ x_3 \\ \dots \end{bmatrix}$$

→ CALCULO DE CARACTERÍSTICAS
QUE REPRESENTA EL AUTOMÓVIL

→ x_1 - MOTOR

x_2 - CILINDROS

x_3 - ETC.

$X = \begin{bmatrix} 1 \\ x_1 \\ x_2 \\ x_3 \\ \dots \end{bmatrix}$ • EL PRIMER ELEMENTO DEL VECTOR DE CARACTERÍSTICAS SE ESTABLECE EN 1.

IMPORTANTE:

- COEFICIENTE Θ_0 EN EL PARÁMETRO DE INTERSECCIÓN O SESGO
- CUANDO EL VECTOR SE MULTIPLICA POR EL VECTOR DEL PARÁMETRO

• LA TRANSPOSICIÓN $\Theta^T X$ EN UN ESPACIO UNIDIMENSIONAL ES LA ECUACIÓN DE UNA LÍNEA:

REGRESIÓN LINEAL SIMPLE

• CUANDO TENEMOS MÁS DE UNA ENTRADA LA LÍNEA SE LLAMA: PLANO / HIPERPLANO

REGRESIÓN LINEAL MÚLTIPLE

• DEBEMOS ENCONTRAR EL HIPERPLANO QUE MEJOR SE ADAPTA A NUESTROS DATOS.

USANDO MSE PARA ENCONTRAR LOS ERRORES EN EL MODELO

$$\hat{y} = \Theta^T X$$

• CUANDO CONOCAMOS Θ^T YA
PODEMOS USAR EL MODELO Y EL CONJUNTO
DE CARACTERÍSTICAS DE CADA 1ª FILA

$$\hat{y} = 140 \rightarrow \text{PREDICCIÓN CO}_2 \text{ X}_i$$

$$y_i = 196 \rightarrow \text{VALOR REAL}$$

$$y_i - \hat{y} = 56 \rightarrow \text{ERROR RESIDUAL}$$

EL ERROR PARA UNA SGA LINEAL
COMO EN LA REGRESIÓN LINEAL SIMPLE

$$MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

→ ESTA MEDIDA
REPRESENTA

QUE TAN MAL REPRESENTA EL MODELO EL CONJUNTO
DE DATOS =

• EL OBJETIVO ES MINIMIZAR MSE •

¿CÓMO ESTIMAMOS θ ?

①

→ MÍNIMOS CUADRADOS ORDINARIOS →

⇒ INTENTAN ESTIMAR LOS VALORES DE LOS COEFICIENTES MINIMIZANDO EL ERROR CUADRÁTICO MEDIO: MSE

→ UTILIZAN LOS DATOS COMO UNA MATRIZ

→ - OPERACIONES DE ALGEBRA LINEAL

- EL PROBLEMA: COMPLEJIDAD TEMPORAL DE CÁLCULO DE LAS OPERACIONES MATRICIALES, PUEDE LLEVAR MUCHO TIEMPO.

→ CUANDO EL CONJUNTO DE DATOS ES SUPERIOR A 10.000 ESTA TÉCNICA ES UNA BUENA OPCIÓN.

②

→ ALGORITMO DE OPTIMIZACIÓN →

⇒ GRADIENTES DESCENDIENTES

→ ES ADECUADO CONJUNTO DE DATOS DE 10.000 +.

③ FASE DE PREDICCIÓN.

- ES TAN SENCILLO COMO RESOLVER LA ECUACION PARA UN CANTIDAD ESPECÍFICA DE ENTRADAS.

* PREDICCIÓNES CON LÍNEAS MÚLTIPLES.

	MOTOR	Ciudades	Consumo	CO ₂
0	2.0	4	8.5	196
1	2.4	4	9.6	221
2	1.5	4	5.9	136
3	3.5	6	11.1	255
4	3.5	6	10.6	244
5	3.7	6	10.1	230
6	2.4	4	9.2	211
7	3.7	6	11.1	255
8	3.7	6	11.6	267
9	2.4	4	9.2	?

$$\hat{y} = \theta^T X$$

$$\theta^T = [125, 6.2, 14, \dots]$$

$$\hat{y} = 125 + 6.2x_1 + 14x_2 + \dots$$

$$CO_2Em = 125 + 6.2 \text{ motor} + 14 \text{ ciudades} \dots$$

$$CO_2Em = 125 + 6.2 \times 2.4 + 14 \times 4 + \dots$$

- PREDICCIÓN
- CÁLCULO
- RESULTADO

$$CO_2Em = 125 + 6.2 \times 2.4 + 14 \times 4 \dots etc$$

$$CO_2Em = 214.1$$

PREGUNTAS SOBRE:

REGRESIÓN LINEAL MÚLTIPLE

• PODEMOS USAR MÚLTIPLES VARIABLES INDEPENDIENTES PARA PREDECIR LA VARIABLE DEPENDIENTE:

- UNO DE LOS RESULTADOS DE ESTOS MODELOS ES MEJOR QUE LA REGRESIÓN SIMPLE

• ¿CUANTAS VARIABLES DEBEMOS DE USAR PARA LA PREDICCIÓN?

- USAR VARIABLES SIN JUSTIFICACIÓN PUEDE RESULTAR UN MODELO SOBREADJUSTADO

• UN MODELO SOBREADJUSTADO ES UN VERDADERO PROBLEMA PORQUE ES DEMASIADO COMPLICADO PARA EL CONJUNTO DE DATOS Y NO ES LO SUFICIENTEMENTE GENERAL PARA UNA BUENA PREDICCIÓN.

• ES RECOMENDABLES EVITAR USAR MUCHAS VARIABLES

• SE PUEDEN UTILIZAR GRÁFICOS DE DISPERSIÓN PARA COMPROBAR VISUALMENTE LA LINEALIDAD.

• SI NO ES LINEAL, HAY QUE USAR REGRESIÓN NO LINEAL.

#####

LABORATORIO

#####

* REGRESIÓN LINEAL MÚLTIPLE *

ESTUDAR EN VIDEO => LABORATORIO 2

#####

INTRODUCCIÓN

MÓDULO 3

CLASIFICACIÓN

#####

- ES UN ENFOQUE DE APRENDIZAJE SUPERVISADO
- MEDIO PARA CATEGORIZAR O CLASIFICAR ALGUNOS ELEMENTOS DE CONOCIMIENTO EN UN CONJUNTO DISCRETO DE CLASES
- INTENTA CONOCER LA RELACIÓN ENTRE LAS VARIABLES CARACTERÍSTICAS Y LAS VARIABLES OBJETIVO DE INTERÉS.

DEL DISTRIBUTO OBJETIVO DE LA CLASIFICACIÓN ES:

VARIABLES CATEGÓRICAS CON VALORES DISCRETOS

¿CÓMO FUNCIONA LA CLASIFICACIÓN Y LOS CLASIFICADORES?

AGE	ED	EMPL	ADDRESS	INCOME	DEBT	CREDIT	OTHER	DEFAULT
41	3	17	12	176	9.3	14.359	5.009	1
27	1	10	6	31	17.3	1362	4.001	0
40	1	15	14	55	5.5	0.836	2.169	0
42	1	15	14	120	2.9	7.659	0.821	0
24	2	2	0	28	17.3	1.787	3.057	1
41	2	5	5	25	10.2	0.398	2.457	0
39	1	20	9	67	30.6	3.834	16.668	0
43	1	12	11	38	3.6	0.479	1.239	0
24	1	3	4	19	24.4	1.358	3.277	1
36	1	0	13	25	19.7	2.778	2.147	0

37	2	16	10	130	9.3	10.23	3.21	
----	---	----	----	-----	-----	-------	------	--

* PREDICCIÓN IMPAGO CREDITO *

(DATOS DE MOROSIDAD)

VARIABLE CATEGORICA

AGE	ED	EMLOY	ADDRESS	HOME	DEBIT	CREDIT	OTHER	DEFER
41	3	17	12	176	9.3	11.359	5.009	1
27	1	10	6	31	17.3	1.362	4.001	0
40	1	15	14	55	5.5	0.836	2.169	0
41	1	15	14	120	2.9	2.659	0.821	0
24	2	2	0	28	17.3	1.387	3.057	1
41	2	5	5	25	10.2	0.538	2.47	0
39	1	20	9	67	30.6	3.834	1.668	0
43	1	12	11	38	3.6	0.479	1.239	0
24	1	3	4	19	24.4	1.358	3.279	1
36	1	0	13	25	19.7	2.778	2.147	0

37	2	16	10	130	9.3	10.33	3.21	
----	---	----	----	-----	-----	-------	------	--



DADO UN CONJUNTO DE DATOS DE ENTRENAMIENTO Y UNO CON CASI
ETIQUETAS DE DESTINO, LA CLASIFICACIÓN DETERMINA LA ETIQUETA
DE CLASE PARA UN CASO DE PRUEBA EN ESTADÍSTICA.


* EJEMPLO *

- UN BUEN EJEMPLO ES LA PREDICCIÓN DE UN IMPAGO CREDITICIO:
- NOS PREOCUPA LA POSIBILIDAD DE QUE UN PRÉSTAMO NO SE REEMBOLE.
- SI LOS DATOS DE MOROSIDAD CREDITICIA SE PUEDEN UTILIZAR PARA PREDECIR QUE CLIENTES TIENEN PROBABILIDADES DE TENER PROBLEMAS PARA DEVOLVER LOS PRÉSTAMOS, ES POSIBLE SE RECHAZA SU SOLICITUD DE PRÉSTAMO O SE LES OFRECEN PRODUCTOS ALTERNATIVOS.
- EL OBJETIVO DE UN MODELO DE PREDICCIÓN DE MOROSIDAD ES USAR LOS DATOS PARA CREAR UN CLASIFICADOR.

AGE	ED	CREDIT	ADDRESS	INCOME	DEBT	CREDIT	OTHER	STATUS
41	3	17	12	176	9.3	11.359	5.001	1
27	1	10	6	31	17.3	1.362	4.001	0
40	1	15	14	55	5.5	2.186	2.169	0
41	1	15	14	120	2.9	2.691	0.871	0
24	2	2	0	28	17.3	1.353	3.052	1
41	2	5	5	25	10.2	0.198	2.471	0
39	1	20	9	67	30.6	3.839	16.09	0
43	1	12	11	38	3.6	0.071	1.259	0
24	1	3	4	19	29.4	1.359	3.277	1
36	1	0	13	25	19.2	2.778	2.471	0
37	2	16	10	180	9.3	10.25	3.21	

CATEGORICAL VARIABLES

MODELING



PREDICCIÓN

ETIQUETA PREDICIDA

◦ EL EJEMPLO ANTERIOR SE
REFIERE AL CLASIFICADOR BINARIO

0 1
CON DOS VALORES.

◦ PERO PODEMOS CREAR MODELOS
PARA LA CLASIFICACIÓN MULTICLASES.

CLASIFICACIÓN MULTICLASES

EJEMPLO



* CONJUNTOS DE DADOS DE PACIENTES QUE PADecem
 TODAS A MESMA ENFERMIDADE *

DGE	SEX	BP	CHOLESTEROL	NA	K	DRUG
23	F	HIGH	HIGH	0.773	0.039	Y
42	M	LOW	HIGH	0.735	0.056	C
47	M	LOW	HIGH	0.697	0.067	C
28	F	NORMAL	HIGH	0.564	0.072	X
61	F	LOW	HIGH	0.557	0.039	Y
22	F	NORMAL	HIGH	0.671	0.079	X
49	F	NORMAL	HIGH	0.77	0.049	Y
44	M	LOW	HIGH	0.767	0.065	C
60	M	NORMAL	HIGH	0.777	0.051	Y
43	M	LOW	NORMAL	0.526	0.077	Y

CATEGORICAL
 VARIABLE

DGE	SEX	BP	CHOLESTEROL	NA	K	DRUG
36	F	LOW	HIGH	0.697	0.069	

* DRUG: ET MEDICAMENTO AL CAC RESPONDO BEM.

DGE	SEX	BP	CHOLEST.	NU	K	DRUG
23	F	HIGH	HIGH	0.793	0.037	Y
42	M	LOW	HIGH	0.725	0.056	C
47	M	LOW	HIGH	0.694	0.069	C
28	F	NORMAL	HIGH	0.564	0.042	X
61	F	LOW	HIGH	0.559	0.077	Y
22	F	NORMAL	HIGH	0.673	0.039	X
49	F	NORMAL	HIGH	0.77	0.049	Y
44	M	LOW	HIGH	0.767	0.069	C
60	M	NORMAL	HIGH	0.773	0.051	Y
43	M	LOW	NORMAL	0.526	0.072	Y

CATEGORICAL
VARIABLE

AGE	SEX	BP	CHOLEST.	NU	K	DRUG
36	F	LOW	HIGH	0.697	0.069	


* MUESTRA DE
CLASIFICACIÓN
MULTICLASE



PREDICTED
CLASSES

MODELING

PREDICTION



CLASSIFIER


USOS EMPRESARIALES DE CLASIFICACIÓN

- * PARA PREDECIR LA CATEGORÍA A LA QUE PERTENECE UN CLIENTE
- * PARA DETECTAR LA PÉRDIDA DE CLIENTES.
SE PUEDE PREDECIR SI UN CLIENTE CAMBIA A OTRO PROVEEDOR O MARCA.
- * PARA PREDECIR SI UN CLIENTE RESPONDE O NO A UNA CAMPAÑA PUBLICITARIA CONGRUENTE.

LA CLASIFICACIÓN DE DATOS:

• VARIAS APLICACIONES EN UNA AMPLIA VARIEDAD DE SECTORES.

• MUCHOS PROBLEMAS PUEDEN SOLUCIONARSE CON ASOCIACIONES ENTRE LAS VARIABLES CARACTERÍSTICAS Y LAS VARIABLES OBJETIVO.



• ESPECIALMENTE CUANDO SE DISPONE DE DATOS ETIQUETADOS:

- FILTRAR SPAM
- RECONOCER LA VOZ
- RECONOCER LA ESCRITURA A MANO
- IDENTIFICACIÓN BIOMÉTRICA
- CLASIFICACIÓN DE DOCUMENTOS, ETC.

*CLASIFICACIÓN DE ALGORITMOS EN MACHINE LEARNING *

- DECISION TREES (ID3, C4.5, C5.0)
- NAÏVE BAYES
- LINEAR DISCRIMINANT ANALYSIS
- K-NEAREST NEIGHBOR
- LOGISTIC REGRESSION
- NEURAL NETWORKS
- SUPPORT VECTOR MACHINES (SVM)

#####

K-NEAREST NEIGHBOURS

ALGORITMO MACHINE LEARNING

MÓDULO 3

#####

INTRO TO KNN

- IMAGINA QUE UN PROVEEDOR DE TELÉFONO HA SEGMANTADO SU BASE DE CLIENTES SEGUN PATRONES DEL USO DEL SERVICIO.
- CLASIFICA A LOS CLIENTES EN 4 GRUPOS

VALUE	LABEL
1	BASIC SERVICE
2	E-SERVICE
3	PLUS SERVICE
4	TOTAL SERVICE

CON TODOS LOS DATOS DEMOGRÁFICOS LA EMPRESA PUEDE PERSONALIZAR LAS OFERTAS PARA CLIENTES POTENCIALES INDIVIDUALES.

* ESTAMOS ANTE :

PROBLEMA DE CLASIFICACIÓN

* CONJUNTO DE DATOS CON ETIQUETAS PREDEFINIDAS

* NECESITAMOS CONSTRUIR UN MODELO QUE PUEDA PREDICIR LA CLASE DE UN CASO NUEVO O DESCONOCIDO

* TENEMOS QUE CREAR UN CLASIFICADOR POR EJEMPLO :

- USAR LAS FICAS DEL ϕ AL 7 PARA PREDICIR LA FKA 8.

DEMOSTRACIÓN





REGION AGE MARITAL ADDRESS INCOME ED EMPLOY RETIRE GENDES DESIDE CLETCAT

0	2	44	1	9	64	4	5	0	0	2	1
1	3	33	1	7	136	5	5	0	0	6	4
2	3	52	1	24	146	1	29	0	1	2	3
3	2	33	0	12	33	2	0	0	1	1	1
4	2	30	1	9	30	1	2	0	0	4	3
5	2	39	0	12	39	2	16	0	1	1	3
6	3	22	1	2	19	2	4	0	1	5	2
7	2	35	0	5	26	2	10	0	0	3	4
8	3	50	1	7	166	4	31	0	0	5	?

*USAMOS SOLO DOS CAMPOS
COMO PREDICTORES:

- EDDAD
- INGRESOS

*DESPUES GRAFICAREMOS
LOS CLIENTES EN FUNCION DE
SU MEMBRERIA.

* ¿CÓMO ENCONTRAMOS LA CLASE
DE NUESTRO NUEVO CLIENTE?

Nº 8

1° → PODAMOS ASIGNAR LA CLASE
DE SU VECINO MAS CERCAÑO EN
LA GRÁFICA.


IMPORTANT

⇒ 1-NN → 4: TOTAL SERVICE
(ES EL VECINO MAS CERCAÑO)
"KNN"

1-NN = 4

TOTAL SERVICE

GRÁFICA DE
DISPERSIÓN




* ¿PODEMOS CONFIAR EN QUE NUESTRO JUICIO SE BASA EN EL VECINO MAS CERCANO?

— PUEDE SER UN MAU JUICIO SI EL VECINO MAS CERCANO ES UN CASO MUY EXCEPCIONAL O UN CASO ATÍPICO.

PARA EVITAR ESTO
ESCOGEMOS LOS 5
VECINOS MAS CERCANOS.

OBTENEMOS LA
MAYORIA DE CLASES
PARA DEFINIR
LA CLASE



ESTO TIENE
MAS SENTIDO.

5-NN → 3
PLUS SERVICE

ESTO DEMUESTRA LA
INTUICIÓN QUE SUBYACE EN KNN

DEFINICIÓN DE KNN


• ES UN ALGORITMO DE CLASIFICACIÓN QUE TOMA UN CONJUNTO DE PUNTOS ETIQUETADOS Y LOS USA PARA APRENDER A ETIQUETAR OTROS PUNTOS.



* CLASIFICA LOS CASOS EN FUNCIÓN DE SU SIMILITUD CON OTROS CASOS.

* LOS PUNTOS QUE ESTÁN CERCA SE LLAMAN VECINOS:

NEIGHBORS



* KNN SE BASA EN ESTE PARADIGMA:

- CASOS SIMILARES CON LAS MISMAS ETIQUETAS DE CASOS ESTÁN CERCA UNO DE OTROS.

- LA DISTANCIA ENTRE DOS CASOS ES UNA MEDIDA DE SU SIMILITUD

* CUALQUIER LA SIMILITUD O «A INVERSA», LA DISTANCIA O DISIMILITUD DE DOS PUNTOS DE DATOS.

↳ USANDO:

LA DISTANCIA EUCLIDIANA

* ALGORITMO KNN *

(K-NEAREST NEIGHBOURS)

1° DAR UN VALOR A K .

2° CALCULAR LA DISTANCIA DESDE EL NUEVO CASO HASTA CADA UNO DE LOS CASOS DEL CONJUNTO DE DATOS.

3° BUSCAR LAS OBSERVACIONES K EN LOS DATOS DE ENTRENAMIENTO QUE ESTEN MÁS CERCA DE LAS MEDICIONES DEL PUNTO DE DATOS DESCONOCIDO.

4° PREDECIR LA RESPUESTA DEL PUNTO DEL DATO DESCONOCIDO. UTILIZANDO EL VALOR DE RESPUESTA MÁS POPULAR DE LOS K -NEAREST NEIGHBOURS MÁS CERCANOS.

* PARTES CONFUSAS *

- 1° ¿CÓMO SELECCIONAR LA K CORRECTA?
- 2° ¿CÓMO CALCULAR LA SIMILITUD DE LOS CASOS?



* PARTES CONFUSAS *

2º - CALCULAR SIMILITUD ENTRE DOS PUNTOS DE DATOS:

* EJEMPLO ① 1 DIMENSION

- SUPONEMOS QUE TENEMOS 2 CLIENTES Y QUE SOLO TIENEN UNA CARACTERÍSTICA:
- EDAD

CLIENTE 1: 34 AÑOS

CLIENTE 2: 30 AÑOS

PODEMOS USAR FACILMENTE UN TIPO ESPECÍFICO DE DISTANCIA:

* DISTANCIA MINIKOWSKI *

$$DIS(X_1, X_2) = \sqrt{\sum_{i=1}^n (x_{1i} - x_{2i})^2}$$

(DISTANCIA EUCLIDIANA)


LA DISTANCIA ENTRE X_1 Y X_2

$$= \sqrt{(34 - 30)^2} = 4$$

* EJEMPLO (2): 2 DIMENSIONES

CLIENTE 1: 34 AÑOS - 190 INGRESOS

CLIENTE 2: 30 AÑOS - 200 INGRESOS



$$DIS (x_1, x_2) = \sqrt{\sum_{i=1}^n (x_{1i} - x_{2i})^2}$$

$$= \sqrt{(34-30)^2 + (190-200)^2} = 10.77$$

* EJEMPLO (3): MULTIDIMENSIONES



CLIENTE 1: 34 AÑOS - 190 INGRESOS - 3 EDUCACIÓN

CLIENTE 2: 30 AÑOS - 200 INGRESOS - 8 EDUCACIÓN

$$DIS (x_1, x_2) = \sqrt{\sum_{i=1}^n (x_{1i} - x_{2i})^2}$$

$$= \sqrt{(34-30)^2 + (190-200)^2 + (3-8)^2} = 11.87$$

¿CUAL ES EL MEJOR VALOR DE K?



• UN K BAJO PROVOCA UN SOBREFITTS DEL MODELO.


• SIGNIFICA QUE EL MODELO NO ESTA LO SUFICIENTEMENTE GENERALIZADO PARA PODER SER USADO EN CASOS FUERA DE LA MUESTRA.

 * FUERA DE LA MUESTRA: *
 * SON DATOS QUE ESTAN FUERA DEL *
 * CONJUNTO DE DATOS UTILIZADO PARA *
 * ENTRENAR EL MODELO. *

• EL SOBREFITTS ES MALO. PUESTO QUE QUEREMOS QUE NUESTRO MODELO GENERAL FUNCIONE CON CUALQUIER DATO. NO SOLO CON LOS DATOS UTILIZADOS EN EL ENTRENAMIENTO

• $K = 20 \rightarrow ?$

↓



• SI ELEGIMOS UN VALOR MUY ALTO DE K .
EL MODELO SE GENERALIZA DEMASIADO.

* LA SOLUCIÓN GENERAL: *

- RESERVAR UNA PARTE DE LOS DATOS PARA
PROBAR LA PRECISIÓN DEL MODELO.

- UNA VEZ HECHO ESTO:

a) $K = 1$

b) UTILIZAR LOS DATOS DEL TRAIN PARA
MODELAR

c) CALCULAR LA PRECISIÓN DE LA PREDICCIÓN
CON TODAS LAS MUESTRAS DEL CONJUNTO DE
TEST.

d) REPETIR EL PROCESO DETERMINANDO LA K

e) COMPROBAR QUE K ES LA MEJOR PARA
TU MODELO.

- EN NUESTRO EJEMPLO ES EL 4.
 $K=4 \rightarrow$ NOS DADA LA MEJOR PRECISIÓN.

*TAMBIÉN SE PUEDE USAR PARA CALCULAR
LOS VALORES DE UN OBJETIVO CONTINUO*

- KNN: SE PUEDE USAR PARA REGRESIÓN

- EN ESTA SITUACIÓN EL VALOR OBJETIVO
MEDIO O KNN MEDIO.

→ SE USA PARA OBTENER LA PREDICCIÓN
PARA EL NUEVO CASO.

• EJEMPLO:

- HAY QUE HACER LA PREDICCIÓN DEL PRECIO DE
UNA VIVIENDA EN FUNCIÓN DE SU CONJUNTO DE
CARACTERÍSTICAS.

→ - Nº HABITACIONES
- AÑO CONSTRUCCIÓN
- ETC.

- PUEDE ENCONTRAR FÁCILMENTE LOS 3
CASOS VECINOS MÁS CERCANOS, NO SOLO
EN FUNCIÓN DE DISTANCIA, SINO TAMBIÉN EN
FUNCIÓN DE TODAS LAS VARIABLES Y LUEGO
PREDICIR EL PRECIO SEGÚN TAMAÑO MEDIO DE LOS
VECINOS.

#####

MÉTRICAS DE EVALUACIÓN DE LOS CLASIFICADORES

MÓDULO 3

#####

— ESTAS MÉTRICAS EXPLICAN EL RENDIMIENTO
DE UN MODELO.

• TENEMOS UN CONJUNTO DE DATOS CON EL
HISTÓRICO QUE MUESTRA EL GIRO DE UN
CLIENTE PARA UNA EMPRESA DE SEGURO.

— HEMOS ENTRENADO EL MODELO Y AHORA
QUEREMOS CALCULAR SU PRECISIÓN USANDO
EL CONJUNTO DE TEST.

— PASAMOS EL CONJUNTO DE TEST (PRUEBA)
A NUESTRO MODELO Y OBTENDEMOS LAS
ETIQUETAS PREDICIDAS.

— ¿CÓMO SABEMOS CUÁL ES EL PROCESO?



- COMPARAR LOS VALORES REALES EN EL TEST CON LOS VALORES PREDICADOS POR EL MODELO.
- LAS MÉTRICAS DESEMPLEAN UN PAPEL CLAVE EN EL DESARROLLO DE UN MODELO
 - ↳ LAS PROPORCIONA INFO SOBRE LAS ÁREAS QUE PODRÍAN REQUIRIR MEJORA

* METRICS *

- 1º - ÍNDICE DE JACCARD
- 2º - PUNTUACIÓN F1
- 3º - LOG LOSS


* INDICE DE JACCARD *

(JACCARD INDEX)

≡ COEFICIENTE DE SIMILITUD DE JACCARD ≡

Y : ACTUAL LABELS

$\hat{Y}$: PREDICTED LABELS



$$J(Y, \hat{Y}) = \frac{|Y \cap \hat{Y}|}{|Y \cup \hat{Y}|} = \frac{|Y \cap \hat{Y}|}{|Y| + |\hat{Y}| - |Y \cap \hat{Y}|}$$

JACCARD ES EL TAMAÑO DE LA INTERSECCIÓN
DIVIDIDO POR EL TAMAÑO DE LA UNIÓN DEL
CONJUNTO DE ETIQUETAS

EJEMPLO:

- CONJUNTO DE PRUEBAS DE TAMAÑO 10
- CON 8 PREDICIONES CORRECTAS U 8 INTERSECCIONES

$Y: [0, 0, 0, 0, 0, 1, 1, 1, 1, 1]$

$\hat{Y}: [1, 1, 0, 0, 0, 1, 1, 1, 1, 1]$



$$J(Y, \hat{Y}) = \frac{8}{10 + 10 - 8} = 0.66$$

* LA PRECISION DE JACCARD ES: 0.66

* SI TODO EL CONJUNTO DE PREDICTED LABELS PARA UNA MUESTRA COINCIDE Estrictamente con el conjunto REAL (Actual Labels):

* DE LO CONTRARIO:

→ 0.0

↓
 $J(Y, \hat{Y}) = 1.0$


=====

* MATRIZ DE CONFUSIÓN *

(F1-SCORE)

≡ CONFUSION MATRIX ≡

- SUPONGAMOS QUE NUESTRO CONJUNTO DE TEST TIENE SOLO 40 FILAS



* ESTA MATRIZ MUESTRA PREDECIONES CORRECTAS E INCORRECTAS EN COMPARACION CON LAS TRUE LABELS

- LA PRIMERA FILA ES PARA CLIENTES CUYO VALOR REAL DE CHURN EN EL CONJUNTO DE PRUEBA ES 1.
- COMO PODEMOS CALCULAR 40 CLIENTES EL VALOR DE CHURN DE 15 DE ELLOS ES 1.
- DE ESOS 15: PREDITO BIEN 6 COMO 1 Y 9 COMO 0.

• ESTO SIGNIFICA QUE PARA 6 CLIENTES, EL VALOR DE CHURN REAL ERA 1, EN EL CONJUNTO DE PRUEBA, Y EL CLASIFICADOR TAMBIÉN PREDIJO BIEN LOS 6 COMO 1.

• SIN EMBARGO: MIENTRAS QUE LA ETIQUETA REAL DE 9 CLIENTES ERA 1 EL CLASIFICADOR PREDIJO 0.

↳ PODEMOS CONSIDERAR ESTO COMO UN ERROR DEL MODELO PARA LA 1ª FICHA.

* LOS CLIENTES CON VALOR REAL 0 DE LA SEGUNDA FICHA SON 25.
EL CLASIFICADOR PREDIJO BIEN 24 Y UNO DE ELLOS COMO 1.

↳ ESTA PREDICCIÓN ES OK.

IMPORTANTE:

LA MATRIZ DE CONFUSIÓN NOS MUESTRA LA CAPACIDAD DEL MODELO PARA PREDICAR O SEPARAR CORRECTAMENTE LAS CLASES.

• EN EL CASO ESPECÍFICO DE UN CLASIFICADOR BINARIO COMO ESTE EJEMPLO:

- PODEMOS INTERPRETAR ESTOS NÚMEROS COMO EL RECuento DE:

- VERDADEROS POSITIVOS $\rightarrow$ TP
- FALSOS NEGATIVOS $\rightarrow$ FN
- VERDADEROS NEGATIVOS $\rightarrow$ TN
- FALSOS POSITIVOS $\rightarrow$ FP

• BASÁNDONOS EN EL RECuento DE CADA SECCIÓN, PODEMOS CALCULAR LA PRECISIÓN Y LA RECUPERACIÓN DE CADA ETIQUETA.

* LA PRECISIÓN ES UNA MEDIDA DE LA PREDICCIÓN *

$$\bullet \text{PRECISION} = TP / (TP + FP)$$

$$\bullet \text{RECALL} = TP / (TP + FN)$$

$\rightarrow$ ES LA VERDADERA TASA POSITIVA

CONFUSION MATRIX

TRUE LABEL γ	CHURN = 1	6	9
	CHURN = 0	1	24
		CHURN = 1	CHURN = 0
		PREDICTED LABEL $\hat{\gamma}$	

20
15
10
5

- $\text{PRECISION} = \text{TP} / (\text{TP} + \text{FP})$
- $\text{RECALL} = \text{TP} / (\text{TP} + \text{FN})$
- $\text{F1-SCORE} = 2 \times (\text{PRC} \times \text{REC}) / (\text{PRC} + \text{REC})$ ✗

	PRECISION	RECALL	F1-SCORE
CHURN = 0	0.73	0.96	0.83
CHURN = 1	0.86	0.40	0.55

PRECISION MEDIA = 0.69

* F1-SCORE *

ES EL PROMEDIO ARMÓNICO DE LA
PRECISION Y EL RECALL.
DONDE F1 SU MEJOR VALOR ES 1 Y PEOR 0.

* PÉRDIDA LOGARÍTMICA *

(LOG LOSS)

≡ MIDE EL RENDIMIENTO DE CLASIFICADOR ≡
DE PROBABILIDADES ENTRE 0 y 1.


A VECES LA SALIDA DE CLASIFICADOR
ES LA PROBABILIDAD DE UNA ETIQUETA
DE CLASE EN LUGAR DE LA ETIQUETA

* EJEMPLO:

↳ EN REGRESIÓN LOGÍSTICA, LA SALIDA
PUEDE SER LA PROBABILIDAD DE
PÉRDIDA DEL CLIENTE

AGE	SEX	BP	CHLORSTE.	LDL	K	CHURN
23	F	HIGH	HIGH	0.753	0.031	1
42	M	LOW	HIGH	0.737	0.056	1
47	M	LOW	HIGH	0.695	0.067	0
28	F	NORMAL	HIGH	0.564	0.022	0
61	F	LOW	HIGH	0.559	0.078	0
22	F	NORMAL	HIGH	0.573	0.039	1
49	F	NORMAL	HIGH	0.77	0.049	0
44	M	LOW	HIGH	0.762	0.057	1
60	M	NORMAL	HIGH	0.772	0.051	0
43	M	LOW	NORMAL	0.526	0.072	1

TEST



↓
ACTUAL LABELS
Y

PREDICTED CHURN
0.91
0.13
0.04
0.23
0.43
...

PREDICTED PROBABILITY

ŷ

* ECUACIÓN LOG LOSS *

$$-(y \times \log(\hat{y}) + (1-y) \times \log(1-\hat{y})) \quad (1)$$

• POR AHORA CALCULAREMOS LA PÉRDIDA DE LOG PARA CADA FILA QUE MIDE CUÁN LEJOS ESTÁ NUESTRA PREDICCIÓN DE LA REALIDAD:

PREDICTED CHURN	log loss
0.91	0.094 <=
0.13	0.89 ✗
0.04	0.04 <=
0.23	0.26
0.43	0.56
...	

(2)

$$\log \text{loss} = 0.60$$

$\hat{y}$ PREDICTED PROBABILITY

$$\log \text{loss} = -\frac{1}{n} \sum (y \times \log(\hat{y}) + (1-y) \times \log(1-\hat{y}))$$

• CALCULAMOS LA PÉRDIDA PROMEDIO EN TODAS LAS FILAS DEL CONJUNTO DE PRUEBAS.

#####

LABORATORIO

#####

* LABORATORIO KNN *

ESTUDAR EN VISUAL => LABORATORIO 3

#####

INTRODUCCIÓN

MÓDULO 3

DECISION TREES

#####

TRAZAR TODOS LOS CAMINOS DE DECISION POSIBLES EN FORMA DE ARBOL

≡ ¿CÓMO CONSTRUIR UN DECISION TREE? ≡

* CONSULTAS DE DATOS DE PACIENTES QUE PADECEN TODAS LA MISMA ENFERMEDAD *

AGE	SEX	BP	CHOLEST.	LDL	K	DRUG
23	F	HIGH	HIGH	0.793	0.039	A
42	M	LOW	HIGH	0.739	0.056	A
47	M	LOW	HIGH	0.694	0.069	B
28	F	NORMAL	HIGH	0.564	0.042	B
61	F	LOW	HIGH	0.559	0.079	B
22	F	NORMAL	HIGH	0.691	0.079	A
49	F	NORMAL	HIGH	0.77	0.049	B
44	M	LOW	HIGH	0.762	0.069	A
60	M	NORMAL	HIGH	0.772	0.051	B
43	M	LOW	NORMAL	0.516	0.072	A

CATEGORICAL
VARIABLE

AGE	SEX	BP	CHOLEST.	LDL	K	DRUG
36	F	LOW	HIGH	0.697	0.069	

* DRUG: EL MEDICAMENTO AL CUAL RESPONDIÓ BIEN.

* CREAR UN MODELO PARA DETERMINAR
QUE FÁRMACO SERÍA EL ADECUADO
PARA UN FUTURO PACIENTE CON
LA MISMA ENFERMEDAD

• CARACTERÍSTICAS:

- EDAD.
- SEXO.
- PRESIÓN ARTERIAL (BP).
- COLESTEROL.

• OBJETIVO:


- EL FÁRMACO AL QUE RESPONDIÓ CADA PACIENTE.

• ES UN EJEMPLO DE CLASIFICADORES
BINARIOS Y PUEDE UTILIZAR LA PARTE
DE ENTRENAMIENTO DEL CONJUNTO DE
DATOS PARA CREAR UN DECISION TREE.

CONSTRUIR DECISION TREE CON CONJUNTO DE ENTRENAMIENTO (TRAINING TEST) ←


SE CREA DIVIDIENDO EL TRAINING TEST EN
MUCHOS DIFERENTES.

△ DRUG B
○ DRUG A




CLASIFICADOR DE PACIENTES.

- DONDE UN NUDO CONTIENE LA TOTALIDAD O MAYOR PARTE DE UNA CATEGORIA DE DATOS.



* Podemos construir el árbol considerando los atributos uno por uno.

1. ELEGIR UN ATRIBUTO PARA TU DATASET.
2. CALCULAR LA IMPORTANCIA EN LA DIVISION DE DATOS : (SPITTING OF DATA).
3. SPLIT DATA BASED. DIVIDIR LOS DATOS SEGUN EL VALOR DEL MEJOR ATRIBUTO.
4. GO TO STEP 1. (REPETIR EN CADA RAMA).



CLASIFICADOR DE PACIENTES.

#####

CONSTRUIR

MÓDULO 3


DECISION TREES

#####


* SE CREAN UTILIZANDO PARTICIONES RECURSIVAS PARA CLASIFICAR LOS DATOS.

⇒ ¿CUÁL ES EL MEJOR ATRIBUTO?

- SUJITOS QUE TENEMOS 14 PACIENTES EN NUESTRA BASE DE DATOS.
- EL ALGORITMO ELIGE LA CARACTERÍSTICA MÁS PREDICTIVA PARA DIVIDIR LOS DATOS.
- ELEGIMOS COLESTEROL COMO PRIMER ATRIBUTO PARA DIVIDIR LOS DATOS.




• DIVIDIR LOS DATOS EN DOS PARTES: ALTO Y NORMAL



- SOLO CON HIGH NO PODAMOS PREDECIR CON ALTA CONFIANZA QUE EL MEDICAMENTO B PODRÍA SER EL ADECUADO PARA EL.


- SOLO CON NORMAL NO TENEMOS SUFICIENTE EVIDENCIA O INFORMACIÓN PARA DETERMINAR SI EL MEDICAMENTO B O A ES DE HECHO EL ADECUADO.



HUESTRAS MUY POCAS PARA DIVIDIR DATOS (SPILT)

△ DRUG B
○ DRUG A

• USAMOS EL DIFERENTE SEXO:



- F: DRUG B CON ALTA CERTeza

- M: DRUG A CON BAJA CERTeza.

* MEJOR OPCIÓN QUE COLESTEROL.

• POR LO TANTO EL NUDO SEX ES MAS SIGNIFICATIVO QUE COLESTEROL, ES MAS PREDICTIVO QUE LOS OTROS ATRIBUTOS.


- MAS PREDICTIVO
- DISTINCIÓN DE LA IMPUREZA DE LOS NODOS
- LOWER ENTROPY

• AÑADIMOS A SEX EL ATRIBUTO DE COLESTEROL

IMPORTANTE:



* UN NUDO ES PURO SI EN EL

100% DE LOS CASOS
LOS NODOS CAEN A
UNA CATEGORÍA
ESPECÍFICA DEL CAMPO
DE DESTINO *



→
- AHORA SI PODEMOS
TOMAR FACILMENTE
UNA DECISIÓN

* AHORA NUDO
COLESTEROL ES
MAS PURO:



ENTROPY = ? ENTROPY = ?

- EL MÉTODO USÓ PARTICIONES RECURSIVAS PARA DIVIDIR LOS REGISTROS DE ENTRENAMIENTO EN SECCIONES MINIMIZANDO LA IMPUREZA EN CADA CASO.
- LA IMPUREZA DE LOS NODOS SE CALCULA MEDIANTE LA ENTROPÍA DE LOS DATOS DEL NODO.

¿QUÉ ES LA ENTROPÍA?

- LA CANTIDAD DE TRASTORNO DE LA INFORMACIÓN O CANTIDAD DE INCERTIDUMBRE EN LOS DATOS.
- LA ENTROPÍA EN EL NUDO DEPENDE DE CUANTOS DATOS HAY EN ESE NUDO Y SE CALCULA PARA CADA NUDO.


△ DRUG B 7
○ DRUG A 1



ENTROPY LOW



△ DRUG B 3
○ DRUG A 5



ENTROPY HIGH



△ DRUG B ?
○ DRUG A 0

ENTROPY = 0



△ DRUG B 4
○ DRUG A 4

ENTROPY = 1



- EN LAS DECISION TREE BUSCAMOS ÁRBOLES QUE TENGAN LA ENTROPÍA MÁS BAJA EN SUS NUDOS.
- LA ENTROPÍA SE USA PARA CALCULAR LA HOMOGENEIDAD DE LAS MUESTRAS CON CADA NUDO.

● CALCULO ENTROPY DE UN NODO ●

≡ TABLA DE FRECUENCIAS ≡

$$\text{ENTROPY} = -p(A) \log_2(p(A)) - p(B) \log_2(p(B))$$


P → LA PROPORCIÓN DE UNA CATEGORÍA (MEDICAMENTO)
A B

EJEMPLO:

• VAMOS A CALCULAR LA ENTROPÍA DEL CONJUNTO DE DATOS ANTES DE DIVIDIRLO:

DGE	SEX	BP	CHOLESTR.	LDL	K	DRUG
23	F	HIGH	HIGH	0.793	0.031	A
42	M	LOW	HIGH	0.735	0.056	A
47	M	LOW	HIGH	0.694	0.067	B
28	F	NORMAL	HIGH	0.564	0.021	B
61	F	LOW	HIGH	0.559	0.079	B
22	F	NORMAL	HIGH	0.631	0.039	A
49	F	NORMAL	HIGH	0.77	0.049	B
44	M	LOW	HIGH	0.763	0.065	A
60	M	NORMAL	HIGH	0.773	0.051	B
43	M	LOW	NORMAL	0.526	0.072	A

$$E = 0.940$$



S: [9B, 5A]



$$E = -p(A) \log_2(p(A)) - p(B) \log_2(p(B))$$

$$E = -(9/14) \log_2(9/14) - (5/14) \log_2(5/14)$$

$$E = 0.940$$

• AHORA PODEMOS PROBAR DIFERENTES ATRIBUTOS PARA VER EL MAS PRECISIVO

AGE	SEX	BP	CHOLESTR.	LDL	K	DRUG
23	F	HIGH	HIGH	0.793	0.034	A
42	M	LOW	HIGH	0.735	0.056	A
47	M	LOW	HIGH	0.694	0.067	B
28	F	NORMAL	HIGH	0.564	0.022	B
61	F	LOW	HIGH	0.559	0.079	B
22	F	NORMAL	HIGH	0.573	0.039	A
49	F	NORMAL	HIGH	0.77	0.049	B
44	M	LOW	HIGH	0.763	0.055	A
60	M	NORMAL	HIGH	0.772	0.051	B
43	M	LOW	NORMAL	0.526	0.072	A



¿CUAL ES EL NODO CON MAYOR GANCHO DE INFORMACIÓN?

→ (LA INFORMACIÓN QUE SE OBTIENE AL AUMENTAR EN NIVEL DE CERTIDUMBRE DESPUES DE LA DIVISION).

INFORMATION GAIN = (ENTROPY BEFORE SPLIT) - ENTROPY AFTER SPLIT

* CONSTRUIR UN DECISION TREE ES:

- ENCONTRAR ATRIBUTOS QUE DISMINUIAN LA MAYOR GANANCIA DE INFORMACIÓN.

AGE	SEX	BP	CHOLESTR.	LDL	K	DRUG
23	F	HIGH	HIGH	0.773	0.037	A
42	M	LOW	HIGH	0.735	0.056	A
47	M	LOW	HIGH	0.697	0.067	B
28	F	NORMAL	HIGH	0.564	0.022	B
61	F	LOW	HIGH	0.559	0.077	B
22	F	NORMAL	HIGH	0.577	0.039	A
49	F	NORMAL	HIGH	0.77	0.049	B
44	M	LOW	HIGH	0.767	0.059	A
60	M	NORMAL	HIGH	0.777	0.051	B
43	M	LOW	NORMAL	0.526	0.072	A

$S: [9B, 5A]$

$E = 0.940$



CHOLESTEROL

NORMAL

HIGH

$S: [6B, 2A]$

$S: [3B, 3A]$

$E = 0.811$

$E = 1.00$

$GAIN(S, cholesterol)$

$= 0.048$

$S: [9B, 5A]$

$E = 0.940$



SEX

M

F

$S: [3B, 4A]$

$S: [6B, 1A]$

$E = 0.985$

$E = 0.592$


$GAIN(S, sex)$

$$= 0.940 - [(7/14)0.985 + (7/14)0.592]$$

$$= 0.151$$



*YA TENEMOS NUESTRO COMIENZO
CORRECTO DEL DECISION TREE.



• PODEMOS REPETIR EL PROCESO PARA
CADA RAMA Y PROBAR CADA UNO DE
LOS OTROS ATRIBUTOS PARA SEGUIR ALCANZANDO
LAS HOJAS MAS PURAS.

• ESTA ES LA FORMA EN LA QUE
SE CONSTRUYE UN ARBOL DE DECISIONES.

#####

LABORATORIO

#####

* LABORATORIO ARBOL DE DECISIONES *

ESTUDAR EN VISUALC => LABORATORIO 4

#####

LABORATORIO II

#####

* LABORATORIO CREDIT CARD FRAUD DETEC *

ESTUDAR EN VIDEO => LABORATORIO 5
OPTIONAL

* IMPORTANTE:

— Librerías:

- SCIKIT-LEARN
- SNAP ML

* SNAP ML: LIBRERÍA DE IBM DE ALTO
(IBM) RENDIMIENTO PARA EL
MODELADO DE ML.

- PROPORCIONA IMPLEMENTACIONES DE CPU/GPU ALTAMENTE EFICIENTES DE MODELOS LINEALES Y BODAS EN DEBODAS.
- NO SOLO DEBODA LOS ALGORITMOS ML, TIENE SUS PROPIOS ALGORITMOS.

#####

ARBOLES DE

MÓDULO 3

REGRESIÓN

REGRESIÓN TREE

#####

LOS ARBOLES DE DECISION SE USAN PARA
LA CLASIFICACIÓN, PERO TAMBIÉN PUEDE
USARSE PARA LA REGRESIÓN.


• IDEA BÁSICA:

- DIVIDIR LOS DATOS EN GRUPOS BASADOS EN
CARACTERÍSTICAS COMO ES LA CLASIFICACIÓN
Y DESPUÉS UNA PREDICCIÓN QUE SEA
LA MEDIA DE LOS DATOS QUE YA HEMOS VISTO

* LOS DATOS DE
VIVIENDA DONDE
UTILIZAMOS LO COMO
DATA PREDICAR EL
PRECIO:


AGE $\longrightarrow$ PRICE

HOUSING PRICE DATA



• CUANTOS HEMOS DE LOS MAYOR
PRECIO.

• CON ESTAS DATAS PODEMOS CREAR
UN ESTO PARA DESELECCION:



	AGE	PRICE
0	1	515550.73
1	2	491775.93
2	5	457544.34
3	7	506443.94
4	7	524594.98
5	15	368796.62
6	39	362740.81
7	45	411260.00
8	32	390396.54
9	21	94761.54
10	55	115335.98
11	64	73278.04
12	75	116153.90
13	62	361462.41
14	79	135407.55



* UTILIZAMOS LAS CARACTERÍSTICAS
Agrupar las cosas y luego
CALCULAMOS EL PRECIO MEDIO
DE ESTAS AGRUPACIONES.

• CRITERIO:

LA FORMA EN QUE SE CONSTRUYEN ES SIMILAR
PERO EN LUGAR DE USAR EL CRITERIO DE
ENTROPÍA. ELEGIMOS LAS CARACTERÍSTICAS
QUE DIFERENCIEN LA COMPOSICIÓN DE INFO.

- CARACTERÍSTICAS QUE MINIMIZEN EL ERROR.

↳ ERROR ABSOLUTO MEDIO:

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$

¿CÓMO SE CONSTRUYEN?

	AGE	PRICE	NEAR WATER
0	1	515550.73	NO
1	2	491775.93	NO
2	5	457544.34	NO
3	7	506443.94	NO
4	7	524594.98	NO
5	15	368796.62	YES
6	39	367740.84	YES
7	45	411260.00	YES
8	32	390396.54	YES
9	21	94761.54	YES
10	55	115555.98	YES
11	64	73275.04	NO
12	75	116153.90	NO
13	62	361462.41	YES
14	79	135408.55	YES

1. DECIDIR LA PRIMERA DECISIÓN USANDO EL CRITERIO Y COMPARANDO CADA UNA DE LAS CARACTERÍSTICAS DEL CONJUNTO PARA VER CUAL PRODUCE EL ERROR MÍNIMO.

2. CARACTERÍSTICAS CATEGÓRICAS:
(SI/NO)

3. NEAR WATER



* CATEGORÍA 'NO': *

- INDICES CASAS NO = $[0, 1, 2, 3, 4]$
- PRECIOS " " = $[260831, 222937 \dots]$
- PRECIO MEDIO $\bar{y} = 191479.05$
- MAE 'NO' = $[39534.41569 \dots]$

* CATEGORÍA 'SI': *

- INDICES CASAS SI = $[5, 6, 7, 8, 9]$
- PRECIOS " " = $[260831, 459917 \dots]$
- PRECIO MEDIO $\bar{y} = 285063.11$
- MAE 'SI' = $[32460, 36978 \dots]$

* MAE *

- ES EL MAE DE LA CARACTERÍSTICA 'NEW WATER' Y SE USA PARA COMPARARLO CON LOS OTROS MAE. ESTABLECIENDO LA DECISIÓN DEL ÁRBOL DE REGRESIÓN:

$$MAE = 66383.17$$

* CARACTERÍSTICAS NUMÉRICAS *

- COMO "EODD" ES MAS DIFICIL DE MANEJAR PORQUE HAY QUE ENCONTRAR UN N°. POR EL QUE DIVIDIR LOS DATOS.
- CREAR UN LIMITE EN CADA PUNTO Y CALCULAR EL ERROR.

$E \cong H^2_0$:

- PRIMER LIMITE EDDO ENTRE 0 y 10 años
 - REDUCIENDO PASOS SUERTE.
 - NÚMERO = ...
 - PRECIO = ...
 - PROBABILIDAD = ...
 - MÁS = ...
- CONTINUAMOS CON LOS CORREOS
10 y 50 → < 50 = MÁS
└─ > 50 = MENOS

VER PDF. 

Árboles de regresión

Como ya hemos visto, los árboles de decisión pueden utilizarse para la clasificación, pero también podemos utilizarlos para la regresión, comúnmente llamados árboles de regresión.

La idea básica de los árboles de regresión es dividir nuestros datos en grupos basados en características, como en la clasificación, y devolver una predicción que sea la media de los datos que ya hemos visto.


Consideremos los datos de vivienda que aparecen a continuación, en los que estamos utilizando la "Edad" para predecir el "Precio" de una casa.

	Age	Price
0	1	515550.73
1	2	491775.83
2	5	457544.34
3	7	506443.94
4	7	524594.98
5	15	368796.62
6	39	362740.81
7	45	361467.51
8	32	411260.00
9	21	390396.54
10	55	94761.54
11	64	115555.98
12	75	73275.04
13	62	116153.90
14	79	135408.55

Aquí podemos ver la diferencia que tiene la edad en el precio de la vivienda. Las edades entre 0 y 10 años tienen un precio medio de aproximadamente 500.000 dólares, las edades entre 10 y 50 años tienen un precio medio de aproximadamente 380.000 dólares y las casas de más de 50 años tienen un precio medio de aproximadamente 100.000 dólares. Utilizando estos rangos generales, podemos predecir el precio de una casa.



Utilizando los datos anteriores, podemos crear el árbol de regresión, como se muestra a continuación. Los precios se determinaron calculando el precio medio de las casas en el rango de edad.



Como puede ver, utilizamos las características para agrupar las casas y luego calculamos el precio medio en estas agrupaciones.

Criterio

La forma en que se construyen los árboles es similar a la clasificación, pero en lugar de utilizar el criterio de entropía. En los árboles de clasificación, elegimos características que aumenten la ganancia de información. En los Árboles de Regresión, elegimos características que minimicen el error.

Una muy popular es el Error Absoluto Medio, que también hemos visto anteriormente.

$$MAE = \frac{1}{n} \sum_{j=1}^n |y_j - \hat{y}_j|$$

¿Cómo se construyen los árboles de regresión?

Tomemos la muestra del conjunto de datos que se muestra a continuación, el primer paso es decidir cuál es la primera decisión. Para ello, utilizaremos el criterio y comprobaremos cada una de las características del conjunto de datos para ver cuál produce el error mínimo.

	Near Water	Age	Price
0	No	0	260831.34
1	No	45	222939.35
2	No	60	101882.10
3	No	20	226868.52
4	No	90	94868.94
5	Yes	100	197703.55
6	Yes	5	347982.98
7	Yes	10	343150.38
8	Yes	55	206713.16
9	Yes	25	329768.77

Características categóricas

Las características categóricas son sencillas, aquí tenemos Agua cercana, así que todo lo que tenemos que hacer es calcular el error si utilizamos ésta como primera característica. La característica Cerca del agua tiene dos categorías: 'Sí' y 'No', por lo tanto, debemos calcular el 'Precio' medio de las casas en las categorías 'Sí' y 'No'. A continuación, utilizamos esos valores para calcular el error medio.

categoría 'No':

- Índice de casas en la categoría 'No' = [0, 1, 2, 3, 4]
- Precios de las casas en la categoría 'No' = [260831,34, 222939,35, 101882,1, 226868,52, 94868,94]
- Precio medio de las casas en la categoría 'No' = 181478,05
- Error absoluto = [79353,29, 41461,30, 79595,95, 45390,47, 86609,11]

categoría 'Sí':

- Índice de Casas en Categoría 'Sí' = [5,6,7,8,9]
- Precios de las casas en la categoría "Sí" = [197703,55, 347982,98, 343150,38, 206713,16, 329768,77]
- Precio medio de las casas en la categoría 'Sí' = 285063,77
- Error absoluto = [87360,22, 62919,22, 58086,61, 78350,61, 44705,00]

MAE


Este es el MAE de la característica Agua cercana, y este número se utilizará para compararlo con el MAE de todas las demás características y determinar cuál es la más baja. Por lo tanto, establecerá la primera decisión en nuestro árbol de regresión.

MAE = 66383,17

Características numéricas

Las características numéricas, como "Edad", son más difíciles de manejar porque tenemos que encontrar un número, en lugar de utilizar una categoría, por el que dividir los datos. Para ello, creamos un límite entre cada punto y, a continuación, calculamos el error.

Por ejemplo, primero creamos el límite entre los dos primeros puntos de datos, que son (0, 260831,34) y (5, 347982,98), por lo que creamos un límite de $x = 2,5$ (El punto medio entre el componente x de los dos primeros puntos de datos). Ahora hallamos el precio medio de las casas a la izquierda y a la derecha de esta frontera y lo utilizamos para calcular el MAE.



Izquierda:

Índice de casas en el lado izquierdo = [0] Precios de las casas del lado izquierdo = [260831,34] Precio medio de las casas del lado izquierdo = 260831,34 Error absoluto = [0]

Derecha

Índice de Casas del Lado Derecho = [1, 2, 3, 4, 5, 6, 7, 8, 9] Precios de las Casas en la Categoría Derecha = [222939,35, 101882,1, 226868,52, 94868,94, 197703,55, 347982,98, 343150,38, 206713,16, 329768,77] Precio medio de la vivienda en la categoría correcta = 230208,64 Error absoluto = [7269,29, 128326,54, 3340,12, 135339,7, 32505,09, 117774,34, 112941,74, 23495,48, 99560,13]


MAE

Ahora podemos hallar el MAE, utilizando los errores absolutos de los lados izquierdo y derecho.


MAE = 66055,24

Pasos posteriores

A continuación se repite este proceso para cada límite entre cada par de puntos consecutivos.



El resultado es el siguiente MAE para cada límite:




Donde los valores para los puntos son:

(2.5, 66055.24) (7.5, 60871.09) (15, 50847.52) (22.5, 57918.2) (35, 49726.55) (50, 51792.86) (57.5, 51288.06) (75, 62616.49) (95, 66568.42)

Podemos ver que el límite 35 da como resultado el MAE más bajo en esta característica.

Elección de la decisión

Ahora, comparamos el MAE categórico y el MAE numérico más bajo, en este caso, el categórico es 66055,24, y el numérico es 49726,55. Así pues, para la primera decisión, utilizaremos la característica numérica "Edad". Terminamos con un árbol de regresión que tiene este aspecto:



¿Cuándo nos detenemos?

Con el árbol de regresión anterior, tenemos dos opciones, podemos detenernos aquí y utilizar el valor medio del 'Sí' (izquierda) y del 'No' (derecha) para predecir los precios de la vivienda, o podemos seguir añadiendo más decisiones a cualquiera de las ramas. Existen algunas condiciones que se utilizan habitualmente para detener el crecimiento de los árboles de regresión:

- Profundidad del árbol - Número de muestras restantes en una rama - Número de muestras en cada rama si se toma otra decisión

La profundidad del árbol anterior, es 1, porque hay una sola decisión y el número de muestras en cada lado es 5. Añadamos más decisiones hasta que la profundidad del árbol sea 2. Primero, empezamos con el lado 'Sí' (izquierdo) y calculamos el MAE para las características utilizando las casas que tienen 'Edad' < 35.

Añadir decisiones

Izquierda


Como antes, utilizamos la característica Cerca del agua y calculamos el MAE en las casas con índice 0, 3, 6, 7 y 9.

Características categóricas

MAE = 11005,34

Características numéricas

Ahora, hallamos el MAE para los límites en la característica 'Edad'.



Podemos ver que la característica Cerca del agua hace que el MAE sea más bajo en el lado 'S' (izquierdo) del árbol de regresión, por lo que añadiremos una decisión para la característica Cerca del agua.


Derecha

Ahora encontraremos las características que dan lugar al MAE más bajo de las casas con índice 1, 8, 2, 4 y 5.

Características categóricas


MAE = 35018,94

Características numéricas



Aquí también podemos ver que la característica 'Edad' dará como resultado el MAE más bajo con el límite fijado en 57,5, por lo que en el lado 'No' (derecho) del árbol, añadiremos otra decisión para la característica 'Edad'.

Resultado final



#####

LABORATORIO

#####

* LABORATORIO ARBOL REGRESIÓN *

ESTUDAR EN VÍDEO => LABORATORIO 5

#####

REGRESIÓN LOGÍSTICA

MÓDULO 4

INTRO TO LOGISTIC REGRESSION

#####

OSE USA PARA LA CLASIFICACIÓN.

- ES UNA TÉCNICA ESTADÍSTICA Y DE ML
PARA CLASIFICAR LOS REGISTROS. EN
FUNCIÓN DE LOS VALORES DE LAS CARACTERÍSTICAS DE ENTRADA.

	TELEF	AGE	ADDRESS	MEANS	ED	STADY	EQUIP	COLORADO	WIDOWS	CHURN
0	11.0	38.0	7.0	136.0	5.0	5.0	0.0	1.0	1.0	YES
1	33.0	33.0	12.0	83.0	2.0	0.0	0.0	0.0	0.0	YES
2	13.0	30.0	9.0	30.0	1.0	2.0	0.0	0.0	0.0	NO
3	39.0	35.0	5.0	76.0	2.0	10.0	1.0	1.0	1.0	NO
4	7.0	35.0	14.0	80.0	2.0	15.0	0.0	1.0	0.0	?

¿QUÉ CLIENTE PODRÍA CAUSAR
BAJO EL MES QUE VIENE?

• TENER MAS UNO MUESTRO DE DATOS HISTÓRICOS DE CUÉNTOS.

• CADA FILA REPRESENTA UN CUÉNTO

= 1 ##### ~~#####~~ ##### = 1

• TENER QUE DIFERENCIAR QUE CUÉNTOS SE QUEDA, QUIEN SE VA Y POR QUÉ.

= 1 ##### ~~#####~~ ##### = 1

* LA REGRESIÓN LOGÍSTICA ES MÚLTIPLO A LA REGRESIÓN LINEAL. PERO INTENTO PREDECIR UN CUÉNTO CATEGÓRICO O DISCRETO EN LUGAR DE UNO NUMÉRICO *

- SE PREDECEN UNA VARIABLE VALEND:

- YES/NO
- TRUE/FALSE.
- ETC

- LOS CUÉNTOS SE PUEDEN CODIFICAR CON 1/0.

• LAS VARIABLES INDEPENDIENTES TIENEN QUE SER CONTINUAS.

● SI SON CATEGÓRICOS:

- DEBEREN SER FICTICIOS
- CODIFICADOS COMO INDICADORES.

→ TEMENOS QUE TRANSFORMARLOS EN UN VALOR CONTINUO.

* APLICACIONES *

- PROBABILIDAD DE QUE UN PERSONA SUFRA UN INFARTO EN UN PERÍODO DE TIEMPO ESPECÍFICO.
- PROBABILIDAD DE MUERTE DE UN PACIENTE POR UNA ENFERMEDAD DETERMINADA.
- PROBABILIDAD DE QUE UN CLIENTE COMPRA UN PRODUCTO O CANCELE UNA SUSCRIPCIÓN.
- PROBABILIDAD DE FALLO DE UN PROCESO
- PROBABILIDAD DE PAGAR UNA HIPÓTESA

- NO SOLO PREDECIMOS LA CLASE DE CADA CASO, SI NO QUE MEDIMOS LA PROBABILIDAD DE QUE UN CASO PERTENEZCA A UNA CLASE ESPECÍFICA.

* ALGORITMOS DE MÁQUINA *

$\Rightarrow$ ⁰ ¿CUANDO USAR REGRESIÓN LOGÍSTICA? $\Leftarrow$

• CUANDO EL OBJETIVO ES:

- 0/1, YES/NO, TRUE/FALSE

• CUANDO NECESITAS UNA PROBABILIDAD

• SI SUS DATOS PUEDEN SEPARARSE LINEALMENTE

- LÍNEA


- PLANO

- HIPERPLANO

• SI NECESITAS COMPRENDER

EL IMPACTO DE UNA

FUNCIÓN. **



$$\theta_0 + \theta_1 x_1 + \theta_2 x_2 > 0$$

******: PUEDE SELECCIONAR LOS MEJORES CARACTERÍSTICAS EN FUNCIÓN DE LA SIGNIFICACIÓN ESTADÍSTICA DE LOS COEFICIENTES O PARÁMETROS DEL MODELO DE REGRESIÓN LOGÍSTICA:



TRAS ENCONTRAR LOS PARÁMETROS ÓPTIMOS, UNA ENTIDAD X CON UN PESO θ_{theta} $\uparrow$ PROXIMO A 0. TIENE UN EFECTO MENOR EN LA PREDICCIÓN QUE LAS ENTIDADES CON VALORES ABSOLUTOS ALTOS DE θ_{theta} .

- NOS PERMITE COMPARAR EL IMPACTO QUE TIENE UNA VARIABLE INDEPENDIENTE SOBRE LA DEPENDIENTE Y, AL MISMO TIEMPO, CONTROLAR OTRAS VARIABLES INDEPENDIENTES.

X										Y
TELNO	ASE	ADDRESS	NRKMS	ED	ETARY	EQUIP	CDKCARD	WIBSCESS	CHAPN	
0	11.0	33.0	7.0	136.0	5.0	5.0	0.0	1.0	1.0	YES
1	33.0	33.0	12.0	83.0	2.0	0.0	0.0	0.0	0.0	YES
2	13.0	30.0	9.0	30.0	1.0	2.0	0.0	0.0	0.0	NO
3	39.0	35.0	5.0	76.0	2.0	10.0	1.0	1.0	1.0	NO
4	7.0	35.0	14.0	80.0	2.0	15.0	0.0	1.0	0.0	?

• DEBEMOS CODIFICAR LOS VALORES DEPENDIENTES EN CERO O UNO: 0/1

X										Y
TELNO	ASE	ADDRESS	NRKMS	ED	ETARY	EQUIP	CDKCARD	WIBSCESS	CHAPN	
0	11.0	33.0	7.0	136.0	5.0	5.0	0.0	1.0	1.0	1.0
1	33.0	33.0	12.0	83.0	2.0	0.0	0.0	0.0	0.0	1.0
2	13.0	30.0	9.0	30.0	1.0	2.0	0.0	0.0	0.0	0.0
3	39.0	35.0	5.0	76.0	2.0	10.0	1.0	1.0	1.0	0.0
4	7.0	35.0	14.0	80.0	2.0	15.0	0.0	1.0	0.0	?

$$X \in \mathbb{R}^{m \times n}$$

$$Y \in \{0, 1\}$$

$$\hat{y} = P(y=1|x)$$

$$P(y=0|x) = 1 - P(y=1|x)$$

#####

REGRESIÓN LOGÍSTICA

VS


MÓDULO 4

REGRESIÓN LINEAL

#####

X										Y
TELNO	AGE	ADDRESS	KEYS	ED	ETHNIC	EQUIP	COLORADO	WIRELESS	CARPET	

0	44.0	33.0	7.0	136.0	5.0	5.0	0.0	1.0	1.0	YES
1	33.0	33.0	12.0	23.0	2.0	0.0	0.0	0.0	0.0	YES
2	23.0	30.0	9.0	30.0	1.0	2.0	0.0	0.0	0.0	NO
3	39.0	35.0	5.0	76.0	2.0	10.0	1.0	1.0	1.0	NO




• EJEMPLOS:

— REGRESION LINEAL PODEMOS PREDECIR
 LOS INGRESOS DE UN CLIENTE SOLO CON LA
 EDAD. LOS INGRESOS ES UN VALOR CONTINUO.
NO CATEGORICO:

	FEEL	AGE	ADDRESS	MEANS	ED	EMPOY	EQUIP	COLORADO	WIRELESS	CHURN
0	11.0	33.0	7.0	136.0	5.0	5.0	0.0	1.0	1.0	YES
1	33.0	33.0	12.0	83.0	2.0	0.0	0.0	0.0	0.0	YES
2	13.0	30.0	9.0	30.0	1.0	2.0	0.0	0.0	0.0	NO
3	39.0	35.0	5.0	76.0	2.0	10.0	1.0	1.0	1.0	NO

• CON LA REGRESION LINEAL
 PODEMOS APOSTAR UN CIERO
 OPORTUNISMO A TRAVES DE LOS
 DATOS.



• PODEMOS ENCONTRAR ESTA LINEA ENTRENANDO
 NUESTRO MODELO O CALCULANDO MATEMATICAMENTE
 LA FUNCION DE LAS COORDENADAS DE NUESTROS DATOS.

• EL TIENE UNA ECUACION: $A + B \times X_1$

• USANDO ESA LINEA PODAMOS PREDECIR
LOS INGRESOS DE UN CLIENTE DESCONOCIENDO
SOLO POR SU EDAD.


¿PODEMOS PREDECIR LA PERDIDA
DE CLIENTES SOLO CON LA EDAD?

	TEMP	AGE	ADDRESS	INCOME	ED	EMERGENCY	EQUIP	COLORADO	WIRELESS	CHURN
0	11.0	33.0	7.0	136.0	5.0	5.0	0.0	1.0	1.0	YES
1	33.0	33.0	11.0	83.0	7.0	0.0	0.0	0.0	0.0	YES
2	13.0	30.0	9.0	30.0	1.0	2.0	0.0	0.0	0.0	NO
3	39.0	35.0	5.0	76.0	2.0	10.0	1.0	1.0	1.0	NO

$$\theta^T X = \theta_0 + \theta_1 x_1$$

$$\theta^T X = \theta_0 + \theta_1 x_1 + \theta_2 x_2 + \dots$$

$$\theta^T = [\theta_0, \theta_1, \theta_2, \dots] \quad X = \begin{bmatrix} 1 \\ x_1 \\ x_2 \\ \dots \end{bmatrix}$$



$$\theta^T X = \theta_0 + \theta_1 x_1$$


$$P_1 = [13] \rightarrow \theta^T x = -1 + 0.1 x_1$$

$$= -1 + 0.1 \times 13$$

$$= 0.3$$

* CREAMOS UN UMBRAL
PARA PODER ASIGNAR
LA CLASE.

0.5



$$\hat{y} = \begin{cases} 0 & \text{if } \theta^T x < 0.5 \\ 1 & \text{if } \theta^T x \geq 0.5 \end{cases}$$

- Podemos decir que nuestro cliente pertenece a la clase 0.

PROBLEMA: ¿CUÁL ES LA PROBABILIDAD
DE QUE ESTE CLIENTE SEA CLASE
0?

≡ NO SE PUEDE SABER ≡

* AL TRABAJAR CON UN UMBRAL DA IGUAL QUE TAN PEQUEÑO O GRANDE SEA EL RESULTADO, SIEMPRE LO VAMOS A CATEGORIZAR

$$\begin{aligned} L \Rightarrow < 0.5 \Rightarrow 0, -1, -1.000 \\ \geq 0.5 \Rightarrow 1, 2, 35, 1.000 \end{aligned}$$

* ESTO NO NOS PROPORCIONA NINGUNA PROBABILIDAD DE QUE UN CLIENTE SEA DE UNA CLASE U OTRA.

= PODRÍAMOS CONSEGUIRLO USANDO EN LUGAR DE USAR:

$$\theta^T x = \theta_0 + \theta_1 x_1 \dots$$

→ USAMOS: (SIGMOIDE)

$$\sigma(\theta^T x) = \sigma(\theta_0 + \theta_1 x_1 \dots)$$

NOS DA LA PROBABILIDAD DE QUE UN PUNTO PERTENEZCA A UNA CLASE EN LUGAR DE UN VALOR

- SIEMPRE DEVUELVE UN VALOR 0 y 1.


* FUNCIÓN SIGMOIDE EN LA REGRESIÓN LOGÍSTICA *

• FUNCIÓN SIGMOIDE

• FUNCIÓN LOGÍSTICA

⇓

$$\sigma(\theta^T x) = \frac{1}{1 + e^{-\theta^T x}}$$




• SE PARECE A LA FUNCIÓN ESCALONADA.

- CUANDO LA TRANSPOSICIÓN $\theta^T x$ ES MUY GRANDE, LA POTENCIA "e" HACE LA TRANSPOSICIÓN $\theta^T x$ EN EL DENOMINADOR DE LA FRACCIÓN SE CONVIERTE EN CASI 0 Y EL VALOR DE LA FUNCIÓN SIGMOIDE SE APROXIMA A UNO.

$$\sigma(\theta^T x) = \frac{1}{1 + e^{-\theta^T x}} \uparrow \Rightarrow \sigma(\theta^T x) = 1$$

• SI LA TRANSPOSICIÓN DE $\theta^T X$ ES MUY PEQUEÑA, LA FUNCIÓN SIGMOIDEA SE ACERCA A 0.

$$\sigma(\theta^T X) = \frac{1}{1 + e^{-\theta^T X}} \downarrow \Rightarrow \sigma(\theta^T X) = 0$$



¿CUAL ES EL RESULTADO DE NUESTRO MODELO CUANDO LA FUNCIÓN SIGMOIDEA?

- EN LA REGRESIÓN LOGÍSTICA, MODEAMOS LA PROBABILIDAD DE QUE UNA ENTRADA X PERTENEZCA A LA CLASE PREDETERMINADO.

- $P(Y=1|X)$

└─▶ $Y=1$: Podemos escribir
que $Y=1$ como probabilidad
(Y) = 1 DADA X

- $P(Y=0|X) = 1 - P(Y=1|X)$

└─▶ TAMBIEN PODEMOS
ESCRIBIR LA PROBABILIDAD DE
QUE "Y" PERTENEZCA A LA
CLASE "0".

EJEMPLO :

- LA PROBABILIDAD DE QUE UN CLIENTE PERMANezca
EN UNA EMPRESA SE PUEDE MOSTRAR COMO LA
PROBABILIDAD DE QUE UNO "CHURN" IGUAL A 1.
DADO LOS INGRESOS Y EDADE DE CLIENTES


- $P(\text{CHURN}=1 | \text{income, AGE}) = 0.8$



LA PROBABILIDAD DE ABANDONO ES 0
PARA EL MISMO CLIENTE, DADO QUE LOS
INGRESOS Y LA EDAD DEL CLIENTE SE PUEDEN
SE PUEDEN CALCULAR COMO: $1 - 0.8 = 0.2$

$$\bullet P(\text{CHURN} = 1 \mid \text{income, AGE}) = 0.8$$

$$\bullet P(\text{CHURN} = 0 \mid \text{income, AGE}) = 1 - 0.8 = 0.2$$




$$\sigma(\theta^T x) \longrightarrow P(y=1|x)$$

* * * * *

AHORA TENEMOS QUE ENTRENAR EL
MODELO PARA QUE ESTABLEZCA LOS VALORES
DE SUS PARÁMETROS DE TAL MANERA QUE
NUESTRO MODELO SEA UNA BUENA ESTIMACIÓN
DE LA PROBABILIDAD $(y)=1$ EN FUNCIÓN DE x

* * * * *

SE SUPONE QUE DEBE DE HACER POR
NUESTROS UN BUEN MODELO CLASIFICADOR
CONSTRUIDO MEDIANTE REGRESIÓN LOGÍSTICA.



$$1 - \sigma(\theta^T x) \longrightarrow P(y=0|x)$$

DEBERÍA SER UNA BUENA ESTIMACIÓN
DE QUE (y) PERTENEZCA A LA CLASE $\emptyset$

PROCESO DE ENTRENAMIENTO

$$\sigma(\theta^T X) \longrightarrow P(Y=1|X)$$

*1. INICIALIZAR θ . $\longrightarrow \theta = [-1, 2]$

*2. CALCULAR $\hat{y} = \sigma(\theta^T X)$ PARA UN CLIENTE

$$\hat{y} = \sigma([-1, 2] \cdot [7, 5]) = 0.9997$$

↓ ↓
EDAD INGRESOS

θ Theta = ES LA CONFIANZA O EL PESO QUE HEMOS ESTABLECIDO EN EL PASO 1.

PROBABILIDAD DE QUE EL CLIENTE PERTENEZCA A LA CLASE: 1.

*3. COMPARAR $\hat{y}$ CON LA ETIQUETA REAL DEL CLIENTE:

$$\longrightarrow \text{ERROR} = 1 - 0.9997 = 0.0003$$

Y LO REGISTRAMOS COMO EL ERROR DE NUESTRO MODELO

* ESTE ES EL ERROR DE UN SOLO CLIENTE.

*4. CALCULAR EL ERROR DE TODOS LOS CLIENTES Y SUMAR TODOS LOS ERRORES:

→ $COST = J(\theta)$

EL "COST" DE UN MODELO, ES EL ERROR DE UN MODELO:

- LA DIFERENCIA ENTRE LOS VALORES REALES Y LOS PREDICADOS POR NUESTRO MODELO.

• CUANTO MENOR SEA EL COSTO, MEJOR SERÁ EL MODELO PARA PREDICAR CORRECTAMENTE LAS ETIQUETAS DE LOS CLIENTES.

*5. CAMBIAR θ PARA REDUCIR EL COST. → θ_{new}

↓
EL RESO.

• LOS VALORES INICIALES DE θ SE ELIGIERON AL AZAR Y ES MUY POSIBLE QUE LA FUNCIÓN DE COST SEA MUY ALTA.

* 6. VOLVER AL PASO 2.

IMPORTANTE:

- ¿CÓMO PODEMOS IR VARIANDO LOS VALORES DEL PESO?
 - DESCENSO EN GRADIENTE
- ¿CUÁNDO DEBEMOS DETENER LAS ITERACIONES?
 - CUANDO EL RESULTADO ES SATISFACTORIO.

#####

REGRESIÓN LOGÍSTICA

TRAINING

MÓDULO 4

#####

• EL OBJETIVO PRINCIPAL DEL ENTRENAMIENTO ES CAMBIAR LOS PARÁMETROS DEL MODELO PARA QUE LOGRE LA MEJOR ESTIMACIÓN DE LAS ETIQUETAS.

GENERAL COST FUNCTION

$$\sigma(\theta^T x) \longrightarrow P(y=1|x)$$

- CAMBIAR PESO $\longrightarrow$ REDUCIR EL COSTO
- COST FUNCTION $\longrightarrow \text{Cost}(\hat{y}, y) = \sigma(\theta^T x) - y$

$$\text{Cost}(\hat{y}, y) = \frac{1}{2} (\sigma(\theta^T x) - y)^2$$

- POR LO GENERAL USAMOS EL CUADRO DE ESTA ECUACIÓN POR LA POSIBILIDAD DE UN RESULTADO NEGATIVO Y POR BUSCAR LA SIMPLICIDAD

$$\text{Cost}(\hat{y}, y) = \frac{1}{2} (\sigma(\theta^T x) - y)^2$$

$$J(\theta) = \frac{1}{m} \sum_{i=1}^m \text{Cost}(\hat{y}_i, y_i)$$

→ * TAMBIÉN SE DENOMINA: MSE
Error Cuadrático Medio

¿CÓMO PODEMOS ESTABLECER LOS MEJORES PESOS QUE MINIMICEN LA FUNCIÓN DE COST?


1. DEBEMOS CALCULAR EL PUNTO MÍNIMO DE LA FUNCIÓN Y NOS MOSTRARÁ LOS MEJORES PARÁMETROS PARA NUESTRO MODELO.
2. COMO PODEMOS ENCONTRAR EL PUNTO MÍNIMO DE UNA FUNCIÓN CON LA DERIVADA DE

UNA FUNCIÓN. NO HAY MANERA FÁCIL DE ENCONTRAR EL PUNTO MÍNIMO GLOBAL PARA DICHA ECUACIÓN.

• COMO ESTO ES MUY COMPLEJO EN SU LUGAR UDHS A BUSCAR OTRA FUNCIÓN DE COSTO.

• QUE TENGA EL MISMO COMPORTAMIENTO PERO QUE SEA MÁS FÁCIL ENCONTRAR SU PUNTO MÍNIMO.


TRAZANDO LA FUNCIÓN DE COSTO EN EL MODELO



TRAZANDO LA FUNCIÓN DE COSTO EN EL MODELO

- Modelo $\hat{y}$
- Valor actual $y = 1$ ó 0
- if $Y=1$, and $\hat{y}=1 \rightarrow \text{cost} = 0$
 - ↳ EL COSTO DEBERIA DE AUMENTAR A MEDIDA QUE NUESTRO MODELO SE ALEJA DE 1
- if $Y=1$, and $\hat{y}=0 \rightarrow \text{cost} = \text{LARGE}$
 - ↳ EL COSTO DEBERIA SER MUY ELEVADO SI EL RESULTADO DE NUESTRO MODELO ES CERCA DE 0

• LA FUNCIÓN LOGARÍTMICA NEGATIVA NOS PROPORCIONA LA FUNCIÓN DE COSTO.



$y=1$
(es ideal) *

* NUESTRO MODELO ES MEJOR SI ESTIMAMOS QUE $y=1$.

* SI EL VALOR REAL ES 1 Y EL MODELO TAMBIÉN PREDICE 1 LA FUNCIÓN LOGARÍTMICA NEGATIVA DE NUESTRAS UN COSTE 0.

* PERO SI LA PREDICCIÓN ES INFERIOR A 1, LA FUNCIÓN LOGARÍTMICA NEGATIVA DE NUESTRAS UN VALOR DE COSTE MAYOR.

* USAREMOS LA FUNCIÓN LOGARÍTMICA NEGATIVA PARA CALCULAR EL COSTO DE NUESTRO MODELO DE REGRESIÓN LOGÍSTICA *

$$\text{Cost}(\hat{y}, y) = \begin{cases} -\log(\hat{y}) & \text{if } y=1 \\ -\log(1-\hat{y}) & \text{if } y=0 \end{cases}$$

$$J(\theta) = \frac{1}{m} \sum_{i=1}^m y^i \log(\hat{y}^i) + (1-y^i) \log(1-\hat{y}^i)$$

¡IMPORTANTE!

- $\hat{y}$: NO DEVUELVE UNA CLASE COMO SALIDA.
- $\hat{y}$: ES UN VALOR DE 0 A 1 QUE DEBE ASUMIRSE COMO UNA PROBABILIDAD

- AHORA PODEMOS USAR FACILMENTE ESTA FUNCIÓN PARA ENCONTRAR LOS PARÁMETROS DE NUESTRO MODELO DE TAL MANERA QUE SE MINIMICE EL COSTO.

$$J(\theta) = \frac{1}{m} \sum_{i=1}^m y^i \log(\hat{y}) + (1 - y^i) \log(1 - \hat{y}^i)$$

- SIGUIENTE PASO ES MINIMIZAR: $J(\theta)$ (COST FUNCTION)

↳ USANDO GRADIENT DESCENT

↳ ES EL ENFOQUE ITERATIVO PARA ENCONTRAR EL MÍNIMO DE UNA FUNCIÓN.

↳ USANDO LAS DERIVADAS DE COST FUNCTION.

* GRADIENT DESCENT *


- PENSAMOS EN LOS PARÁMETROS O PESOS DE NUESTRO MODELO COMO SI FUERAN UN ESPACIO BIDIMENSIONAL:

- ASPECTOS UNIDIMENSIONALES MÁS DE LA FUNCIÓN COST:

• θ_1 y θ_2 :

DOS CARACTERÍSTICAS

└─ - EDAD.
- INGRESOS.




$$\hat{y} = \sigma(\theta_1 x_1 + \theta_2 x_2)$$

$$J(\theta) = -\frac{1}{m} \sum_{i=1}^m y^i \log(\hat{y}^i) + (1 - y^i) \log(1 - \hat{y}^i)$$

└─ MINIMIZAR: J

GRÁFICA FUNCIÓN COSTO

- CURVA DE ERROR O'
- CUENCO DE ERROR DE LA FUNCIÓN DE COSTOS.



ESTO REPRESENTA EL UNIV. DE ERROR PARA DIFERENTES VALORES DE PARÁMETROS:

— EL ERROR ES UNA FUNCIÓN DE DOS PARÁMETROS.

RECUERDA:

* QUEBAMOS USAR ESTE ERROR
PARA ENCONTRAR LOS MEJORES VALORES
DE LOS PARÁMETROS QUE REDUZCAN AL
MÍNIMO EL VALOR DE COSTO *

¿CUÁL ES EL MEJOR PUNTO PARA LA
FUNCIÓN DE COSTO?

- HAY QUE INTENTAR MINIMIZAR LA POSICIÓN EN
LA CURVA DE ERROR.

• PARTIMOS DESDE UN PUNTO ALEATORIO Y
USAMOS ESTA ECUACIÓN:

$$\frac{\partial J}{\partial \theta_1} = -\frac{1}{n} \sum_{i=1}^n (y^i - \hat{y}^i) x_1^i$$

• ESTA ECUACIÓN DETERMINA LA PENDIENTE DE
ESE PUNTO Y DEBEMOS ACTUALIZAR EL
PARÁMETRO EN LA DIRECCIÓN OPUESTA A
LA PENDIENTE.

• EL VECTOR DE TODAS LAS PENDIENTES ES EL VECTOR DE GRADIENTE:

$$\frac{\partial J}{\partial \theta_1} = -\frac{1}{m} \sum_{i=1}^m (y^i - \hat{y}^i) x_1^i$$

$\nabla J = \begin{bmatrix} \frac{\partial J}{\partial \theta_1} \\ \frac{\partial J}{\partial \theta_2} \\ \dots \\ \frac{\partial J}{\partial \theta_k} \end{bmatrix}$

• Podemos usar este vector para cambiar o actualizar todos los parámetros

$$\theta_{\text{New}} = \theta_{\text{Old}} - \eta \nabla J$$

• Nuevos parámetros de theta que han reducido el coste.

• Restamos el peso al vector del gradiente y lo multiplicamos por una constante η

→ • Se denomina en la tasa de aprendizaje.

• LA TASA DE APRENDIZAJE NOS DA UN CONTROL ADICIONAL SOBRE LA RAPIDEZ CON LA QUE NOS MOVAMOS POR LA SUPERFICIE

* EL DESCENSO DE LA PENDIENTE (∇J) ES COMO DAR PASOS EN LA DIRECCIÓN ACTUAL DE LA PENDIENTE

* LA TASA DE APRENDIZAJE (η): ES LA LONGITUD DEL PASO QUE DAMOS.

NO OLVIDAR:

- ES UNA OPERACIÓN ITERATIVA Y EN CADA ITERACIÓN ACTUALIZAMOS LOS PARÁMETROS Y MINIMIZAMOS EL COSTO HASTA QUE LA CONVERGENCIA DEL ALGORITMO ESTÉ EN UN NÚMERO DESEABLES.

* TRAINING ALGORITHM RECAP *

1. INICIALIZAMOS PARÁMETROS CON VALORES ALEATORIOS:

$$\Theta^T = [\theta_0, \theta_1, \theta_2 \dots]$$

2. MINIMIZAMOS LA FUNCIÓN DE COSTE CON EL SET DE ENTRENAMIENTO Y CALCULAMOS EL ERROR.

$$J(\theta) = -\frac{1}{m} \sum_{i=1}^m y^i \log(\hat{y}) + (1 - y^i) \log(1 - \hat{y}^i)$$

3. CALCULAMOS EL GRADIENTE DE COST FUNCTION.

$$\nabla J = \left[\frac{\partial J}{\partial \theta_1}, \frac{\partial J}{\partial \theta_2}, \dots, \frac{\partial J}{\partial \theta_k} \right] \quad * \text{ VECTOR DE GRADIENTE}$$

4. ACTUALIZAMOS LOS PESOS CON NUEVOS VALORES.

$$\text{New } \theta = \text{old } \theta - \eta \nabla J$$

5. VOLVEMOS AL PASO ② y VOLVEMOS A ALIMENTAR LA FUNCIÓN DE COSTE.

6. PREDECIR EL NUEVO CUENTE:

$$P(y=1|x) = \sigma(\theta^T x)$$

#####

LABORATORIO

#####

* LABORATORIO REGRESIÓN LOGÍSTICA *

ESTUDAR EN VIDEO => LABORATORIO 6

#####

SUPPORT VECTOR MACHINE

SVM

MÓDULO 4

-SE USA PARA LA CLASIFICACIÓN

CLASIFICACIÓN CON SVM

TEMEROS UND BRDD CON NIVELES DE HUEVEDOS AS
CELULAS HUMANAS:

ID	CLUMP	USRE	USARE	M.DDH	SEPSIRE	BAREUL	B. CHROM	N.NUL	MIT	CLASS
1000025	5	1	1	1	2	1	3	1	1	BEVING
1002945	5	4	4	5	7	10	3	2	1	BEVING
1015425	3	1	1	1	2	2	3	1	1	MALIGNANT
1016277	6	8	8	1	3	4	3	7	1	BEVING
1017023	4	1	1	3	2	1	3	1	1	BEVING
1017122	9	10	10	8	7	10		7	1	MALIGNANT
1018099	1	1	1	1	2	10	3	1	1	BEVING
1018561	2	1	2	H	2	1	3	1	1	BEVING
1033071	2	1	1	1	2	1	1	1	5	BEVING
1033078	4	2	1	1	2	1	2	1	1	BEVING

DE PACIENTES QUE SE CREÍA QUE ESTABAN EN RIESGO DE DESARROLLAR UN CÁNCER.

- EN LAS TABLAS SE SIGNIFICATIVIDADES ENTRE MUESTRAS BENIGNAS Y MALIGNAS.
- PODEMOS UTILIZAR LOS VALORES DE ESTAS CARACTERÍSTICAS CELULARES PARA OBTENER UNA INDICACIÓN ESTADÍSTICA DE SI UNA MUESTRA PUEDE SER BUENA O MALA.

ID	CLUMP	USGE	USHAPE	M.DDH	SEPSING	TEXTURE	B. CHROM	NNUL	MIT	CLASS
1000025	5	1	1	1	2	1	3	1	1	BENIGN
1002945	5	4	4	5	7	10	3	2	1	BENIGN
1015425	3	1	1	1	2	2	3	1	1	MALIGN
1016277	6	8	8	1	3	4	3	7	1	BENIGN
1017023	4	1	1	3	2	1	3	1	1	BENIGN
1017122	8	10	10	8	7	10		7	1	MALIGN
1018099	1	1	1	1	2	10	3	1	1	BENIGN
1018561	2	1	2	4	2	1	3	1	1	BENIGN
1033079	2	1	1	1	2	1	1	1	5	BENIGN
1033078	4	2	1	1	2	1	2	1	1	BENIGN

1000015	6	1	1	1	7	1	3	1	1	
---------	---	---	---	---	---	---	---	---	---	--

*¿QUÉ ES SVM?

- MÁQUINA VECTORIAL DE SOPORTE
- SUPPORT VECTOR MACHINE

- ES UN ALGORITMO SUPERVISADO
QUE PUEDE CLASIFICAR LOS CASOS MEDIANTE
UN SEPARADOR.

* * * *

1. Mapea los datos en espacio de
características de alta dimensión.


↳ CON ESTO LOS PUNOS DE DATOS SE PUEDEN
CLASIFICAR, INCLUSO CUANDO NO SE PUEDEN
SEPARAR LINEALMENTE.

2. SE ESTIMA UN SEPARADOR PARA
LOS DATOS

↳ SE DEBE QUE PODER DIBUJAR UN
SEPARADOR COMO UN HIPERPLANO

DISTRIBUCIÓN DE UN CONJUNTO PEQUEÑO DE CÉLULAS EN FUNCIÓN DE SU TAMAÑO Y GRADO DE DIFERENCIACIÓN

ID	CLUMP	USIZE	USHARE	M.DM	SEPSIZE	BRELUK	B. CHROM	N.NUL	MIT	CLASS
1000025	5	1	1	1	2	1	3	1	1	BELOW
1002945	5	4	4	5	7	10	3	2	1	BELOW
1015425	3	1	1	1	2	2	3	1	1	HIGHER
1016277	6	8	8	1	3	4	3	7	1	BELOW
1017023	4	1	1	3	2	1	3	1	1	BELOW
1017122	8	10	10	8	7	10		7	1	HIGHER
1018099	1	1	1	1	2	10	3	1	1	BELOW
1018561	2	1	2	1	2	1	3	1	1	BELOW
1033079	2	1	1	1	2	1	1	1	5	BELOW
1033078	4	2	1	1	2	1	2	1	1	BELOW




- LOS PUNTOS DE DATOS SE DIVIDEN EN DOS CATEGORIAS DIFERENTES:

- MALIGNANT
- BENIGN

- ESTO REPRESENTA UN CONJUNTO DE DATOS LINEALMENTE NO SEPARABLES



- SE PUEDE SEPARAR POR UNA CURVA



- COMO ES EL CASO DE LA MAYORIA DE CONJUNTOS DE DATOS DEL MUNDO REAL.


- PERO PODEMOS TRANSFERIR ESTOS DATOS A UN ESPACIO DE DIMENSIONES SUPERIORES






MAPA TRIDIMENSIONAL

¿AHORA SI PODEMOS DEFINIR EL LÍMITE ENTRE LAS DOS CATEGORÍAS CON UN HÍPERPLANO




◦ COMO ESTAMOS EN UN ESPACIO TRIDIMENSIONAL EL SEPARADOR SE MUESTRA COMO UN PLANO.

◦ EL PLANO SE PUEDE USAR PARA CLASIFICAR CASOS NUEVOS O DESCONOCIDOS.





* ¿CÓMO TRANSFERIMOS LOS DATOS DE FORMA QUE SE PUEDA DIBUJAR UN HIPERPLANO?

* ¿CÓMO PODEMOS ENCONTRAR EL SEPARADOR MEJOR U OPTIMIZADO DESPUÉS DE LA TRANSFORMACIÓN?





* DATA TRANSFORMATION *


1. IMAGINAMOS QUE NUESTRO DATO SET ES UNIDIMENSIONAL.



2. LO TRANSFERIMOS A UN ESPACIO BIDIMENSIONAL




• PODEMOS AUMENTAR LA DIMENSION Mapeando x en un nuevo espacio mediante una función con las variables x y x^2



$$\phi(x) = [x, x^2]$$

- PODEMOS SEPARARLOS LINEALMENTE

Y PODEMOS CLASIFICARLOS



¡IMPORTANTE!

BÁSICAMENTE, HACER DATOS EN UN ESPACIO DE DIMENSIONES SUPERIORES SE DENOMINA:

CREACIÓN DE NÚCLEOS:

KERNELING:

- LINEAR
- POLYNOMIAL
- RBF
- SIGMOID


FUNCIÓN DE NÚCLEO $\Rightarrow$

$$\phi(x) = [x, x^2]$$

* ¿CÓMO PODEMOS ENCONTRAR EL SEPARADOR MEJOR U OPTIMIZANDO DESPUÉS DE LA TRANSFORMACIÓN?


0

- UNA OPCIÓN POSIBLE COMO MEJOR HIPERPLANO ES LA QUE REPRESENTA LO MAYOR SEPARACIÓN ENTRE LAS DOS CLASES.




- POR LO TANTO EL OBJETIVO ES ELEGIR UN HIPERPLANO CON UN MARGEN LO MÁS GRANDE POSIBLE.

• USAMOS LOS VECTORES DE SOPORTE.



LINEARLY SEPARABLE



— LAS LÍNEAS DE DECISIÓN DEL HIPERPLANO Y DEL LÍMITE TIENEN SUS PROPIAS ECUACIONES:

→ $w^T x + b = -1$, etc.

✓ EL HIPERPLANO NACE A PARTIR DE DATOS DE ENTRENAMIENTO MEDIANTE UN PROCESO DE OPTIMIZACIÓN.

• ESTE PROBLEMA DE OPTIMIZACIÓN TAMBIÉN SE PUEDE RESOLVER MEDIANTE:

— DESCENSO GRADIENTE

(*NO SE US EN ESTE MÓDULO*)

- LA SALIDA DEL ALGORITMO SON LOS VALORES w y b DE LA LINEA.
- PODEMOS HACER CLASIFICACIONES USANDO ESTA LINEA ESTIMADA.
- BASTA CON INTRODUCIR LOS VALORES DE ENTRADA EN LA ECUACIÓN LINEAL.
- ESTO NOS DIRA SI UN PUNTO DESCONOCIDO ESTÁ POR ARRIBA O POR DEBAJO

* PROS Y CONTRAS DE SVM *

• VENTAJAS:


- SON PRECISAS EN ESPACIOS DE ALTAS DIMENSIONES
- AHORRAN MEMORIA

• DESVENTAJAS:

- EL MODELO ES PROFUNDO Y SUERDE A DISTORSIONES SI EL NÚMERO DE CARACTERÍSTICAS ES MUCHO MAYOR QUE EL NÚMERO DE MUESTRAS.
- NO PROPORCIONAN DIRECTAMENTE ESTIMACIONES DE PROBABILIDAD. ALGO IMPORTANTES EN LA MAYORÍA DE LOS PROBLEMAS DE CLASIFICACIÓN.
- NO SON MUY EFICIENTES DESDE EL PUNTO DE VISTA COMPUTACIONAL, SI EL CONJUNTO DE DATOS ES MUY GRANDE POR EJEMPLO DE 1.000 FILAS. (1.000 MUESTRAS).

APPLICATIONS

- RECONOCIMIENTO DE IMAGEN:

- 
- CLASIFICACIÓN IMÁGENES
 - ESCRITURA A MANO
 - RECONOCIMIENTO DE DÍGITOS

- CLASIFICACIÓN DE TEXTOS:

- 
- SPAM O NO SPAM
 - OPINIONES (Sentiment Analysis)
 - DOCUMENTOS LEGALES
 - NOTICIAS (Deportes, Fútbol, etc)
 - FILTRADO DE CONTENIDOS RSCS
 - FAQs
 - RECOMENDAS PELÍCULAS

- REGRESIÓN

- DETECCIÓN DE VALORES ANÓMALOS

- CLUSTERING

#####



LABORATORIO

#####

LABORATORIO SVM (SUPPORT VECTOR MACHINES)

ESTUDAR EN VIDEO => LABORATORIO 7

$$RAE = \frac{\sum_{j=1}^n |y_i - \hat{y}_j|}{\sum_{j=1}^n |y_i - \bar{y}|}$$





$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$$



$$MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

*

$$\hat{y} = \theta_0 + \theta_1 x_1$$

$$\theta_1 = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2}$$

$$\theta_0 = \bar{y} - \theta_1 \bar{x}$$