

#####

DEEP LEARNING KERAS

MODULO 1

#####

- ES UNO DE LOS CAMPOS DE LA CIENCIA
DE DATOS. (DATA SCIENCE)

≡ APLICACIONES ≡

* COLOR RESTORATION *

ES LA CORRECCIÓN AUTOMÁTICA Y
RESTAURACIÓN DE COLOR EN IMÁGENES
EN BLANCO Y NEGRO.

EL SISTEMA UTILIZA:

RED NEURONAL CONVOLUCIONAL

* SPEECH REENACTMENT *

(REPRESENTACIÓN DE VOZ)

- UN CLIP DE AUDIO SE SINTETIZA CON UN VIDEO Y LOS MOVIMIENTOS DE LOS LABIOS SE SINCROAN CON LOS SONIDOS Y LAS PALABRAS DEL CLIP DE AUDIO
- EL SISTEMA USA UNO:

RED NEURONAL RECURRENTE

* AUTOMATIC HANDWRITING GENERATION *

(GENERACIÓN AUTOMÁTICA DE ESCRITURA A MANO)

- UN ALGORITMO QUE PUEDE ESCRIBIR UN MENSAJE DETERMINADO CON LETRAS MUY REALISTAS
- EL SISTEMA USA UNO:

RED NEURONAL RECURRENTE

OTRAS APLICACIONES

- AUTOMATIC MACHINE TRANSLATION

(TRADUCCIÓN AUTOMÁTICA)

RED NEURONAL CONVOLUCIONAL

→ TRADUCE EL TEXTO DE UNA IMAGEN SOBRE LA MARCA

- AUTOMATICALLY ADDING SOUNDS TO SILENT MOVIES

(AGREGAR SONIDOS AUTOMÁTICAMENTE A FILMS MUDOS)

→ USA BASES DE DATOS SONOROS Y ELIGE EL SONIDO QUE MEJOR SE ADAPTA A LA ESCENA.

- CLASIFICACIÓN DE OBJETOS Y DETECCIÓN DE IMAGENES.

- COCHES AUTÓNOMOS

#####

NEURONAS Y REDES NEURONALES

DEEP LEARNING MODULO 1

#####

EL APRENDIZAJE PROFUNDO SE INSPIRA
EN GRAN MEDIDA EN LA FORMA EN LA
QUE LAS NEURONAS Y LAS REDES NEURONALES
FUNCIONAN Y PROCESAN LOS DATOS EN
EL CEREBRO.


* UNA RED NEURONAL *

LA PRIMERA IMAGEN DE UNA NEURONA
FUE DIBUJADA POR:

SANTIAGO RAMÓN Y CAJAL

EN EL AÑO: 1899

NEURONA BIOLÓGICA REAL.



1. LAS DENTRITAS RECIBEN IMPULSOS ELÉCTRICOS QUE TRANSPORTAN INFORMACIÓN O DATOS DESDE LAS SINAPSIS DE OTRAS NEURONAS CONTIGUAS.
2. LAS DENTRITAS LLEVAN LOS IMPULSOS O DATOS AL SOMA.
3. EN EL NÚCLEO LOS DATOS O IMPULSOS SE PROCESAN COMBINÁNDOLOS
4. LOS DATOS SE TRANSMITEN AL AXÓN

5. EL AXÓN LLEVA LA INFORMACIÓN PROCESADA AL BOTÓN TERMINAL O SÍNAPSIS.
6. LA SALIDA DE ESTA NEURONA SE CONVIERTE EN LA ENTRADA A MÁS DE OTRAS NEURONAS.

IMPORTANTE:


*EL APRENDIZAJE EN EL CEREBRO SE PRODUCE AL ACTIVAR REPETIDAMENTE CIERTAS CONEXIONES NEURONALES SOBRE OTRAS, REFORZANDO ASÍ LAS CONEXIONES.

*ESTO HACE QUE SEA MÁS PROBABLE QUE PRODUZCA EL RESULTADO DESEADO CON UNA ENTRADA ESPECÍFICA

*UNA VEZ QUE SE PRODUCE EL RESULTADO DESEADO, LAS CONEXIONES NEURONALES QUE CAUSAN ESE RESULTADO SE FORTALEZCAN.

* NEURONA ARTIFICIAL *

LA NEURONA ARTIFICIAL SE CARACTERIZA POR LA SIGUIENTE FORMA:



- AXÓN: ES EL QUE TRANSMITE LA INFORMACIÓN A OTRAS NEURONAS.
- PUEDE RAMIFICARSE PARA CONECTARSE A MUCHAS OTRAS

EL PROCESO DE APRENDIZAJE SE PARECE MUCHO A LA FORMA EN QUE SE PRODUCE EL APRENDIZAJE EN EL CEREBRO.

#####


REDES NEURONALES ARTIFICIALES

DEEP LEARNING

MODULO 1

#####

LAS REDES ARTIFICIALES SE DIVIDEN EN VARIAS CAPAS.



*LOS 3 PRINCIPALES TEMAS ASOCIADOS
CON LA REDES NEURONALES ARTIFICIALES:


1. FUNCIONES PROPAGACIÓN HACIA DELANTE.
2. PROPAGACIÓN HACIA ATRÁS.
3. ACTIVACIÓN. (FUNCIÓN SIGMOIDE)

FORWARD PROPAGATION

▶ PROPAGACIÓN HACIA DELANTE.

ES EL PROCESO MEDIANTE EL CUAL LOS
DATOS PASAN A TRAVÉS DE LAS CAPAS
DE NEURONAS DE LA RED.

DESDE EL INPUT HASTA EL OUTPUT



X_1
 X_2 $\begin{matrix} > \\ > \end{matrix}$ $\begin{matrix} \text{- DOS ENTRADAS} \\ \text{- ENTEROS O FLOTANTES} \end{matrix}$

W_1
 W_2 $\begin{matrix} > \\ > \end{matrix}$ $\text{- PESOS DE LAS CONEXIONES}$

$b_1 \rightarrow \text{SESGO (CONSTANTE)}$

LA NEURONA PROCESA LA INFORMACIÓN
EMITIENDO UNA SUMA PONDERADA DE ESTAS
ENTRADAS

$$a = z$$

$$z = x_1 \cdot w_1 + x_2 \cdot w_2 + b_1$$


Y AÑADE UNA CONSTANTE A LA SUMA (SESGO)

POR LO TANTO 'Z' ES LA COMBINACIÓN LINEAL
DE LAS ENTRADAS Y LOS PESOS JUNTO CON
EL SESGO. Y 'a' ES LA SALIDA.

* EL SIMPLE HECHO DE GENERAR UNA SUMA PONDERADA DE LAS ENTRADAS, LÍMITA LAS TAREAS QUE PUEDE REALIZAR LA RED NEURONAL.

* PARA MEJORAR EL PROCESAMIENTO DE LOS DATOS SERÍA MOVER LA SUMA PONDERADA A UN ESPACIO **NO LINEAL**.

* USAR: **FUNCIÓN SIGMOIDE**



• SI LA SUMA PONDERADA ES UN N° POSITIVO MUY GRANDE LA SALIDA DE LA NEURONA ES PRÓXIMA A 1 Y SI ES UN NEGATIVO MUY GRANDE, LA SALIDA ES PRÓXIMA A 0

*LAS TRANSFORMACIONES NO LINEALES,
COMO LA FUNCIÓN SIGMOIDE, SE DENOMINAN:

FUNCIONES DE ACTIVACIÓN

IMPORTANTE:

- LAS FUNCIONES DE ACTIVACIÓN SON UNA CARACTERÍSTICA EXTREMADAMENTE IMPORTANTES EN LAS NEURONAS ARTIFICIALES
 - DECIDEN SI UNA NEURONA TIENE QUE ACTIVARSE O NO.
 - SI LA INFORMACIÓN QUE RECIBE LA NEURONA ES RELEVANTE O DEBE IGNORARSE
- POR LO TANTO:
UNA NEURONA SIN UNA FUNCIÓN DE ACTIVACIÓN ES BÁSICAMENTE UN MODELO DE REGRESIÓN LINEAL


- LA FUNCIÓN DE ACTIVACIÓN REALIZA UNA TRANSFORMACIÓN NO LINEAL DE LA ENTRADA LO QUE PERMITE A LA RED NEURONAL APRENDER Y REALIZAR TAREAS COMPLEJAS.

- COMO LA CLASIFICACIÓN DE IMÁGENES Y LA TRADUCCIÓN DE IDIOMAS.

#####*#####

PARA SIMPLIFICAR AUN MÁS

EJEMPLO:



- NEURONA CON UN INPUT

$$x_1 = 0.1$$

$$w_1 = 0.15$$

$$b_1 = 0.40$$

$$z = w_1 \cdot x_1 + b_1$$

$$= 0.15 \cdot 0.1 + 0.4$$

$$= 0.415$$

$$a = f(z) = \frac{1}{1 + e^{-z}}$$


$$a = f(z)$$

$$= \frac{1}{1 + e^{-z}}$$

$$= \frac{1}{1 + e^{-0.415}}$$

$$= 0.6023$$


$$\text{OUTPUT} = 0.6023$$



$$a_1 = f(z_1) = \frac{1}{1 + e^{-z_1}} = 0.6023$$

$$\begin{aligned} z_2 &= w_2 \cdot a_1 + b_2 \\ &= 0.45 \cdot 0.6023 + 0.65 \\ &= 0.9210 \end{aligned}$$

$$a_2 = f(z_2) = \frac{1}{1 + e^{-z_2}} = 0.7153$$



SALIDA DE LA RED

(RED DE 2 NEURONAS)

0.7153 = SERIA EL VALOR PREVISTO PARA UN INPUT = 0.1

ASÍ ES COMO UNA RED NEURONAL PREDICE LA SALIDA DE CUALQUIER ENTRADA.

*NO IMPORTA LO COMPLICADA QUE SEA LA RED SIEMPRE SIGES ESTE MISMO PROCESO.

RESUMEN

DADA UNA RED NEURONAL CON UN CONJUNTO DE PESOS Y SESGOS, DEBERÍAS PODER CALCULAR LA SALIDA DE LA RED DADA CUALQUIER ENTRADA DADA.

#####*#####

#####

#####

LABORATORIO I MODULO 1

#####

REDES NEURONALES ARTIFICIALES

#####


GRADIENTE DESCENT

DEEP LEARNING

MODULO 2

#####

- REPRESENTAR UNA FUNCIÓN DE COSTO EN UN DIAGRAMA DE DISPERSIÓN
- DESCRIBIR EL ALGORITMO GRADIENTE DESCENDIENTE
- DESCRIBIR COMO SE REPRESENTAN LAS DIFERENTES ITERACIONES EN UN GRADIENTE DESCENDIENTE.



LÍNEA QUE
MEJOR SE
AJUSTA A LOS DATOS.

$$Z = wX$$

$$J(w) = \frac{1}{2M} \sum_{i=1}^M (z_i - wx_i)^2$$

FUNCIÓN DE COSTO O DE PÉRDIDA

- Función de Costes o de Pérdida


$$J(w) = \frac{1}{2M} \sum_{i=1}^M (z_i - wx_i)^2$$




- EL VALOR MÍNIMO O PÉRDIDA

* LO HACE QUE ESTA FUNCIÓN SEA ATRUCTIVA, ES QUE ES UNA PARÁBOLA CON UN MÍNIMO GLOBAL O SOLUCIÓN ÚNICA.

$$Z = wX$$



$$J(w) = \frac{1}{2M} \sum_{i=1}^M (z_i - wx_i)^2$$



* PARA LOS DATOS DADOS, EL VALOR DE ~~w~~ QUE HACE QUE ESTA FUNCIÓN DE COSTE SEA MÍNIMA ES QUE ES $w = 2$.

* $Z = 2x$: UNA LÍNEA QUE SE AJUSTA PERFECTAMENTE A LOS PUNTOS.

✓ EL VALOR DE W EN EL CASO DE QUE TENGA MUCHOS PESOS QUE OPTIMIZAR, SE DETERMINA MEDIANTE:

— ALGORITMO DE DESCENSO GRADIENTE —


● ALGORITMO DE OPTIMIZACIÓN ITERATIVO PARA ENCONTRAR EL MÍNIMO DE UNA FUNCIÓN.

1. COMENZAMOS CON UN VALOR ALEATORIO INICIAL DE W

→ $W_0 = 0.2$

2. DAR PASOS HACIA EL PUNTO AZUL QUE ES $W=2$

3. CALCULAR GRADIENTE PARA SABER EN QUE DIRECCIÓN MOVERNOS.



4. EN LA FUNCIÓN DE PÉRDIDA EL VALOR DE $W=0.2$. EL GRADIENTE VIENE DADO POR LA PENDIENTE DE LA TANGENTE EN $W=0.2$

5. LA MAGNITUD DEL ESCALÓN SE CONTROLA CON:
LA TASA DE APRENDIZAJE

* CUANTO MAYOR SEA LA TASA DE APRENDIZAJE, MAYOR SERÁ EL PASO QUE DEMOS.

* CUANTO MENOR SEA LA TASA, MENOR SERÁ EL PASO A DAR.

LEARNING RATE

$$\rightarrow \eta \frac{\partial J}{\partial W}$$


6. DADOS EL PASO Y PASAMOS A W_1

7. LO CALCULAMOS COMO W_0 Y ESTO REPRESENTA LA PRIMERA ITERACIÓN DEL ALGORITMO.

8. EN W_1 REPETIMOS EL MISMO PROCESO DE CALCULAR EL GRADIENTE Y UTILIZAMOS LA MISMA VELOCIDAD DE APRENDIZAJE PARA (TASA)

CONTROLAR LA MAGNITUD DEL PASO HACIA EL MÍNIMO.

9. REPETIMOS EL PASO HASTA QUE ALCANZAMOS EL MÍNIMO, O UN VALOR DE LA FUNCIÓN DE COSTE QUE ESTE MUY CERCA DEL MÍNIMO DELTA DE UN VALOR PEQUEÑO Y PREDEFINIDO



$$w_1 \rightarrow w_0 - \eta \frac{\partial J}{\partial w}$$

AL ELEGIR LA TASA DE APRENDIZAJE, HAY QUE TENER CUIDADO. UNA TASA MUY ALTA PUEDE CONDUCIR A GRANDES PASOS, Y FINALMENTE A PERDER EL MÍNIMO.

* UNA TASA MUY PEQUEÑA PUEDE RESULTAR EN PASOS EXTREMADAMENTE PEQUEÑOS Y POR LO TANTO HACER QUE EL ALGORITMO TARDE MUCHO EN ENCONTRAR EL PUNTO MÍNIMO.



● EJEMPLO:

COMO CADA ITERACIÓN CON UNA TASA DE APRENDIZAJE DE 0.4 AFECTA A LA FORMA EN QUE LA LÍNEA RESULTANTE SE AJUSTA A LA LÍNEA DE LA FIGURA.

INITIALIZATION:

$$Z = W X$$

$$J(W) = \frac{1}{2M} \sum_{i=1}^M (z_i - w x_i)^2$$



1. INICIALIZAMOS $W=0 \Rightarrow Z=0$

- COMO ES UNA LÍNEA HORIZONTAL.

- EL COSTE ES ELEVADO Y LA LÍNEA NO SE AJUSTA BIEN.



2. W SE AJERA A 2 TRAS LA PRIMERA ITERACIÓN

- COMO LA PENDIENTE ES MUY PROCLIVADA

CUANDO W ES IGUAL A 0, EL NUEVO VALOR

DE W PRODUCE UNA GRAN CAÍDA EN LA FUNCIÓN DE PÉRDIDA.

3. LA LÍNEA RESULTANTE SE AJUSTA MEJOR.





W

AUNQUE SE AJUSTA MEJOR, AUN HAY ESPACIO DE MEJORA.




4. EN LA SIGUIENTE ITERACIÓN W CONTINUÁ MOVIÉNDOSE HACIA $W=2$. COMO LA PENDIENTE NO ESTÁ PRONUNCIADA COMO ANTES, EL GRADIENTE ES MENOR.

5. PERO LA FUNCIÓN DE COSTE SIGUE BAJANDO DE VALOR. LA LÍNEA RESULTANTE SE ACERCA A LA LÍNEA IDEAL.



W

*LA MISMA OBSERVACIÓN SE OBSERVA EN LA TERCERA ITERACIÓN: Y CON LA 4^{ta}.






*DESPUÉS DE 4 ITERACIONES
ESTAMOS CASI EN $W=2$
*LA LÍNEA RESULTANTE CASI SE
AJUSTA PERFECTAMENTE AL
DIAGRAMA DE DISPERSIÓN.

CON CADA ITERACIÓN, EL PESO SE DETERMINA
DE FORMA PROPORCIONAL AL NEGATIVO DEL
GRADIENTE DE LA FUNCIÓN EN EL PUNTO
ACTUAL.

* POR LO TANTO:

- SI SE INICIALIZA LA PONDERRACIÓN EN UN VALOR QUE ESTÉ A LA DERECHA DEL MÍNIMO, EL GRADIENTE POSITIVO HACE QUE W SE MUOVA HACIA LA IZQUIERDA HACIA EL MÍNIMO:

$$W^{i+1} \rightarrow W^i - \eta \frac{\partial J}{\partial W}$$



* RECAP *

↓ (PESO)

- EL MEJOR VALOR DE W SE DETERMINA MEDIANTE UN ALGORITMO LLAMADO:
 - DESCENSO GRADIENTE
 - EL DESCENSO GRADIENTE ES UN ALGORITMO DE OPTIMIZACIÓN ITERATIVO PARA ENCONTRAR EL MÍNIMO DE UNA FUNCIÓN.
 - AL ELEGIR LA TASA DE APRENDIZAJE PARA SU CÁLCULO, HAY QUE TENER CUIDADO:
 - UNA TASA ALTA: PUEDE CAUSAR AGRAVOS PARA QUE PUEDAN LLEVAR A PERDER UN PUNTO MÍNIMO.
 - UNA TASA BAJA: PASOS EXTREMADAMENTE PEQUEÑOS Y HACER QUE EL ALGORITMO TARDE MUCHO EN ENCONTRAR EL PUNTO MÍNIMO.
- ** LA TASA DE APRENDIZAJE HAY QUE ELEGIRLA ANTES DE COMENZAR A ENTRENAR EL MODELO ****

IMPORTANTE

1. FUNCIÓN DE COSTO (O PÉRDIDA):

- MIDE CUÁNTO DE BEN ESTÁ PREDICIENDO UNA RED NEURONAL (MSE)
- EL OBJETIVO ES MINIMIZAR ESTA FUNCIÓN ANTES EL ENTRENAMIENTO (REDUCIR EL ERROR)

$$J(w) = \frac{1}{2M} \sum_{i=1}^M (z_i - wx_i)^2$$

2. DESCENSO GRADIENTE:

- ALGORITMO QUE AJUSTA LOS PESOS DE LA RED PARA MINIMIZAR LA FUNCIÓN DE COSTO.

- GRADIENTE: ES UNA DERIVADA PARCIAL DE LA FUNCIÓN DE COSTO. INDICA LA DIRECCIÓN QUE DEBES TENER CADA PESO:

PARA UN PESO w , SU GRADIENTE SERÁ:

$$\frac{\partial \text{costo}(J)}{\partial w}$$

3. TASA DE APRENDIZAJE: (α)

- ES UN FACTOR DE ESCALA QUE CONTROLA QUE GRANDES SON LOS PESOS:

$$w_{\text{nuevo}} = w_{\text{viejo}} - \alpha \frac{\partial \text{costo}(J)}{\partial w}$$


RETROPROPAGACIÓN

DEEP LEARNING MODULO 2

#####


EN REDES NEURONALES EL AJUSTE DE
LOS PESOS NO SE HACE EN UN SOLO
NODO, SE RESOLTA A TRAVÉS DE:

BACKPROPAGATION



- EN UN ENTORNO DE APRENDIZAJE SUPERVISADO CADA PUNTO DE DATOS TIENE ETIQUETADO VERDAD BÁSICA CORRESPONDIENTE.

- Y EL ENTRENAMIENTO ES NECESARIO CUANDO EL VALOR PREDICHO POR LA RED NEURONAL NO COINCIDE LA VERDAD BASICA PARA UNA ENTRADA DETERMINADA



T : GROUND TRUTH

$T \ll a_2$

#####

ALGORITMO BACKPROPAGATION

EL PROCESO DE ENTRENAMIENTO COMIENZA:



1. CALCULAR EL ERROR E :

- ENTRE LOS VALORES PRONOSTICADOS Y LOS ETIQUETAS DE LAS UNIDADES FUNDAMENTALES.


* E : REPRESENTA EL VALOR O FUNCIÓN DE PÉRDIDA.

2. PROPAGAR EL ERROR A LA RED Y USARLO PARA REALIZAR UN DESCENSO DE GRADIENTE EN LOS DIFERENTES PESOS Y PESOS DE LA RED:

- OPTIMIZARLOS USANDO LAS MISMAS ECUACIONES:

$$W_i \rightarrow W_i - \eta \cdot \frac{\partial E}{\partial W_i}$$

$$b_i \rightarrow b_i - \eta \cdot \frac{\partial E}{\partial b_i}$$




1. CALCULAMOS EL ERROR CUADRÁTICO MEDIO (MSE)

$$E = \frac{1}{2} (T - a_2)^2 \rightarrow E = \frac{1}{2m} \sum_{i=1}^m (T_i - a_{2,i})^2$$

2. ACTUALIZAMOS: w_2, b_2, w_1 y b_1

- PROPAGANDO EL ERROR A LA REJ.



UPDATING: w_2

$$w_2 \rightarrow w_2 - \eta \cdot \frac{\partial E}{\partial w_2}$$

$$E = \frac{1}{2} (T - a_2)^2$$



$$\frac{\partial E}{\partial a_2}$$



$$a_2 = f(z_2) = \frac{1}{1 + e^{-z_2}}$$




$$\frac{\partial a_2}{\partial z_2}$$



$$z_2 = a_1 \cdot w_2 + b_2$$



$$\frac{\partial z_2}{\partial w_2}$$



*UPDATING W_2 *

LA DERIVADA DEL ERROR CON RESPECTO A W_2 SERÍA:

$$W_2 \rightarrow W_2 - \eta \cdot \frac{\partial E}{\partial W_2}$$

(EL PRODUCTO DE LAS DERIVADAS INDIVIDUALES)


LA DERIVADA E RESPECTO W_2 :

$$\frac{\partial E}{\partial W_2} = \frac{\partial E}{\partial a_2} \cdot \frac{\partial a_2}{\partial z_2} \cdot \frac{\partial z_2}{\partial W_2}$$

$$= (-(1-a_2)) \cdot (a_2(1-a_2)) \cdot (a_1)$$

$$W_2 \rightarrow W_2 - \eta \cdot (-(1-a_2)) \cdot (a_2(1-a_2)) \cdot (a_1)$$

*¿CÓMO ENCONTRAR LAS DERIVADAS? *



$$\text{Eqn \# 1: } z_1 = x_1 \cdot w_1 + b_1$$

$$\text{Eqn \# 2: } a_1 = f(z_1) = \frac{1}{1 + e^{-z_1}}$$

$$\text{Eqn \# 3: } z_2 = a_1 \cdot w_2 + b_2$$

$$\text{Eqn \# 4: } a_2 = f(z_2) = \frac{1}{1 + e^{-z_2}}$$

$$\text{Eqn \# 5: } E = \frac{1}{2} (T - a_2)^2$$

$$1. \frac{\partial E}{\partial w_2} = \frac{\partial E}{\partial a_2} \cdot \frac{\partial a_2}{\partial z_2} \cdot \frac{\partial z_2}{\partial w_2}$$

$$\bullet E = \frac{1}{2} (T - a_2)^2$$

$$\frac{\partial E}{\partial a_2} = 2 \cdot \frac{1}{2} (T - a_2) \cdot (-1) = -(T - a_2)$$

$$\bullet a_2 = \frac{1}{1 + e^{-z_2}} = (1 + e^{-z_2})^{-1}$$

$$\frac{\partial a_2}{\partial z_2} = -1 \cdot (1 + e^{-z_2})^{-2} \cdot e^{-z_2} \cdot (-1)$$

$$= \frac{e^{-z_2}}{(1 + e^{-z_2})^{-2}} = (a_2)^2 \frac{1 - a_2}{a_2} = a_2(1 - a_2)$$

$$\bullet z_2 = a_1 \cdot w_2 + b_2$$

$$\frac{\partial z_2}{\partial w_2} = a_1$$

$$\frac{\partial E}{\partial w_2} = -(T - a_2) \cdot a_2(1 - a_2) \cdot a_1$$

$$2. \frac{\partial E}{\partial b_2} = \frac{\partial E}{\partial a_2} \cdot \frac{\partial a_2}{\partial z_2} \cdot \frac{\partial z_2}{\partial b_2}$$

$$\bullet E = \frac{1}{2} (T - a_2)^2$$

$$\frac{\partial E}{\partial a_2} = 2 \cdot \frac{1}{2} (T - a_2) \cdot (-1) = -(T - a_2)$$

$$\bullet a_2 = \frac{1}{1 + e^{-z_2}} = (1 + e^{-z_2})^{-1}$$

$$\frac{\partial a_2}{\partial z_2} = -1 \cdot (1 + e^{-z_2})^{-2} \cdot e^{-z_2} \cdot (-1)$$

$$= \frac{e^{-z_2}}{(1 + e^{-z_2})^{-2}} = (a_2)^2 \cdot \frac{1 - a_2}{a_2} = a_2(1 - a_2)$$

$$\bullet z_2 = a_1 \cdot w_2 + b_2$$

$$\frac{\partial z_2}{\partial b_2} = 1$$

$$\frac{\partial E}{\partial b_2} = -(T - a_2) \cdot a_2(1 - a_2) \cdot 1$$

$$3. \frac{\partial E}{\partial w_1} = \frac{\partial E}{\partial a_2} \cdot \frac{\partial a_2}{\partial z_2} \cdot \frac{\partial z_2}{\partial a_1} \cdot \frac{\partial a_1}{\partial z_1} \cdot \frac{\partial z_1}{\partial w_1}$$

$$\bullet E = \frac{1}{2}(T - a_2)^2$$

$$\frac{\partial E}{\partial a_2} = -(T - a_2)$$

$$\bullet a_2 = \frac{1}{1 + e^{-z_2}} = (1 + e^{-z_2})^{-1}$$

$$\frac{\partial a_2}{\partial z_2} = a_2(1 - a_2)$$

$$\bullet z_2 = a_1 \cdot w_2 + b_2$$

$$\frac{\partial z_2}{\partial a_1} = w_2$$

$$\bullet a_1 = \frac{1}{1 + e^{-z_1}} = (1 + e^{-z_1})^{-1}$$

$$\frac{\partial a_1}{\partial z_1} = a_1(1 - a_1)$$

$$\bullet z_1 = x_1 \cdot w_1 + b_1$$

$$\frac{\partial z_1}{\partial w_1} = x_1$$

$$\frac{\partial E}{\partial w_1} = -(T - a_2) \cdot a_2(1 - a_2) \cdot w_2 \cdot a_1(1 - a_1) \cdot x_1$$

$$4. \frac{\partial E}{\partial b_1} = \frac{\partial E}{\partial a_2} \cdot \frac{\partial a_2}{\partial z_2} \cdot \frac{\partial z_2}{\partial a_1} \cdot \frac{\partial a_1}{\partial z_1} \cdot \frac{\partial z_1}{\partial b_1}$$

$$\bullet E = \frac{1}{2}(T - a_2)^2$$

$$\frac{\partial E}{\partial a_2} = -(T - a_2)$$

$$\bullet a_2 = \frac{1}{1 + e^{-z_2}} = (1 + e^{-z_2})^{-1}$$

$$\frac{\partial a_2}{\partial z_2} = a_2(1 - a_2)$$

$$\bullet z_2 = a_1 \cdot w_2 + b_2$$

$$\frac{\partial z_2}{\partial a_1} = w_2$$

$$\bullet a_1 = \frac{1}{1 + e^{-z_1}} = (1 + e^{-z_1})^{-1}$$

$$\frac{\partial a_1}{\partial z_1} = a_1(1 - a_1)$$

$$\bullet z_1 = x_1 \cdot w_1 + b_1$$

$$\frac{\partial z_1}{\partial b_1} = 1$$

$$\frac{\partial E}{\partial b_1} = -(T - a_2) \cdot a_2(1 - a_2) \cdot w_2 \cdot a_1(1 - a_1) \cdot 1$$

*UPDATING b_2 *

- EXACTAMENTE IGUAL, PERO LA DIFERENCIA CON LA DERIVADA DE Z_2 CON RESPECTO A b_2 ES 1 Y NO LA ENTRADA DE UNO

$$b_2 \rightarrow b_2 - \eta \cdot \frac{\partial E}{\partial b_2}$$

- DERIVADA DE E RESPECTO b_2 :


$$\frac{\partial E}{\partial b_2} = \frac{\partial E}{\partial a_2} \cdot \frac{\partial a_2}{\partial z_2} \cdot \frac{\partial z_2}{\partial b_2}$$

$$= (-(1-a_2)) \cdot (a_2(1-a_2)) \cdot 1$$

$$b_2 \rightarrow b_2 - \eta \cdot (-(1-a_2)) \cdot (a_2(1-a_2)) \cdot 1$$

*UPDATING W_1 *

- USAMOS ESTA EXPRESIÓN PARA ACTUALIZAR W_1 . PERO EL ERROR NO ESTÁ RELACIONADO EXPLÍCITAMENTE CON W_1 .



$$W_1 \rightarrow W_1 - \eta \cdot \frac{\partial E}{\partial W_1}$$

USAMOS LA CADENA

*E ES UNA FUNCIÓN DE a_2 :

$$E = \frac{1}{2} (T - a_2)^2 \longrightarrow \frac{\partial E}{\partial a_2}$$

* a_2 UNA FUNCIÓN DE z_2 :

$$a_2 = f(z_2) = \frac{1}{1 + e^{-z_2}} \longrightarrow \frac{\partial a_2}{\partial z_2}$$

* z_2 ES UNA FUNCIÓN DE a_1 :

$$z_2 = a_1 \cdot w_2 + b_2 \longrightarrow \frac{\partial z_2}{\partial a_1}$$

* a_1 ES UNA FUNCIÓN DE z_1 :

$$a_1 = f(z_1) = \frac{1}{1 + e^{-z_1}} \longrightarrow \frac{\partial a_1}{\partial z_1}$$

* z_1 ES UNA FUNCIÓN DE w_1 :

$$z_1 = x_1 \cdot w_1 + b_1 \longrightarrow \frac{\partial z_1}{\partial w_1}$$

● LA DERIVADA DE E RESPECTO W_1 ES LA MULTIPLICACION DE LAS DERIVADAS INDIVIDUALES:

$$W_1 \rightarrow W_1' - \eta \cdot \frac{\partial E}{\partial W_1}$$

$$\frac{\partial E}{\partial W_1} = \frac{\partial E}{\partial a_2} \cdot \frac{\partial a_2}{\partial z_2} \cdot \frac{\partial z_2}{\partial a_1} \cdot \frac{\partial a_1}{\partial z_1} \cdot \frac{\partial z_1}{\partial W_1}$$

$$= (-(T - a_2)) \cdot (a_2(1 - a_2)) \cdot (W_2) \cdot a_1(1 - a_1) \cdot X_1$$

$$W_1 \rightarrow W_1' - \eta \cdot (-(T - a_2)) \cdot (a_2(1 - a_2)) \cdot (W_2) \cdot a_1(1 - a_1) \cdot X_1$$

~~✱ UPDATING b_1 ✱~~


$$b_1 \rightarrow b_1 - \eta \cdot \frac{\partial E}{\partial b_1}$$

$$\frac{\partial E}{\partial b_1} = \frac{\partial E}{\partial a_2} \cdot \frac{\partial a_2}{\partial z_2} \cdot \frac{\partial z_2}{\partial a_1} \cdot \frac{\partial a_1}{\partial z_1} \cdot \frac{\partial z_1}{\partial b_1}$$

$$= (-(T - a_2)) \cdot (a_2(1 - a_2)) \cdot (W_2) \cdot a_1(1 - a_1) \cdot 1$$

$$b_1 \rightarrow b_1 - \eta \cdot (-(T - a_2)) \cdot (a_2(1 - a_2)) \cdot (W_2) \cdot a_1(1 - a_1) \cdot 1$$

* BACKPROPAGATION EXAMPLE *



$$z_1 = w_1 \cdot x_1 + b_1$$

$$= 0.15 \cdot 0.1 + 0.40$$
$$= 0.415$$

$$a_1 = f(z_1) = \frac{1}{1 + e^{-(0.415)}}$$
$$= 0.6023$$

$$z_2 = w_2 \cdot a_1 + b_2$$


$$= 0.45 \cdot 0.6023 + 0.65$$
$$= 0.9210$$

$$a_2 = f(z_2) = \frac{1}{1 + e^{-(0.9210)}}$$
$$= 0.7153$$


←
EL VALOR DE SALIDA PARA UNA RED
PARA UNA ENTRADA DE: 0.1

* AHORA SUPONGAMOS QUE LA VERDAD
UNIVERSAL ES:

$$T = 0.25$$



$$\begin{aligned}
 z_1 &= 0.415 \\
 a_1 &= 0.6023 \\
 z_2 &= 0.9210 \\
 a_2 &= 0.7153
 \end{aligned}
 \quad
 \begin{aligned}
 T &= 0.25 \\
 E &= \frac{1}{2} (T - a_2)^2 \\
 &= 0.1083
 \end{aligned}
 \quad
 \begin{aligned}
 &\text{CALCULAMOS} \\
 &\text{EL ERROR} \\
 &E
 \end{aligned}$$



epochs = 1000

$\epsilon = 0.001$



ACTUALIZAMOS PESOS Y
SEGUN CON UN N° DE
ITERACIONES O HASTA
QUE EL ERROR SEA: 0.001



$\eta = 0.4$ TASA DE
APRENDIZAJE

$$w_2 \rightarrow w_2 - \eta \cdot \frac{\partial E}{\partial w_2}$$

$$w_2 \rightarrow w_2 - \eta \cdot (-(T - a_2)) \cdot (a_2 (1 - a_2)) \cdot (a_1)$$

$$w_2 \rightarrow 0.45 - 0.4 \cdot (-(0.25 - 0.7153)) \cdot (0.7153 (1 - 0.7153)) \cdot (0.6023)$$



EL GRADIENTE DE w_2 :

0.05706



$$w_2 \rightarrow 0.45 - 0.4 \cdot 0.05706$$

$$w_2 \rightarrow 0.427 \quad \text{UPDATE } w_2: w_2 = 0.45$$



$$w_2 = 0.427$$

• UPDATE b_2 :

$$b_2 \rightarrow b_2 - \eta \cdot (-(T - a_2)) \cdot (a_2(1 - a_2)) \cdot 1$$

$$b_2 \rightarrow 0.612$$

• UPDATE W_1 :

$$W_1 \rightarrow W_1 - \eta \cdot (-(T - a_2)) \cdot (a_2(1 - a_2)) \cdot (W_2) - a_1(1 - a_1) \cdot X_1$$

$$W_1 \rightarrow 0.15 - 0.4 \cdot (6 \text{ ~~antes~~ })$$

$$W_1 \rightarrow 0.15 - 0.4 \cdot 0.001021$$

$$W_1 \rightarrow 0.1496$$

• UPDATE b_1 :

$$b_1 \rightarrow b_1 - \eta \cdot (-(T - a_2)) \cdot (a_2(1 - a_2)) \cdot (W_2) \cdot a_1(1 - a_1) \cdot 1$$

$$b_1 \rightarrow 0.40 - 0.4 \cdot 0.001021$$

$$b_1 \rightarrow 0.3959$$

*** ESTO COMPLETA LA 1ª ITERACIÓN ***

(ÉPOCA DEL PROCESO DE ENTRENAMIENTO)

- REALIZAMOS OTRA RONDA DE PROPAGACIÓN HACIA DELANTE $\rightarrow$ FORWARD PROPAGATION.

- CALCULAMOS EL ERROR

- RONDA DE $\rightarrow$ BACK PROPAGATION (UPDATE PESOS Y SESGOS)

ALGORITMO DE ENTRENAMIENTO COMPLETO

1. INICIALIZAMOS PESOS Y SESGOS CON VALORES ALEATORIOS.
2. REPETIMOS ITERATIVAMENTE ESTOS PASOS:
 1. CALCULAR LA SALIDA DE LA RED MEDIANTE PROPAGACIÓN DIRECTA.
 2. CALCULAR ERROR ENTRE PREDICCIÓN Y VERDAD ABSOLUTA.
 3. ACTUALIZAR LOS PESOS Y SESGOS DE LOS NODOS CON BACKPROPAGATION.
4. REPETIR LOS PASOS ANTERIORES HASTA ALCANZAR UN LÍMITE DE ITERACIONES/ÉPOCAS O HASTA QUE EL ERROR ESTE POR DEBAJO DEL UMBRAL DEFINIDO.

GRADIENTE EVANESCENTE

DEEP LEARNING MODULO 2

#####

- LA FUNCIÓN SIGMOIDEA IMPIDE QUE LAS REDES NEURONALES PROPUEREN ALTES
- CON EL GRADIENTE EVANESCENTE ESTE PROBLEMA DESAPARECE

*EU EL EJEMPLO DE UNA RED CON DOS NEURONAS. LAS DERIVADAS DE LOS ERRORES RESPECTO A LOS PESOS SON LOS SIGUIENTES

$$\frac{\partial E}{\partial W_1} = 0.001021$$

$$\frac{\partial E}{\partial W_2} = 0.05706$$


LOS GRADIENTES SON MUY PEQUEÑOS.

LO + IMPORTANTES:

QUE TAN PEQUEÑO ES EL GRADIENTE DEL ERROR CON RESPECTO A W_1 .

* COMO USAMOS LA FUNCIÓN SIGMOIDEA
COMO FUNCIÓN DE ACTIVACIÓN:


- TODOS LOS VALORES INTERMEDIOS DE LA
RED ESTÁN ENTRE 0 Y 1.



- CUANDO HICIEROS BACKPROPAGATION
SEGUIREMOS MULTIPLICANDO LOS FACTORES QUE
SON INFERIORES A 1.

- TIENDEN A HACERSE CADA VEZ MÁS
PEQUEÑOS A MEDIDA QUE VAMOS DIFUNDIENDO
HACIA ATRAS EN LA RED

* ESTO SIGNIFICA QUE LAS NEURONAS DE LAS CAPAS ANTERIORES APRENDEN MUY LENTAMENTE.



* EL APRENDIZAJE LLEVA MUCHO TIEMPO Y LA PRECISIÓN DE PREDICCIÓN ESTÁ COMPROMETIDA.

* ES POR ESTO POR LO QUE NO USAMOS LA FUNCIÓN SIGMOIDEA O FUNCIONES SIMILARES COMO FUNCIONES DE ACTIVACIÓN

* SON PROPIEDADES AL PROBLEMA DEL
GRADIENTE QUE DESAPARECE

...VANISHING GRADIENT...

#####

ACTIVATION FUNCTIONS

DEEP LEARNING

MODULO 2


#####

TIPES DE FUNCIONES DE ACTIVACIÓN:

1. BINARY STEP FUNCTION.
2. LINEAR FUNCTION.
3. SIGMOID FUNCTION.
4. FUNCTION TANGENTE HIPOBÓLICA
5. ReLU (RECTIFIED LINEAR UNIT)
6. LEAKY ReLU
7. SOFTMAX FUNCTION.

● Función sigmoide:

$$a = \frac{1}{1 + \exp(-z)}$$



- CUANDO UN POSITIVO ES MUY GRANDE o TIENDE A 1 y CUANDO EL NEGATIVO ES MUY PEQUEÑO TIENDE A 0.

* SOLIDA USARSE EN LAS CAPAS OCULTAS DE UNA RED NEURONAL COMO FUNCIÓN DE ACTIVACIÓN.

* PERO SE PUEDE USAR LA FUNCIÓN ES MUY PLANA MÁS ALLÁ DE LAS REGIONES $+3$ y -3 .

* ESTO SIGNIFICA QUE UNA VEZ QUE LA FUNCIÓN SE ENCUENTRA EN ESA REGIÓN LOS GRADIENTES SE VUELVEN MUY PEQUEÑOS


* ESTO SE CONVIERTEN EL PROBLEMA DE LA FUGA DE GRADIENTES Y CUANDO LOS GRADIENTES SE ACERCAN A 0 LA RED NO APRENDE.

* LOS VALORES SON OSCILAN ENTRE 0 y 1

* ESTO SIGNIFICA QUE NO ES SÍMETRICA ALGO A SU ORIGEN.

• FUNCIÓN TANGENTE HIPERBÓLICA (TANH)

$$a = \frac{\exp(z) - \exp(-z)}{\exp(z) + \exp(-z)}$$



* ES MUY SIMILAR A LA SIGMOIDEA.


* ES SIMÉTRICA CON RESPECTO AL ORIGEN:

$$-1 \rightarrow +1$$

* AUNQUE SUPERA LA NO SIMETRÍA DE LA FUNCIÓN SIGMOIDEA, TAMBIÉN CONDUCE HACIA EL PROBLEMA DEL GRADIENTE DESFUGO EN REDES MUY PROFUNDAS.

• ReLU (UNIDAD LINEAL RECTIFICADA)

$$a = \max(0, z)$$



* ES LA FUNCIÓN DE ACTIVACIÓN MÁS USADA EN EL DISEÑO DE REDES EN LA ACTUALIDAD.

* NO ES LINEAL Y NO ACTIVA TODAS LAS NEURONAS AL MISMO TIEMPO

* SI LA ENTRADA ES NEGATIVA SE CONVERTIRA EN 0 Y LA NEURONA NO SE ACTIVARA.

* SOLO ACTIVA UNAS POCAS NEURONAS, LO QUE PROVOCA QUE LA RED SEA DIVERSA Y MUY EFICIENTE.

* ESTA FUNCION FUE UNO DE LOS PRINCIPALES AVANCES EN EL DEEP LEARNING.

* ESTA FUNCION PERMITE SUPERAR EL PROBLEMA DEL GRADIENTE DE FUGA.

* SOLO SE USA EN LAS CAPAS OCULTAS

● SOFTMAX FUNCTION:

$$a_i = \frac{e^{z_i}}{\sum_{k=1}^m e^{z_k}}$$

* ES OTRO TIPO DE SIGMOIDEA, PERO RESULTA MUY ÚTIL CUANDO TRATAMOS DE RESOLVER PROBLEMAS DE CLASIFICACIÓN.

* SE USA PRINCIPALMENTE LA CAPA DE SALIDA DEL CLASIFICADOR, DONDE ESTAMOS INTENTANDO OBTENER REALMENTE LAS PROBABILIDADES PARA DETERMINAR LA CLASE DE CADA ENTRADA.

* SI UNA RED CON 3 NEURONAS EN LA CAPA DE SALIDA, EMITE:

$$[1.6, 0.55, 0.98]$$

* SI LE APLICAMOS SOFTMAX, LAS SALIDAS SE CONVIERTEN:

$$a_i = \frac{e^{z_i}}{\sum_{k=1}^m e^{z_k}}$$

$$z = \begin{bmatrix} z_1 \\ z_2 \\ z_3 \end{bmatrix} = \begin{bmatrix} 1.6 \\ 0.55 \\ 0.98 \end{bmatrix}$$

SOFTMAX

$$a = \begin{bmatrix} a_1 \\ a_2 \\ a_3 \end{bmatrix} = \begin{bmatrix} 0.51 \\ 0.18 \\ 0.31 \end{bmatrix}$$

* DE ESTA FORMA ES MAS FACIL CLASIFICAR UN PUNTO DE DATOS DADO Y DETERMINAR A QUE CATEGORIA PERTENECE.

CONCLUSION

- LAS FUNCIONES SIGMOIDEAL E HIPERBOLICA SE EVITAN EN MUCHAS APLICACIONES HOY EN DIA. PUEDEN PRODUCIR EL PROBLEMA DEL GRADIENTE DE DESAPARECER
- **ReLU** ES LA FUNCION DE ACTIVACION MAS USADA EN LA ACTUALIDAD
SOLO SE USA EN LAS CAPAS OCULTAS
- AL CREAR UN MODELO, PODEMOS ESPERAR POR UTILIZAR ReLU Y DESPUES A OTRAS FUNCIONES DE ACTIVACION SI LA FUNCION ReLU NO OFRECIE UN BUEN RENDIMIENTO.

LIBRERÍAS FUNDAMENTALES

DEEP LEARNING

MODULO 3

#####

POPULAR LIBRARIES

• TENSORFLOW :

- LA MÁS POPULAR
- DESARROLLADA POR GOOGLE EN 2015 Y ENTREGADA AL PÚBLICO
- SE USA PARA MODELOS DEEP LEARNING.
- GOOGLE AÚN LA USA ACTIVAMENTE
- NO ES FÁCIL DE USAR Y LA CURVA DE APRENDIZAJE ES MUY PRONUNCIADA

• PYTORCH PyTorch :

- COMPATIBLE CON PYTHON
- BASADO EN FRAMEWORK TORCH EN LUA.
- COMPATIBLE CON ALGORITMOS DE DL QUE SE EJECUTAN EN EL GPU.
- COMPETIDOR DE TENSORFLOW.
- SE USA EN ENTORNOS DE INVESTIGACIÓN ACADÉMICA.
- EN APP DE DL QUE REQUIEREN LA OPTIMIZACIÓN DE EXPRESIONES
- SE UTILIZA ACTIVAMENTE EN FACEBOOK.
- NO ES FÁCIL DE USAR Y LA CURVA DE APRENDIZAJE ES MUY PRONUNCIADA

• KERAS **K** :

- ES UNA API DE ALTO NIVEL PARA CREAR MODELOS DP.
- MUY FÁCIL DE USAR
- SIMPLICIDAD SINTÁCTICA
- SE PUEDE CONSTRUIR UNA RED MUY COMPLEJA CON POCAS LÍNEAS DE CÓDIGO.
- SE EJUTA SOBRE UNA BIBLIOTECA DE BAJO COMO TENSORFLOW.
- PARA USAR KERAS, PRIMERO HAY QUE INSTALAR TENSORFLOW.
- COMPATIBLES CON GOOGLE.

• THEANO — — — → NO HAY SOPORTE

* PARA CREAR ALGO RÁPIDO: KERAS

* PARA TENER CONTROL SOBRE LOS NODOS Y CAPAS DE LA RED Y QUERER ORIENTAR LO QUE SUCEDE CON LA RED A LO LARGO DEL TIEMPO PYTORCH O TENSORFLOW.

MODELOS DE REGRESIÓN CON KERAS

DEEP LEARNING MODULO 3

#####

	CEMENT	WATER	FLY ASH	WATER	SUPER.	COARSE AGG.	FINE AGG.	AGE	STRENGTH
0	540.0	0.0	0.0	162.0	2.5	1040.0	676.0	28	79.79
1	540.0	0.0	0.0	162.0	2.5	1050.0	676.0	28	61.89
2	332.5	142.5	0.0	228.0	0.0	932.0	594.0	270	40.27
3	332.5	142.5	0.0	228.0	0.0	932.0	594.0	365	41.05
4	198.5	132.5	0.0	192.0	0.0	922.0	825.5	260	44.20

PAIDAS DATASETS (CONCRETE - DATA)


* CONJUNTO DE DATOS DE LA RESISTENCIA A LA COMPRESIÓN DE DIFERENTES MUESTRAS DE HORTIGÓN.

* ESTA TABLA NOS MUESTRA LA COMPOSICIÓN DE CADA MUESTRA.

* CREAR RÁPIDA MENTE UNO RED EN KERAS Y MOSTRAR AUTOMÁTICAMENTE

LA RESISTENCIA A LA COMPRESIÓN DE UNA MUESTRA DE MORFISMO.

- * 8 ENTRADAS
- * 2 CAPAS OCULTAS:
 - 5 NODOS.
- * 1 NODO DE SALIDA.



- UBTAMENTE SE USA UN NÚMERO MAYOR DE NEURONAS EN CADA OCULTA: 50 o 100.
- USAMOS UNA RED PEQUEÑA POR SIMPLICIDAD.

LOS NODOS DE UNA CAPA ESTÁN CONECTADOS CON TODOS LOS OTROS NODOS DE LA SIGUIENTE CAPA & RED DENS

1. ANTES DE COMENZAR A USAR LETRAS HAY QUE PREPARAR LOS DATOS Y TENERLOS EN EL FORMATO ADECUADO.

2. DIVIDIMOS EL MARCO DE DATOS EN LAS MARCAS DE DATOS.

- COLUMNAS DE PREDICTORES
- COLUMNA DE OBJETIVO

	CEMENT	WAST	FLY ASH	WATER	SUPER.	COARSE SSG	FINE SSG	AGG	STRENGTH
0	540.0	0.0	0.0	162.0	2.5	1040.0	676.0	28	79.79
1	540.0	0.0	0.0	162.0	2.5	1050.0	676.0	28	61.89
2	332.5	142.5	0.0	228.0	0.0	930.0	594.0	270	40.22
3	332.5	142.5	0.0	228.0	0.0	930.0	594.0	365	41.05
4	198.5	132.5	0.0	192.0	0.0	920.0	125.5	360	44.20


	CEMENT	WAST	FLY ASH	WATER	SUPER.	COARSE SSG	FINE SSG	AGG	STRENGTH
0	540.0	0.0	0.0	162.0	2.5	1040.0	676.0	28	79.79
1	540.0	0.0	0.0	162.0	2.5	1050.0	676.0	28	61.89
2	332.5	142.5	0.0	228.0	0.0	930.0	594.0	270	40.22
3	332.5	142.5	0.0	228.0	0.0	930.0	594.0	365	41.05
4	198.5	132.5	0.0	192.0	0.0	920.0	125.5	360	44.20

PREDICTORS

import keras
from keras.models import
Sequential
from keras.layers import Dense

TARGET

Sequential



model = Sequential()
n_cols = concrete_data.shape[1]

model.add(Dense(5, activation='relu',

input_shape=(n_cols,)))

```
import keras
from keras.model import Sequential
from keras.layers import Dense
```


```
model = Sequential()
n_cols = concrete_data.shape[1]

model.add(Dense(5, activation='relu',
                input_shape=(n_cols,)))
```

```
model.add(Dense(5, activation='relu'))
```

```
model.add(Dense(1))
```

```
model.compile(optimizer='adam', loss='mean_squared_error')
```




USAMOS 'adam' PARA OPTIMIZAR EN LUGAR DEL DEGRADO GRADIENTE PORQUE NO NECESITA TASA DE APRENDIZAJE


ESTO NOS DADEJA LA TAREA DE OPTIMIZAR LA TASA DE APRENDIZAJE DE NUESTROS MODELOS

```
model.fit(predictors, target)
```

```
predictions = model.predict(test_data)
```



PDF. CON METODOS DE KERAS




Keras Activation Functions: <https://keras.io/activations/>



Keras Models: <https://keras.io/models/about-keras-models/#about-keras-models>

Keras Optimizers: <https://keras.io/optimizers/>

Keras Metrics: <https://keras.io/metrics/>



X



#

