

#####

DEEP LEARNING KERAS

MODULO 1

#####

- ES UNO DE LOS CAMPOS DE LA CIENCIA
DE DATOS. (DATA SCIENCE)

≡ APLICACIONES ≡

COLOR RESTORATION

ES LA CORRECCIÓN AUTOMÁTICA Y
RESTAURACIÓN DE COLOR EN IMÁGENES
EN BLANCO Y NEGRO.

EL SISTEMA UTILIZA:

RED NEURONAL CONVOLUCIONAL

* SPEECH REENACTMENT *

(REPRESENTACIÓN DE VOZ)

- UN CLIP DE AUDIO SE SINTETIZA CON UN VIDEO Y LOS MOVIMIENTOS DE LOS LABIOS SE SINCROAN CON LOS SONIDOS Y LAS PALABRAS DEL CLIP DE AUDIO
- EL SISTEMA USA UNO:

RED NEURONAL RECURRENTE

* AUTOMATIC HANDWRITING GENERATION *

(GENERACIÓN AUTOMÁTICA DE ESCRITURA A MANO)

- UN ALGORITMO QUE PUEDE ESCRIBIR UN MENSAJE DETERMINADO CON LETRAS MUY REALISTAS
- EL SISTEMA USA UNO:

RED NEURONAL RECURRENTE

OTRAS APLICACIONES

- AUTOMATIC MACHINE TRANSLATION

(TRADUCCIÓN AUTOMÁTICA)

RED NEURONAL CONVOLUCIONAL

→ TRADUCE EL TEXTO DE UNA IMAGEN SOBRE LA MARCA

- AUTOMATICALLY ADDING SOUNDS TO SILENT MOVIES

(AGREGAR SONIDOS AUTOMÁTICAMENTE A FILMS MUDOS)

→ USA BASES DE DATOS SONOROS Y ELIGE EL SONIDO QUE MEJOR SE ADAPTA A LA ESCENA.

- CLASIFICACIÓN DE OBJETOS Y DETECCIÓN DE IMAGENES.

- COCHES AUTÓNOMOS

#####

NEURONAS Y REDES NEURONALES

DEEP LEARNING MODULO 1

#####

EL APRENDIZAJE PROFUNDO SE INSPIRA
EN GRAN MEDIDA EN LA FORMA EN LA
QUE LAS NEURONAS Y LAS REDES NEURONALES
FUNCIONAN Y PROCESAN LOS DATOS EN
EL CEREBRO.


* UNA RED NEURONAL *

LA PRIMERA IMAGEN DE UNA NEURONA
FUE DIBUJADA POR:

SANTIAGO RAMÓN Y CAJAL

EN EL AÑO: 1899

NEURONA BIOLÓGICA REAL.



1. LAS DENTRITAS RECIBEN IMPULSOS ELÉCTRICOS QUE TRANSPORTAN INFORMACIÓN O DATOS DESDE LAS SINAPSIS DE OTRAS NEURONAS CONTIGUAS.

2. LAS DENTRITAS LLEVAN LOS IMPULSOS O DATOS AL SOMA.

3. EN EL NÚCLEO LOS DATOS O IMPULSOS SE PROCESAN COMBINÁNDOLOS

4. LOS DATOS SE TRANSMITEN AL AXÓN

5. EL AXÓN LLEVA LA INFORMACIÓN PROCESADA AL BOTÓN TERMINAL O SÍNAPSIS.
6. LA SALIDA DE ESTA NEURONA SE CONVIERTE EN LA ENTRADA A MÁS DE OTRAS NEURONAS.

IMPORTANTE:


* EL APRENDIZAJE EN EL CEREBRO SE PRODUCE AL ACTIVAR REPETITIVAMENTE CIERTAS CONEXIONES NEURONALES SOBRE OTRAS, REFORZANDO ASÍ LAS CONEXIONES.

* ESTO HACE QUE SEA MÁS PROBABLE QUE PRODUZCA EL RESULTADO DESEADO CON UNA ENTRADA ESPECÍFICA

* UNA VEZ QUE SE PRODUCE EL RESULTADO DESEADO, LAS CONEXIONES NEURONALES QUE CAUSAN ESE RESULTADO SE FORTALEZCAN.

* NEURONA ARTIFICIAL *

LA NEURONA ARTIFICIAL SE CARACTERIZA DE LA SIGUIENTE MANERA:



- AXÓN: ES EL QUE TRANSMITE LA INFORMACIÓN A OTRAS NEURONAS.
- PUEDE RAMIFICARSE PARA CONECTARSE A MUCHAS OTRAS

EL PROCESO DE APRENDIZAJE SE PARECE MUCHO A LA FORMA EN QUE SE PRODUCE EL APRENDIZAJE EN EL CEREBRO.

#####


REDES NEURONALES ARTIFICIALES

DEEP LEARNING

MODULO 1

#####

LAS REDES ARTIFICIALES SE DIVIDEN EN VARIAS CAPAS.



*LOS 3 PRINCIPALES TEMAS ASOCIADOS
CON LAS REDES NEURONALES ARTIFICIALES:


1. FUNCIONES PROPAGACIÓN HACIA DELANTE.
2. PROPAGACIÓN HACIA ATRÁS.
3. ACTIVACIÓN. (FUNCIÓN SIGMOIDE)

FORWARD PROPAGATION

▶ PROPAGACIÓN HACIA DELANTE.

ES EL PROCESO MEDIANTE EL CUAL LOS
DATOS PASAN A TRAVÉS DE LAS CAPAS
DE NEURONAS DE LA RED.

DESDE EL INPUT HASTA EL OUTPUT



X_1
 X_2 $>$ - DOS ENTRADAS
- ENTEROS O FLOTANTES

W_1
 W_2 $>$ - PESOS DE LAS CONEXIONES

b_1 $\rightarrow$ SESGO (CONSTANTE)

LA NEURONA PROCESA LA INFORMACIÓN
EMITIENDO UNA SUMA PONDERADA DE ESTAS
ENTRADAS

$$a = z$$

$$z = x_1 \cdot w_1 + x_2 \cdot w_2 + b_1$$


Y AÑADE UNA CONSTANTE A LA SUMA (SESGO)

POR LO TANTO 'Z' ES LA COMBINACIÓN LINEAL
DE LAS ENTRADAS Y LOS PESOS JUNTO CON
EL SESGO. Y 'a' ES LA SALIDA.

* EL SIMPLE HECHO DE GENERAR UNA SUMA PONDERADA DE LAS ENTRADAS, LÍMITA LAS TAREAS QUE PUEDE REALIZAR LA RED NEURONAL.

* PARA MEJORAR EL PROCESAMIENTO DE LOS DATOS SERÍA MOVER LA SUMA PONDERADA A UN ESPACIO **NO LINEAL**.

* USAR: **FUNCIÓN SIGMOIDE**



• SI LA SUMA PONDERADA ES UN NÚMERO MUY GRANDE LA SALIDA DE LA NEURONA ES PRÓXIMA A 1 Y SI ES UN NEGATIVO MUY GRANDE, LA SALIDA ES PRÓXIMA A 0

*LAS TRANSFORMACIONES NO LINEALES,
COMO LA FUNCIÓN SIGMOIDE, SE DENOMINAN:

FUNCIÓN DE ACTIVACIÓN

IMPORTANTE:

- LAS FUNCIONES DE ACTIVACIÓN SON UNA CARACTERÍSTICA EXTREMADAMENTE IMPORTANTES EN LAS NEURONAS ARTIFICIALES
 - DECIDEN SI UNA NEURONA TIENE QUE ACTIVARSE O NO.
 - SI LA INFORMACIÓN QUE RECIBE LA NEURONA ES RELEVANTE O DEBE IGNORARSE
- POR LO TANTO:
UNA NEURONA SIN UNA FUNCIÓN DE ACTIVACIÓN ES BÁSICAMENTE UN MODELO DE REGRESIÓN LINEAL


- LA FUNCIÓN DE ACTIVACIÓN REALIZA UNA TRANSFORMACIÓN NO LINEAL DE LA ENTRADA LO QUE PERMITE A LA RED NEURONAL APRENDER Y REALIZAR TAREAS COMPLEJAS.

- COMO LA CLASIFICACIÓN DE IMÁGENES Y LA TRADUCCIÓN DE IDIOMAS.

#####*#####

PARA SIMPLIFICAR AUN MÁS

EJEMPLO:



- NEURONA CON UN INPUT

$$x_1 = 0.1$$

$$w_1 = 0.15$$

$$b_1 = 0.40$$

$$z = w_1 \cdot x_1 + b_1$$

$$= 0.15 \cdot 0.1 + 0.4$$

$$= 0.415$$

$$a = f(z) = \frac{1}{1 + e^{-z}}$$


$$a = f(z)$$

$$= \frac{1}{1 + e^{-z}}$$

$$= \frac{1}{1 + e^{-0.415}}$$

$$= 0.6023$$


$$\text{OUTPUT} = 0.6023$$



$$a_1 = f(z_1) = \frac{1}{1 + e^{-z}} = 0.6023$$

$$z_2 = w_2 \cdot a_1 + b_2 = 0.45 \cdot 0.6023 + 0.65 = 0.9210$$

$$a_2 = f(z_2) = \frac{1}{1 + e^{-(0.9210)}} = 0.7153$$



SALIDA DE LA RED

(RED DE 2 NEURONAS)

0.7153 = SERIA EL VALOR PREVISTO PARA UN INPUT = 0.1

ASÍ ES COMO UNA RED NEURONAL PREDICE LA SALIDA DE CUALQUIER ENTRADA.

*NO IMPORTA LO COMPLICADA QUE SEA LA RED SIEMPRE SIGUE ESTE MISMO PROCESO.

RESUMEN

DADA UNA RED NEURONAL CON UN CONJUNTO DE PESOS Y SESGOS, DEBERÍAS PODER CALCULAR LA SALIDA DE LA RED DADA CUALQUIER ENTRADA DADA.

#####*#####

#####

#####

LABORATORIO I MODULO 1

#####

REDES NEURONALES ARTIFICIALES

#####


GRADIENTE DESCENT

DEEP LEARNING

MODULO 2

#####

- REPRESENTAR UNA FUNCIÓN DE COSTO EN UN DIAGRAMA DE DISPERSIÓN
- DESCRIBIR EL ALGORITMO GRADIENTE DESCENDIENTE
- DESCRIBIR COMO SE REPRESENTAN LAS DIFERENTES ITERACIONES EN UN GRADIENTE DESCENDIENTE.



LÍNEA QUE
MEJOR SE
AJUSTA A LOS DATOS.

$$Z = wX$$

$$J(w) = \frac{1}{2M} \sum_{i=1}^M (z_i - wx_i)^2$$

Función de costo o de pérdida

- Función de Costes o de Pérdida


$$J(w) = \frac{1}{2M} \sum_{i=1}^M (z_i - wx_i)^2$$




- EL VALOR MÍNIMO O PÉRDIDA

* LO HACE QUE ESTA FUNCIÓN SEA ATRACTIVA, ES QUE ES UNA PARÁBOLA CON UN MÍNIMO GLOBAL O SOLUCIÓN ÚNICA.

$$Z = wX$$



$$J(w) = \frac{1}{2M} \sum_{i=1}^M (z_i - wx_i)^2$$



* PARA LOS DATOS DADOS, EL VALOR DE ~~w~~ QUE HACE QUE ESTA FUNCIÓN DE COSTE SEA MÍNIMA ES QUE ES $w = 2$.

* $Z = 2x$: UNA LÍNEA QUE SE AJUSTA PERFECTAMENTE A LOS PUNTOS.

✓ EL VALOR DE W EN EL CASO DE QUE TENGA MUCHOS PESOS QUE OPTIMIZAR, SE DETERMINA MEDIANTE:

≡ ALGORITMO DE DESCENSO GRADIENTE ≡


● ALGORITMO DE OPTIMIZACIÓN ITERATIVO PARA ENCONTRAR EL MÍNIMO DE UNA FUNCIÓN.

1. COMENZAMOS CON UN VALOR ALEATORIO INICIAL DE W

→ $W_0 = 0.2$

2. DAR PASOS HACIA EL PUNTO AZUL QUE ES $W=2$

3. CALCULAR GRADIENTE PARA SABER EN QUE DIRECCIÓN MOVERNOS.



4. EN LA FUNCIÓN DE PÉRDIDA EL VALOR DE $W=0.2$. EL GRADIENTE VIENE DADO POR LA PENDIENTE DE LA TANGENTE EN $W=0.2$

5. LA MAGNITUD DEL ESCALÓN SE CONTROLA CON:
LA TASA DE APRENDIZAJE

* CUANTO MAYOR SEA LA TASA DE APRENDIZAJE, MAYOR SERÁ EL PASO QUE DEMOS.

* CUANTO MENOR SEA LA TASA, MENOR SERÁ EL PASO A DAR.

LEARNING RATE

$$\rightarrow \eta \frac{\partial J}{\partial W}$$


6. DADOS EL PASO Y PASAMOS A W_1

7. LO CALCULAMOS COMO W_0 Y ESTO REPRESENTA LA PRIMERA ITERACIÓN DEL ALGORITMO.

8. EN W_1 REPETIMOS EL MISMO PROCESO DE CALCULAR EL GRADIENTE Y UTILIZAMOS LA MISMA VELOCIDAD DE APRENDIZAJE PARA (TASA)

CONTROLAR LA MAGNITUD DEL PASO HACIA EL MÍNIMO.

9. REPETIMOS EL PASO HASTA QUE ALCANZAMOS EL MÍNIMO, O UN VALOR DE LA FUNCIÓN DE COSTE QUE ESTE MUY CERCA DEL MÍNIMO DELTA DE UN VALOR PEQUEÑO Y PREDEFINIDO



$$w_1 \rightarrow w_0 - \eta \frac{\partial J}{\partial w}$$

AL ELEGIR LA TASA DE APRENDIZAJE, HAY QUE TENER CUIDADO. UNA TASA MUY ALTA PUEDE CONDUCIR A GRANDES PASOS, Y FINALMENTE A PERDER EL MÍNIMO.

* UNA TASA MUY PEQUEÑA PUEDE RESULTAR EN PASOS EXTREMADAMENTE PEQUEÑOS Y POR LO TANTO HACER QUE EL ALGORITMO TARDE MUCHO EN ENCONTRAR EL PUNTO MÍNIMO.



● EJEMPLO:

COMO CADA ITERACIÓN CON UNA TASA DE APRENDIZAJE DE 0.4 AFECTA A LA FORMA EN QUE LA LÍNEA RESULTANTE SE AJUSTA A LA LÍNEA DE LA ÍZQUIERDA.

INITIALIZATION:

$$Z = WX$$

$$J(W) = \frac{1}{2M} \sum_{i=1}^M (z_i - wx_i)^2$$



1. INICIALIZAMOS $W=0 \Rightarrow Z=0$

- COMO ES UNA LÍNEA HORIZONTAL.

- EL COSTE ES ELEVADO Y LA LÍNEA NO SE AJUSTA BIEN.



2. W SE AJERA A 2 TRAS LA PRIMERA ITERACIÓN

- COMO LA PENDIENTE ES MUY PROCLIVADA

CUANDO W ES IGUAL A 0, EL NUEVO VALOR

DE W PRODUCE UNA GRAN CAÍDA EN LA FUNCIÓN DE PÉRDIDA.

3. LA LÍNEA RESULTANTE SE AJUSTA MEJOR.





W

AUNQUE SE AJUSTA MEJOR, AUN HAY ESPACIO DE MEJORA.




4. EN LA SIGUIENTE ITERACIÓN W CONTINUÁ MOVIÉNDOSE HACIA $W=2$. COMO LA PENDIENTE NO ESTÁ TAN PRONUNCIADA COMO ANTES, EL ESCALÓN ES MENOR.

5. PERO LA FUNCIÓN DE COSTE SIGUE BAJANDO DE VALOR. LA LÍNEA RESULTANTE SE ACERCA A LA LÍNEA IDEAL.



W

*LA MISMA OBSERVACIÓN SE OBSERVA EN LA TERCERA ITERACIÓN: Y CON LA 4^{ta}.





*DESPUÉS DE 4 ITERACIONES
ESTAMOS CASI EN $W=2$
*LA LÍNEA RESULTANTE CASI SE
AJUSTA PERFECTAMENTE AL
DIAGRAMA DE DISPERSIÓN.

CON CADA ITERACIÓN, EL PESO SE DETERMINA
DE FORMA PROPORCIONAL AL NEGATIVO DEL
GRADIENTE DE LA FUNCIÓN EN EL PUNTO
ACTUAL.


* POR LO TANTO:

- SI SE INICIALIZA LA PONDERRACIÓN EN UN VALOR QUE ESTÉ A LA DERECHA DEL MÍNIMO, EL GRADIENTE POSITIVO HACE QUE w SE MUOVA HACIA LA IZQUIERDA HACIA EL MÍNIMO:

$$w^{i+1} \rightarrow w^i - \eta \frac{\partial J}{\partial w}$$



w



* RECAP *

↓ (PESO)

- EL MEJOR VALOR DE W SE DETERMINA MEDIANTE UN ALGORITMO LLAMADO:
 - DESCENSO GRADIENTE
 - EL DESCENSO GRADIENTE ES UN ALGORITMO DE OPTIMIZACIÓN ITERATIVO PARA ENCONTRAR EL MÍNIMO DE UNA FUNCIÓN.
 - AL ELEGIR LA TASA DE APRENDIZAJE PARA SU CÁLCULO, HAY QUE TENER CUIDADO:
 - UNA TASA ALTA: PUEDE CAUSAR AGRAVOS PARA QUE PUEDAN LLEVAR A PERDER UN PUNTO MÍNIMO.
 - UNA TASA BAJA: PASOS EXTREMADAMENTE PEQUEÑOS Y HACE QUE EL ALGORITMO TARDE MUCHO EN ENCONTRAR EL PUNTO MÍNIMO.
- ** LA TASA DE APRENDIZAJE HAY QUE ELEGIRLA ANTES DE COMENZAR A ENTRENAR EL MODELO ****

IMPORTANTE

1. FUNCIÓN DE COSTO (O PÉRDIDA):

- MIDE CUÁNTO DE BÉN ESTÁ PREDICIENDO UNA RED NEURONAL (MSE)
- EL OBJETIVO ES MINIMIZAR ESTA FUNCIÓN ANTES EL ENTRENAMIENTO (REDUCIR EL ERROR)

$$J(w) = \frac{1}{2M} \sum_{i=1}^M (z_i - wx_i)^2$$

2. DESCENSO GRADIENTE:

- ALGORITMO QUE AJUSTA LOS PESOS DE LA RED PARA MINIMIZAR LA FUNCIÓN DE COSTO.

- GRADIENTE: ES UNA DERIVADA PARCIAL DE LA FUNCIÓN DE COSTO. INDICA LA DIRECCIÓN QUE DEBES TENER CADA PESO:

PARA UN PESO w , SU GRADIENTE SERÁ:

$$\frac{\partial \text{costo}(J)}{\partial w}$$

3. TASA DE APRENDIZAJE: (α)

- ES UN FACTOR DE ESCALA QUE CONTROLA QUE GRANDES SON LOS PESOS:

$$w_{\text{nuevo}} = w_{\text{viejo}} - \alpha \frac{\partial \text{costo}(J)}{\partial w}$$


RETROPROPAGACIÓN

DEEP LEARNING MODULO 2

#####


EN REDES NEURONALES EL AJUSTE DE
LOS PESOS NO SE HACE EN UN SOLO
NODO, SE RESOLTA A TRAVÉS DE:

BACKPROPAGATION



- EN UN ENTORNO DE APRENDIZAJE SUPERVISADO CADA PUNTO DE DATOS TIENE ETIQUETADO VERDAD BÁSICA CORRESPONDIENTE.

- Y EL ENTRENAMIENTO ES NECESARIO CUANDO EL VALOR PREDICHO POR LA RED NEURONAL NO COINCIDE LA VERDAD BÍSEA PARA UNA ENTRADA DETERMINADA



T : GROUND TRUTH

$T \ll a_2$

#####

ALGORITMO BACKPROPAGATION

EL PROCESO DE ENTRENAMIENTO COMIENZA:



1. CALCULAR EL ERROR E :

- ENTRE LOS VALORES PRONOSTICADOS Y LOS ETIQUETAS DE LAS UNIDADES FUNDAMENTALES.


* E : REPRESENTA EL VALOR O FUNCIÓN DE PÉRDIDA.

2. PROPAGAR EL ERROR A LA RED Y USARLO PARA REALIZAR UN DESCENSO DE GRADIENTE EN LOS DIFERENTES PESOS Y PÉRDAS DE LA RED:

- OPTIMIZARLOS USANDO LAS MISMAS ECUACIONES:

$$W_i \rightarrow W_i - \eta \cdot \frac{\partial E}{\partial W_i}$$

$$b_i \rightarrow b_i - \eta \cdot \frac{\partial E}{\partial b_i}$$




1. CALCULAMOS EL ERROR CUADRÁTICO MEDIO (MSE)

$$E = \frac{1}{2} (T - a_2)^2 \rightarrow E = \frac{1}{2m} \sum_{i=1}^m (T_i - a_{2,i})^2$$

2. ACTUALIZAMOS: w_2, b_2, w_1 y b_1

- PROPAGANDO EL ERROR A LA REJ.




UPDATING: w_2

$$w_2 \rightarrow w_2 - \eta \cdot \frac{\partial E}{\partial w_2}$$

$$E = \frac{1}{2} (T - a_2)^2$$




$$\frac{\partial E}{\partial a_2}$$



$$a_2 = f(z_2) = \frac{1}{1 + e^{-z_2}}$$




$$\frac{\partial a_2}{\partial z_2}$$



$$z_2 = a_1 \cdot w_2 + b_2$$



$$\frac{\partial z_2}{\partial w_2}$$



*UPDATING W_2 *

LA DERIVADA DEL ERROR CON RESPECTO A W_2 SERÍA:

$$W_2 \rightarrow W_2 - \eta \cdot \frac{\partial E}{\partial W_2}$$

(EL PRODUCTO DE LAS DERIVADAS INDIVIDUALES)


LA DERIVADA E RESPECTO W_2 :

$$\frac{\partial E}{\partial W_2} = \frac{\partial E}{\partial a_2} \cdot \frac{\partial a_2}{\partial z_2} \cdot \frac{\partial z_2}{\partial W_2}$$

$$= (-(1-a_2)) \cdot (a_2(1-a_2)) \cdot (a_1)$$

$$W_2 \rightarrow W_2 - \eta \cdot (-(1-a_2)) \cdot (a_2(1-a_2)) \cdot (a_1)$$

*¿CÓMO ENCONTRAR LAS DERIVADAS? *



*UPDATING b_2 *

- EXACTAMENTE IGUAL, PERO LA DIFERENCIA CON LA DERIVADA DE Z_2 CON RESPECTO A b_2 ES 1 Y NO LA ENTRADA DE UNO

$$b_2 \rightarrow b_2 - \eta \cdot \frac{\partial E}{\partial b_2}$$

- DERIVADA DE E RESPECTO b_2 :


$$\frac{\partial E}{\partial b_2} = \frac{\partial E}{\partial a_2} \cdot \frac{\partial a_2}{\partial z_2} \cdot \frac{\partial z_2}{\partial b_2}$$

$$= (-(1-a_2)) \cdot (a_2(1-a_2)) \cdot 1$$

$$b_2 \rightarrow b_2 - \eta \cdot (-(1-a_2)) \cdot (a_2(1-a_2)) \cdot 1$$

*UPDATING w_1 *

- USAMOS ESTA EXPRESIÓN PARA ACTUALIZAR w_1 . PERO EL ERROR NO ESTÁ RELACIONADO EXPLÍCITAMENTE CON w_1 .



$$w_1 \rightarrow w_1 - \eta \cdot \frac{\partial E}{\partial w_1}$$

USAMOS LA CADENA

*E ES UNA FUNCIÓN DE a_2 :

$$E = \frac{1}{2} (T - a_2)^2 \longrightarrow \frac{\partial E}{\partial a_2}$$

* a_2 UNA FUNCIÓN DE z_2 :

$$a_2 = f(z_2) = \frac{1}{1 + e^{-z_2}} \longrightarrow \frac{\partial a_2}{\partial z_2}$$

* z_2 ES UNA FUNCIÓN DE a_1 :

$$z_2 = a_1 \cdot w_2 + b_2 \longrightarrow \frac{\partial z_2}{\partial a_1}$$

* a_1 ES UNA FUNCIÓN DE z_1 :

$$a_1 = f(z_1) = \frac{1}{1 + e^{-z_1}} \longrightarrow \frac{\partial a_1}{\partial z_1}$$

* z_1 ES UNA FUNCIÓN DE w_1 :

$$z_1 = x_1 \cdot w_1 + b_1 \longrightarrow \frac{\partial z_1}{\partial w_1}$$

● LA DERIVADA DE E RESPECTO W_1 ES LA MULTIPLICACION DE LAS DERIVADAS INDIVIDUALES:

$$W_1 \rightarrow W_1' - \eta \cdot \frac{\partial E}{\partial W_1}$$

$$\frac{\partial E}{\partial W_1} = \frac{\partial E}{\partial a_2} \cdot \frac{\partial a_2}{\partial z_2} \cdot \frac{\partial z_2}{\partial a_1} \cdot \frac{\partial a_1}{\partial z_1} \cdot \frac{\partial z_1}{\partial W_1}$$

$$= (-(T - a_2)) \cdot (a_2(1 - a_2)) \cdot (W_2) \cdot a_1(1 - a_1) \cdot X_1$$

$$W_1 \rightarrow W_1' - \eta \cdot (-(T - a_2)) \cdot (a_2(1 - a_2)) \cdot (W_2) \cdot a_1(1 - a_1) \cdot X_1$$

***UPDATING b_1 ***


$$b_1 \rightarrow b_1 - \eta \cdot \frac{\partial E}{\partial b_1}$$

$$\frac{\partial E}{\partial b_1} = \frac{\partial E}{\partial a_2} \cdot \frac{\partial a_2}{\partial z_2} \cdot \frac{\partial z_2}{\partial a_1} \cdot \frac{\partial a_1}{\partial z_1} \cdot \frac{\partial z_1}{\partial b_1}$$

$$= (-(T - a_2)) \cdot (a_2(1 - a_2)) \cdot (W_2) \cdot a_1(1 - a_1) \cdot 1$$

$$b_1 \rightarrow b_1 - \eta \cdot (-(T - a_2)) \cdot (a_2(1 - a_2)) \cdot (W_2) \cdot a_1(1 - a_1) \cdot 1$$

* BACKPROPAGATION EXAMPLE *



$$z_1 = w_1 \cdot x_1 + b_1$$

$$= 0.15 \cdot 0.1 + 0.40$$
$$= 0.415$$

$$a_1 = f(z_1) = \frac{1}{1 + e^{-(0.415)}}$$
$$= 0.6023$$

$$z_2 = w_2 \cdot a_1 + b_2$$


$$= 0.45 \cdot 0.6023 + 0.65$$
$$= 0.9210$$

$$a_2 = f(z_2) = \frac{1}{1 + e^{-(0.9210)}}$$
$$= 0.7153$$


←
EL VALOR DE SALIDA PARA UNA RED
PARA UNA ENTRADA DE: 0.1

* AHORA SUPONGAMOS QUE LA VERDAD
UNIVERSAL ES:

$$T = 0.25$$



$$\begin{aligned}
 z_1 &= 0.415 \\
 a_1 &= 0.6023 \\
 z_2 &= 0.9210 \\
 a_2 &= 0.7153
 \end{aligned}
 \quad
 \begin{aligned}
 T &= 0.25 \\
 E &= \frac{1}{2} (T - a_2)^2 \\
 &= 0.1083
 \end{aligned}
 \quad
 \begin{aligned}
 &\text{CALCULAMOS} \\
 &\text{EL ERROR} \\
 &E
 \end{aligned}$$



epochs = 1000

$\epsilon = 0.001$



ACTUALIZAMOS PESOS Y
SEGUN CON UN N° DE
ITERACIONES O HASTA
QUE EL ERROR SEA: 0.001



$\eta = 0.4$ TASA DE
APRENDIZAJE

$$w_2 \rightarrow w_2 - \eta \cdot \frac{\partial E}{\partial w_2}$$

$$w_2 \rightarrow w_2 - \eta \cdot (-(T - a_2)) \cdot (a_2 (1 - a_2)) \cdot (a_1)$$

$$w_2 \rightarrow 0.45 - 0.4 \cdot (-(0.25 - 0.7153)) \cdot (0.7153 (1 - 0.7153)) \cdot (0.6023)$$



EL GRADIENTE DE w_2 :

0.05706



$$w_2 \rightarrow 0.45 - 0.4 \cdot 0.05706$$

$$w_2 \rightarrow 0.427 \quad \text{UPDATE } w_2: w_2 = 0.45$$



$$w_2 = 0.427$$

• UPDATE b_2 :

$$b_2 \rightarrow b_2 - \eta \cdot (-(T - a_2)) \cdot (a_2(1 - a_2)) \cdot 1$$

$$b_2 \rightarrow 0.612$$

• UPDATE W_1 :

$$W_1 \rightarrow W_1 - \eta \cdot (-(T - a_2)) \cdot (a_2(1 - a_2)) \cdot (W_2) - a_1(1 - a_1) \cdot X_1$$

$$W_1 \rightarrow 0.15 - 0.4 \cdot (612)$$

$$W_1 \rightarrow 0.15 - 0.4 \cdot 0.001021$$

$$W_1 \rightarrow 0.1496$$

• UPDATE b_1 :

$$b_1 \rightarrow b_1 - \eta \cdot (-(T - a_2)) \cdot (a_2(1 - a_2)) \cdot (W_2) \cdot a_1(1 - a_1) \cdot 1$$

$$b_1 \rightarrow 0.40 - 0.4 \cdot 0.001021$$

$$b_1 \rightarrow 0.3959$$

*** ESTO COMPLETA LA 1ª ITERACIÓN ***

(ÉPOCA DEL PROCESO DE ENTRENAMIENTO)

- REALIZAMOS OTRA RONDA DE PROPAGACIÓN HACIA DELANTE $\rightarrow$ FORWARD PROPAGATION.

- CALCULAMOS EL ERROR

- RONDA DE $\rightarrow$ BACK PROPAGATION (UPDATE PESOS Y SESGOS)

ALGORITMO DE ENTRENAMIENTO COMPLETO

1. INICIALIZAMOS PESOS Y SESGOS CON VALORES ALEATORIOS.
2. REPETIMOS ITERATIVAMENTE ESTOS PASOS:
 1. CALCULAR LA SALIDA DE LA RED MEDIANTE PROPAGACIÓN DIRECTA.
 2. CALCULAR ERROR ENTRE PREDICCIÓN Y VERDAD ABSOLUTA.
 3. ACTUALIZAR LOS PESOS Y SESGOS DE LOS NODOS CON BACKPROPAGATION.
4. REPETIR LOS PASOS ANTERIORES HASTA ALCANZAR UN LÍMITE DE ITERACIONES/ÉPOCAS O HASTA QUE EL ERROR ESTE POR DEBAJO DEL UMBRAL DEFINIDO.

GRADIENTE EVANESCENTE

DEEP LEARNING MODULO 2

#####

- LA FUNCIÓN SIGMOIDEA IMPIDE QUE LAS REDES NEURONALES PROPUEREN ALTES
- CON EL GRADIENTE EVANESCENTE ESTE PROBLEMA DESAPARECE

*EU EL EJEMPLO DE UNA RED CON DOS NEURONAS. LAS DERIVADAS DE LOS ERRORES RESPECTO A LOS PESOS SON LOS SIGUIENTES

$$\frac{\partial E}{\partial w_1} = 0.001021$$

$$\frac{\partial E}{\partial w_2} = 0.05706$$


LOS GRADIENTES SON MUY PEQUEÑOS.

LO + IMPORTANTES:

QUE TAN PEQUEÑO ES EL GRADIENTE DEL ERROR CON RESPECTO A w_1 .

* COMO USAMOS LA FUNCIÓN SIGMOIDEA
COMO FUNCIÓN DE ACTIVACIÓN:


- TODOS LOS VALORES INTERMEDIOS DE LA
RED ESTÁN ENTRE 0 Y 1.



- CUANDO HAYAMOS BACKPROPAGATION
SEGUIMOS MULTIPLICANDO LOS FACTORES QUE
SON INFERIORES A 1.

- TIENDEN A HACERSE CADA VEZ MÁS
PEQUEÑOS A MEDIDA QUE VAMOS DIFUNDIENDO
HACIA ATRAS EN LA RED

*ESTO SIGNIFICA QUE LAS NEURONAS DE LAS CAPAS ANTERIORES APRENDEN MUY LENTAMENTE.



*EL APRENDIZAJE LLEVA MUCHO TIEMPO Y LA PRECISIÓN DE PREDICCIÓN ESTÁ COMPROMETIDA.

*ES POR ESTO POR LO QUE NO USAMOS LA FUNCIÓN SIGMOIDEA O FUNCIONES SIMILARES COMO FUNCIONES DE ACTIVACIÓN

* SON PROPIEDADES DEL PROBLEMA DEL
GRADIENTE QUE DESAPARECE


...VANISHING GRADIENT...

#####



ACTIVATION FUNCTIONS

DEEP LEARNING MODULE 2

#####



X



#

